PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Текстовый материал для обучающихся · Python, данные и алгоритмическое мышление для ИИ · 2 академических часа

Главная идея урока

Содержание

- 1. Зачем нужен этот урок
- 2. Проблемная ситуация: школьный фильтр сообщений
- 3. Основные понятия
- 4. Как это связано со словарями Python
- 5. Класс и целевая переменная
- 6. Примеры из ИИ
- 7. Как выглядит хороший датасет
- 8. Частые ошибки
- 9. Памятка
- Финальная мысль
- Материалы к занятию

Модель ИИ учится не на случайных словах и картинках, а на примерах. Каждый пример нужно описать признаками, а рядом указать правильный ответ: класс или другую целевую переменную. Такой набор примеров называется датасетом.
При этом одного набора исходных объектов недостаточно. Важно заранее решить, что именно считается объектом, какие его свойства помогут решить задачу и какой результат модель должна предсказывать. Если эти части перепутаны, даже большой объём данных не сделает задачу обучения понятной.

> **Главная схема**

> Объект отвечает на вопрос «что рассматриваем?», признаки — «что об этом объекте известно?», а целевая переменная — «что требуется предсказать?».

1. Зачем нужен этот урок

Раньше вы уже работали с переменными, условиями, циклами, списками, словарями и функциями. Вы видели, что объект можно описать набором свойств: например, фильм хранит жанр и рейтинг, товар — цену и категорию, сообщение — длину и наличие ссылки.
Теперь мы связываем эти знакомые идеи с данными для ИИ. В этом уроке не нужно обучать настоящую модель. Важнее понять, из каких частей состоит датасет и где в нём находится ответ, который модель должна научиться предсказывать.
Такое разделение необходимо уже на этапе постановки задачи. Например, фраза «создать ИИ для сообщений» слишком общая. Нужно уточнить: объектом будет одно сообщение, признаками — его измеримые характеристики, а целью — определение категории «спам» или «не спам».
После урока важно уметь:

- находить в таблице датасет, отдельный объект, признаки и целевую переменную;
- отличать категориальный ответ — класс — от числового ответа;
- представлять один объект в виде словаря Python;
- объяснять, почему целевую переменную нельзя оставлять среди входных признаков модели;
- проверять, связаны ли выбранные признаки с поставленной задачей.

2. Проблемная ситуация: школьный фильтр сообщений

Представьте, что на учебной платформе появился помощник. Он должен отмечать подозрительные сообщения: рекламные рассылки, странные ссылки, навязчивые предложения. Но помощник не читает текст как человек. Ему нужны признаки — то, что можно записать в таблицу.
Для подготовки данных каждое сообщение рассматривается отдельно. Текст можно сохранить как исходную информацию, а рядом записать более конкретные характеристики: длину, наличие ссылки и определённых слов. После этого человек указывает правильный класс сообщения. Такое указание правильных ответов называют разметкой данных.

Текст сообщения	Длина	Есть ссылка	Есть слово «скидка»	Класс
Получите скидку по ссылке	27	да	да	спам
Привет, во сколько встречаемся?	31	нет	нет	не спам
Заберите подарок сегодня	24	нет	нет	спам
Я отправил домашнее задание	28	нет	нет	не спам

В этой таблице уже есть все главные элементы: вся таблица — датасет, одна строка — объект, столбцы с описанием — признаки, а столбец «Класс» — правильный ответ.
Столбцы «Есть ссылка» и «Есть слово “скидка”» содержат логические признаки: у объекта свойство либо есть, либо отсутствует. Длина, напротив, является числовым признаком. Один объект может быть описан признаками разных типов.
Отдельный признак не всегда однозначно определяет класс. Например, сообщение без ссылки всё равно может оказаться спамом, как в строке «Заберите подарок сегодня». Модель должна искать сочетания признаков и закономерности во многих примерах, а не применять правило по одной строке.

> **Обрати внимание**
>
> Значения признака должны вычисляться по одному и тому же правилу для всех объектов. Например, при подсчёте длины текста нужно заранее решить, учитываются ли пробелы и знаки препинания, а затем использовать выбранное правило во всём датасете.

Мини-проверка

Рассмотрите строку «Я отправил домашнее задание». Что здесь является объектом, какие значения признаков указаны и какой класс назначен объекту?
Объект — всё сообщение. Среди его признаков указаны длина, отсутствие ссылки и отсутствие слова «скидка». Правильный класс — «не спам».

3. Основные понятия

Одни и те же данные можно хранить в таблице, списке словарей или другом формате. Однако смысл частей датасета от формата не меняется: в нём всё равно есть отдельные примеры, их характеристики и ожидаемые ответы.

Понятие	Простое объяснение	Пример
Датасет	Набор примеров для анализа или обучения модели.	Таблица сообщений с признаками и классами.
Объект	Один пример из датасета.	Одно сообщение, одна картинка, один товар.
Признак	Характеристика объекта, по которой модель делает вывод.	Длина сообщения, наличие ссылки, жанр фильма.
Класс	Категория объекта в задаче классификации.	спам / не спам; кот / собака.
Целевая переменная	Ответ, который модель должна научиться предсказывать.	Класс сообщения, цена, балл, рейтинг.

Границы объекта зависят от задачи. В датасете сообщений объектом может быть одно сообщение, а в датасете диалогов — целая переписка. Поэтому объект нельзя определить только по внешнему виду данных: сначала нужно знать, какую задачу решают.
Признак также выбирается относительно задачи. Цена товара может быть признаком, если требуется предсказать спрос, но становится целевой переменной, если задача состоит в прогнозировании самой цены. Следовательно, один и тот же столбец в разных задачах может играть разные роли.

> **Важно**
>
> Не каждый столбец таблицы автоматически является полезным признаком. Например, номер строки помогает различать записи, но обычно не описывает свойства сообщения и не должен влиять на решение о спаме.

4. Как это связано со словарями Python

Один словарь Python похож на карточку объекта. В ИИ такая карточка может стать одной строкой датасета.

```
message = {
    "text": "Получите скидку по ссылке",
    "length": 27,
    "has_link": True,
    "has_discount_word": True,
    "class": "spam"
}
```

Здесь объект — одно сообщение. Признаки — `length`, `has_link`, `has_discount_word`. Класс хранится по ключу `class` и может принимать значения `spam` или `no_spam`.
Ключи словаря обозначают названия характеристик, а значения содержат данные конкретного объекта. Например, значение `True` у ключа `has_link` означает, что у данного сообщения зафиксировано наличие ссылки. У другого объекта набор ключей желательно сохранить тем же, а значения могут отличаться.
Признак `text` содержит исходный текст. В простом учебном примере из него сначала извлекают более конкретные признаки: длину, наличие ссылки, ключевые слова и другие сигналы. Это позволяет представить текст в форме характеристик, с которыми можно выполнять вычисления.
Если таких словарей много, получается набор примеров. Такой набор уже можно представить как небольшой датасет. При этом важно следить за единообразием: например, не следует в одном словаре использовать ключ `has_link`, а в другом — другое название для того же свойства.

> **Частая ошибка**
>
> Значения `True` и `False` — логические значения Python, а не строки. Записи `True` и `"True"` имеют разные типы, поэтому формат признака должен оставаться одинаковым во всех объектах.

В таблице из раздела 2 наличие ссылки записано словами «да» и «нет», а в словаре — значениями `True` и `False`. Перевести одно в другое можно сравнением:

```
value = "да"              # значение из таблицы
has_link = value == "да"  # сравнение даёт логическое значение
print(has_link)           # True
```

Мини-проверка

Какие ключи в словаре описывают входные данные, а какой ключ хранит ожидаемый ответ?
К входным данным относятся `text`, `length`, `has_link` и `has_discount_word`. Ожидаемый ответ хранится по ключу `class`.

5. Класс и целевая переменная

Класс — это категория. Он нужен в задачах классификации: спам или не спам, кот или собака, срочное обращение или обычное обращение.
Целевая переменная — более широкое понятие. Это любой ответ, который модель должна предсказать. Иногда это категория, а иногда число: цена, балл, рейтинг, время выполнения.
Таким образом, каждый класс может быть значением целевой переменной в задаче классификации, но не каждая целевая переменная является классом. Например, числа 2500 и 3100 могут быть значениями прогнозируемой цены, однако они не обозначают категории объектов.

> **Важно**
>
> Класс — это целевой ответ в задаче классификации. Набор правил `if` / `elif`, который человек пишет сам, — это не обучаемая ML-модель: такие правила заданы заранее. Модель машинного обучения сама подбирает зависимость между признаками и классом по размеченным примерам.

Задача	Объект	Признаки	Целевая переменная
Спам-фильтр	Сообщение	Длина, ссылка, подозрительные слова	Класс: спам / не спам
Прогноз цены	Товар	Категория, бренд, отзывы, сезон	Цена
Рекомендации фильмов	Пользователь или фильм	Жанры, просмотры, оценки	Интерес или оценка
Обращения в поддержку	Текст обращения	Ключевые слова, срочность	Класс обращения

Важное правило: целевая переменная не должна попадать в признаки. Иначе модель будет не учиться, а подглядывать правильный ответ.
Например, если при обучении спам-фильтра передать модели и признаки сообщения, и готовое значение столбца «Класс», то определить ответ станет слишком легко: он уже

присутствует во входных данных. Но для нового сообщения правильный класс заранее неизвестен, поэтому такая модель не сможет честно решить реальную задачу.

> **Проверка постановки задачи**
>
> Полезно сформулировать задачу одним предложением: «По признакам объекта нужно предсказать целевую переменную». Для спам-фильтра: «По длине сообщения, наличию ссылки и ключевых слов нужно предсказать класс “спам” или “не спам”».

6. Примеры из ИИ

Схема «объект — признаки — цель» применяется к разным типам данных. Меняется содержание признаков и ответа, но общий способ постановки задачи сохраняется.

Классификация сообщений

Объект — одно сообщение. Признаки — длина, наличие ссылки, слова «скидка», «подарок», «срочно», количество восклицательных знаков. Класс — спам или не спам.
Наличие подозрительного слова само по себе не гарантирует, что сообщение является спамом. Например, слово «подарок» может встретиться и в обычной переписке. Поэтому модель сравнивает признаки сразу у многих размеченных сообщений.

Классификация изображений

Объект — одно изображение. Для модели оно превращается в данные: пиксели, цвета, контуры, формы. Класс — кот, собака, птица, автомобиль и так далее.
В датасете изображения должны быть связаны с правильными классами. Если фотографию собаки по ошибке разметить как «кот», модель получит противоречивый учебный пример. Поэтому аккуратность разметки важна не меньше, чем количество объектов.

Классификация обращений

Объект — одно обращение в поддержку. Признаки — ключевые слова, длина текста, тема, срочность. Класс — техника, оплата, доставка, жалоба или вопрос.
Названия классов должны использоваться последовательно. Если одинаковые обращения в одних строках обозначены классом «оплата», а в других — «платёж», хотя это одна категория, данные следует привести к единому набору названий.

Рекомендации

Объектом может быть пользователь, фильм, товар или действие пользователя. Признаки — просмотры, оценки, жанры, покупки, похожие интересы. Цель — предсказать интерес, оценку или следующий подходящий объект.
Перед подготовкой такого датасета особенно важно определить объект. Если в одной строке описывается пользователь, признаки относятся к его действиям и интересам. Если строка описывает фильм, признаки относятся уже к жанрам, оценкам и другим свойствам фильма.

Мини-проверка

Пусть требуется предсказать итоговый балл за работу по количеству выполненных заданий и числу допущенных ошибок. Что является объектом, признаками и целевой переменной?
Объект — одна работа. Признаки — количество выполненных заданий и число ошибок. Целевая переменная — итоговый балл; это числовой ответ, а не класс.

7. Как выглядит хороший датасет

Хороший датасет не обязательно должен быть очень большим, но он должен соответствовать задаче и быть подготовлен последовательно. Качество примеров влияет на то, какие закономерности сможет обнаружить модель.

- В датасете достаточно примеров, а не один случай. Несколько разных объектов позволяют искать общие признаки, а не запоминать единственный пример.
- Все объекты описаны похожим набором признаков. Если у части строк отсутствует значение, нужно понимать, почему оно отсутствует и как это обозначено.
- Целевая переменная отделена от признаков. Она используется как правильный ответ при обучении, но не передаётся модели как подсказка.
- Ответы размечены аккуратно: без путаницы в названиях классов и без разных обозначений одной категории.
- Признаки связаны с задачей, а не добавлены случайно. Для каждого признака должно быть возможно объяснить, какую информацию об объекте он содержит.
- Значения записаны в едином формате. Например, наличие ссылки не стоит обозначать одновременно словами «да», значением `True` и числом `1`, если формат заранее не приведён к общему виду.
- В наборе представлены разные случаи, которые могут встретиться в реальной задаче. Для спам-фильтра нужны примеры и спама, и обычных сообщений.

- В данных нет явных ошибок и дубликатов, случайно повторённых много раз. Многократное копирование одного объекта не заменяет разнообразие примеров.

Например, для спам-фильтра признак «цвет телефона отправителя» почти не поможет. А наличие ссылки или подозрительных слов может дать полезный сигнал.
При этом полезный сигнал не равен готовому правилу. Наличие ссылки может чаще встречаться в спаме, но ссылки бывают и в обычных учебных сообщениях. Именно поэтому модели нужны разнообразные размеченные примеры.

> **Важно**
>
> Большой датасет с ошибочной разметкой и случайными признаками может оказаться хуже небольшого, но аккуратно подготовленного набора. Количество примеров не заменяет качество и соответствие задаче.

8. Частые ошибки

Ошибка	Как думать правильно
Путать объект и признак	Объект — один пример. Признак — его характеристика.
Считать класс обычным признаком	Класс — это ответ, который модель должна научиться предсказывать.
Думать, что одного примера достаточно	Модели нужны многие примеры, иначе она не увидит закономерность.
Добавлять случайные признаки	Признак должен быть связан с задачей.
Давать модели правильный ответ среди признаков	Так модель не учится, а просто подсматривает ответ.
Использовать разные форматы одного признака	Одинаковые свойства нужно записывать единообразно во всём датасете.
Считать один сигнал точным правилом	Один признак может быть полезен, но не обязан однозначно определять класс.
Путать исходные данные и извлечённые признаки	Текст или изображение — исходный объект, а длина, наличие слова, цвета и формы — характеристики, полученные из него.
Менять смысл объекта между строками	Все строки одного датасета должны представлять сопоставимые примеры: например, только отдельные сообщения, а не смесь сообщений и целых диалогов.

Для самопроверки полезно выбрать любую строку и последовательно задать три вопроса: что здесь является объектом, какие данные модель получит на вход и какой ответ она должна предсказать. Если на эти вопросы нельзя ответить однозначно, структуру датасета нужно уточнить.

9. Памятка

Если видите…	То это может быть…
Вся таблица с примерами	датасет
Одна строка таблицы	объект
Столбцы, описывающие объект	признаки
Столбец с правильным ответом	класс или целевая переменная
Категории вроде «спам / не спам»	классы
Числовой ответ вроде цены или рейтинга	целевая переменная

Эта памятка описывает распространённый табличный формат. В словаре Python объект представлен одной структурой с ключами и значениями, но роли данных остаются теми же: часть значений описывает объект, а одно из них может содержать правильный ответ.

> **Короткий алгоритм разбора датасета**
>
> 1. Определить, какую задачу решают.
> 2. Найти, что считается одним объектом.
> 3. Выделить характеристики объекта — признаки.
> 4. Найти ответ, который требуется предсказывать.
> 5. Проверить, не попал ли этот ответ во входные признаки.

Финальная мысль

ИИ учится на примерах. Чтобы модель могла учиться, человеку нужно подготовить датасет: собрать объекты, описать их признаками и указать правильный ответ.

Главное — не просто заполнить таблицу, а правильно распределить роли данных. Объекты должны быть сопоставимы, признаки — относиться к задаче и записываться единообразно, а целевая переменная — хранить тот результат, который в дальнейшем потребуется получать для новых объектов.
Если можно ясно закончить фразу «по этим признакам объекта модель должна предсказать эту цель», значит основные части задачи определены правильно.

Материалы к занятию

- Урок_1_11_Датасет_объект_признак_класс_презентация_обновленная.pptx (2.7 МБ)