Табличные данные и признаки объектов

Практикум 1.12 для 10–11 классов и СПО

pandas | DataFrame | CSV | stdout-проверка

Результат занятия: открыть таблицу, увидеть её структуру, разделить столбцы по ролям и получить проверяемый вывод программы.

Таблица как датасет

Та же идея, но теперь в DataFrame

Вся таблица = датасет

Одна строка = объект

Столбец = признак или результат

Цель = то, что хотим предсказывать

В этом уроке мы не обучаем модель. Мы готовим таблицу к будущему анализу: смотрим структуру и выбираем входные столбцы.

Минимум pandas для практики

Команды короткие, результат виден сразу

```
import pandas as pd

df =
pd.read_csv('support_requests_10_11_spo.csv')
print(df.shape[0], df.shape[1])
```

pd.read_csv открывает CSV-файл
df.shape возвращает строки и столбцы
print нужен для автопроверки stdout

```
print(','.join(df.columns))
```

Важно: в заданиях для платформы не добавляем лишний текст в вывод.

Задания по уровням

Для базового практикума: L1 и L2

L1	по образцу	создать DataFrame, открыть CSV, вывести размер
L2	в изменённых условиях	вывести столбцы, типы данных, признаки, исправить код ИИ
Баланс	2 задания L1 из 8	доля L1 = 25%, не выше 30%

Уровень 3 можно оставить как расширение для сильной группы, но он не заявляется как обязательный для этого урока.

DataFrame из словаря списков

Первый короткий программный результат

```
students_dict = {
  'student': ['Аня','Илья','Мария','Тимур'],
  'sleep_hours': [7.5,6.0,8.0,5.5],
  'stress_level_1_10': [4,7,3,8]
}
df = pd.DataFrame(students_dict)
print(df.shape[0], df.shape[1])
```

Ожидаемый stdout

```
4 5
```

Проверяем не “понимание на словах”, а программу, которая создаёт таблицу и выводит её размер.

CSV обращений: структура таблицы

support_requests_10_11_spo.csv

```
df = pd.read_csv('support_requests_10_11_spo.csv')
print(df.shape[0], df.shape[1])
print(','.join(df.columns))
```

Размер таблицы

```
12 10
```

Что есть в данных: request_id, текст обращения, длина текста, признаки слов, срочность, источник, приоритет и категория.

Числовые и категориальные столбцы

Таблица готовится к анализу

```
num_cols = df.select_dtypes(include='number').columns
cat_cols = df.select_dtypes(include='object').columns

print(','.join(num_cols))
print(','.join(cat_cols))
```

Числовые	request_id, text_length, has_question…	с ними проще считать показатели
Категории	text, source, priority, category	их нужно понимать перед анализом

Список входных признаков

Не всё, что есть в таблице, нужно брать на вход

```
features = [
 'text_length','has_question','has_payment_word',

'has_delivery_word','urgency_score','source','prior
ity'
]
print(','.join(features))
```

request_id — служебный номер
text — сырой текст, его пока не преобразуем
category — ответ, его нельзя давать на вход

Формула проверки: столбец реально помогает описать объект до того, как известен ответ?

Большой учебный датасет

global_high_school_student_lifestyle_wellness_edu_10_11_spo.csv

```
students =
pd.read_csv('global_high_school_student_lifestyle_wellne
ss_edu_10_11_spo.csv')
print(students.shape[0], students.shape[1])
```

Ожидаемый stdout

```
500 11
```

данные синтетические
каждая строка — один школьник
есть числовые и категориальные столбцы
можно тренироваться без регистрации на Kaggle

Проверяем код, предложенный ИИ

ИИ помогает, но список признаков проверяет человек

```
features = ['student_id','age','gender','country','grade',
 'sleep_hours','screen_time_hours','uses_ai_for_study',
 'stress_level_1_10','exam_preparation','wellness_group']
```

Что не так?

student_id — служебный номер
wellness_group — готовый ответ
оба нужно убрать из features

Это практическое задание уровня 2: условия изменены, готовый код надо проверить и исправить.

Платформенная проверка

Один stdout — один ожидаемый результат

Задание	написать программу	не длинный ответ-рассуждение
Проверка	stdout	сравнение с эталоном
Критерий	нет лишнего текста	только числа или строка со столбцами

Пример: если ожидается `12 10`, не нужно выводить “Строк: 12, столбцов: 10”.

Итог практикума

Что должно остаться после занятия

DataFrame — это таблица pandas внутри Python
структуру таблицы можно проверить командами shape и columns
столбцы бывают числовыми и категориальными
features не должны содержать служебный id и готовый ответ
код, предложенный ИИ, нужно проверять перед запуском

Финальный продукт: выполненные программы + проверяемые выводы + исправленный список признаков.