МОДУЛЬ 1

Качество данных - ошибки, пропуски, дубли

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Команды pandas, которые понадобятся

```
import pandas as pd
```

Для проверки используется библиотека pandas.

Большинство операций pandas в этих примерах возвращают новый результат, но сами по себе не изменяют исходный DataFrame.

Практические задания

01 В этом уроке задания разделены на уровень 1 и уровень 2.

02 Перед выполнением заданий полезно сначала загрузить исходный файл в переменную df и не перезаписывать её.

03 Размер таблицы задаётся двумя числами: количеством строк и количеством столбцов.

04 Задания на максимальный возраст и отрицательное экранное время проверяют не пропуски, а логические ограничения.

Пример: проверяем пропуски

```
import pandas as pd
df = pd.read_csv('student_wellness_dirty_1_13.csv')
print(df.isna().sum().sum())
```

Если программа выводит 3, значит в таблице найдено три пропущенных значения.

Общее число не показывает, в каких именно столбцах находятся пропуски.

Аккуратная очистка

```
clean = df.drop_duplicates().copy()
clean['stress_level'] = clean['stress_level'].replace({'medum':'medium', 'hight':
    'high'})
clean.loc[(clean['age'] < 10) | (clean['age'] > 25), 'age'] = pd.NA
```

Очистка не означает, что нужно угадывать правильные значения.

Перед заменой необходимо сформулировать правило.

Итог урока

01 грязная таблица может дать неверный анализ.

02 пропуски, дубли, опечатки и странные числа ищутся разными командами.

03 пропуск и недопустимое значение — разные виды проблем и требуют разных проверок.

04 очистка должна идти по понятным правилам.

Цели практикума

01 открыть CSV-файл с учебной грязной таблицей и убедиться, что данные прочитаны в ожидаемом виде.

02 проверить размер таблицы, названия столбцов и типы представленных в них значений.

03 найти пропуски, дубли, ошибки категорий и странные числа.

04 различать отсутствие значения, повтор записи и несогласованный вариант написания категории.

Материалы к практике

01 Для работы понадобятся ноутбук с заданиями и два CSV-файла.

02 Перед началом работы необходимо проверить, что оба CSV-файла доступны из ноутбука.

Практическая работа

01 Задание №1

02 Задание №2

03 Задание №3

04 Задание №4

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами