Качество данных

Ошибки, пропуски, дубли и проверяемая очистка таблицы • урок 1.13

пропуски

дубли

опечатки

странные числа

Главная проблема урока

Таблица может выглядеть обычной, но содержать ошибки.

Пропуски, дубли и опечатки меняют расчёты.

Странные числа могут сделать вывод неверным.

ИИ-модель учится на тех данных, которые ей дали.

Сегодня каждое действие завершается проверяемым выводом программы.

Четыре типа проблем

Проблема	Пример	Команда
Пропуск	пустая ячейка, NaN	isna().sum()
Дубль	повтор строки	duplicated().sum()
Опечатка	medum, hight	unique(), replace()
Странное число	age = 150, screen = -2	max(), фильтр

Мини-набор pandas

Команда	Что показывает
read_csv()	открыть CSV
shape	строки и столбцы
isna().sum()	пропуски
duplicated().sum()	дубли
unique()	категории
replace()	исправление значений

Практические задания

№	Уровень	Результат
1	1	15 8
2	1	3
3	2	1
4	2	150
5	2	1
6	2	high,hight,low,medium,medum
7	2	high,low,medium
8	2	14 8
9	2	6

Задание на исправление ИИ-кода

ИИ может предложить неверную замену категории.

Нужно проверить направление исправления: medum → medium.

Результат должен быть точным: high,low,medium.

Это тренирует доверие с проверкой, а не слепое копирование.

Очистка по правилам

Удаляем только настоящие полные дубли.

Очевидные опечатки категорий приводим к единому виду.

Неправдоподобные числа не угадываем, а помечаем как пропуск.

После очистки снова проверяем результат.

Итоговый продукт

стартовый ноутбук с выполненными ячейками;

проверяемые stdout-результаты по 9 заданиям;

частично очищенная таблица в коде;

короткий вывод о влиянии качества данных на анализ.

Финальная мысль

Код помогает быстро найти проблемы.

Смысл помогает понять, что с ними делать.

Хорошая очистка — это не угадывание, а понятные правила.

Данные лучше проверить до выводов, а не после ошибки модели.