PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Зачем нужна разметка

Содержание

- Ключевые понятия
- Практические задания
- Групповая мини-задача
- Частые ошибки
- Итог урока
- Материалы к занятию

На прошлых занятиях таблица рассматривалась как датасет: строка описывает объект, столбцы хранят свойства объекта, а отдельный столбец может содержать правильный ответ. В задачах классификации такой правильный ответ часто появляется не сам по себе, а благодаря разметке.

Без меток алгоритм видит свойства объектов, но не знает, к каким категориям относятся примеры. Разметка связывает каждый объект с ожидаемым ответом и тем самым создаёт материал, на котором можно обучать и проверять модель классификации.

Разметка данных — это добавление меток к объектам датасета. Если примеры размечены аккуратно, будущая модель получает понятные учебные ответы. Если метки противоречат инструкции, модель начинает учиться на ошибках.

Например, одно и то же сообщение разные разметчики могут сначала отнести к разным классам. Общая инструкция помогает проверить признаки сообщения и выбрать метку по единому правилу, а не по личному впечатлению. Если правило не позволяет принять однозначное решение, объект следует выделить для дополнительной проверки.

Важно: качество разметки определяется не только количеством заполненных меток. Метки должны быть согласованными: похожие случаи при одинаковых условиях необходимо размечать одинаково.

Ключевые понятия

При работе с размеченным датасетом важно различать сам объект, его свойства и правильный ответ. Например, текст сообщения является входным признаком объекта, а значение `spam` в столбце `label` — его меткой.

Понятие	Что означает	Пример
Объект	Один пример из датасета	одно сообщение
Класс	Категория, к которой относится объект	spam / normal / needs_review
Метка	Правильный ответ, добавленный человеком или правилом	label = spam
Инструкция разметчика	Правила, по которым ставятся метки	когда ставить spam, normal, needs_review

Класс описывает один из возможных вариантов ответа, а метка показывает, какой именно класс назначен конкретному объекту. Поэтому список классов общий для задачи, но у каждого размеченного сообщения есть собственная метка.
Значение `needs_review` не означает, что объект можно не размечать. Это отдельный класс для случаев, в которых по инструкции нельзя уверенно выбрать между основными категориями. Пустая ячейка в столбце `label`, напротив, показывает, что метка ещё не назначена.
Инструкция должна применяться ко всему датасету одинаково. Если правило изменилось, необходимо проверить уже размеченные объекты: часть прежних меток может перестать соответствовать новой версии инструкции.

Практические задания

В отличие от свободного обсуждения, задания ниже дают измеримый результат: программа должна вывести конкретное число или строку. Это позволяет проверять часть работы автоматически.
Перед выполнением заданий полезно проверить названия столбцов и размер таблицы. Такая проверка помогает убедиться, что открыт нужный файл и программа обращается к существующему столбцу `label`. Пустые метки следует считать до заполнения столбца, иначе результат изменится.

№	Уровень	Что нужно сделать	Ожидаемый результат
1	1	Открыть таблицу сообщений и вывести размер	12 5
2	1	Посчитать пустые метки в label	12
3	2	Разметить сообщения по правилу и вывести количество классов	needs_review=2;normal=5; spam=5
4	2	Вывести id сообщений, требующих проверки	5,9
5	2	Посчитать полные совпадения трёх разметчиков	8
6	2	Вывести id сообщений с разногласиями	5,9
7	2	Выбрать лучший вариант для пар изображений	B,A,A,A
8	2	Исправить ошибочный код разметки, предложенный ИИ	needs_review=2;normal=5; spam=5

При сравнении с ожидаемым результатом важны не только сами значения, но и формат вывода. Например, в задании 3 названия классов, знак `=`, числа и разделители должны образовать строку `needs_review=2;normal=5;spam=5`. Лишние пояснения в выводе могут помешать автоматической проверке.

В заданиях 5 и 6 сравниваются ответы трёх разметчиков. Полным совпадением считается случай, когда все трое назначили объекту одну и ту же метку. Если хотя бы одна метка отличается, объект относится к сообщениям с разногласиями и требует отдельного анализа.

При исправлении кода, предложенного ИИ, необходимо проверять не только отсутствие синтаксических ошибок. Программа может выполняться, но неверно применять условие разметки. Надёжная проверка включает сопоставление логики кода с инструкцией и сравнение результата с ожидаемым распределением классов.

Групповая мини-задача

В группе из трёх человек распределите роли: разметчик, проверяющий, аналитик. Разметчик применяет инструкцию, проверяющий ищет спорные случаи, аналитик фиксирует итоговые метки и расхождения. Итог группы — таблица с метками и список id для дополнительной проверки.
Разметчик должен указывать метку для каждого объекта, не изменяя правила по ходу работы. Проверяющий сопоставляет решение с инструкцией и отдельно отмечает случаи, для которых возможны разные толкования. Аналитик не просто подсчитывает ответы, а связывает каждое расхождение с конкретным `id`, чтобы объект можно было быстро найти в исходной таблице. После первого прохода участники сравнивают результаты. Если метки расходятся, решение следует обсуждать через пункты инструкции и признаки объекта, а не через мнение большинства. Если инструкция не даёт однозначного ответа, объект сохраняется в списке для дополнительной проверки.
Мини-проверка: если два участника выбрали `spam`, а третий — `normal`, можно ли считать разметку полностью согласованной? Нет: хотя одна метка получила большинство голосов, полного совпадения трёх ответов нет.

Частые ошибки

- Размечать пример только по одному слову, не проверяя правило полностью. Отдельное слово может встречаться в сообщениях разных классов, поэтому необходимо учитывать все условия инструкции.
- Ставить spam там, где нет ссылки, но есть слово про приз или оплату. Наличие тематического слова само по себе не заменяет проверку обязательных признаков, указанных в правиле.
- Не использовать needs_review для спорных случаев. Попытка любой ценой выбрать `spam` или `normal` скрывает неопределённость и может добавить в датасет ошибочную метку.
- Менять инструкцию в середине работы. В результате одинаковые объекты могут получить разные метки только из-за того, что размечались в разное время.
- Путать метку с обычным входным признаком. Текст, наличие ссылки и другие свойства используются для принятия решения, а значение в `label` хранит итог этого решения.
- Считать решение большинства полным совпадением. Для полного совпадения все разметчики должны выбрать одну и ту же метку.
- Проверять только итоговое количество классов. Верное распределение по количеству ещё не гарантирует, что метки назначены правильным объектам: две ошибочно переставленные

метки могут не изменить общие числа.

Итог урока

Разметка превращает набор сырых примеров в учебный датасет. Инструкция делает работу разметчиков согласованной. Проверка расхождений помогает находить спорные случаи. Чем аккуратнее метки, тем надёжнее данные для будущей модели.
Качественный процесс разметки включает несколько последовательных действий: применение единой инструкции, фиксацию меток, поиск несовпадений и повторную проверку спорных объектов. При этом пустая метка, класс `needs_review` и разногласие между разметчиками обозначают разные ситуации и не должны смешиваться.
Перед завершением работы необходимо проверить, что каждый объект имеет допустимую метку, одинаковые правила применены ко всем строкам, а `id` спорных сообщений сохранены для дальнейшего анализа. Такая проверка позволяет обнаружить ошибки до того, как датасет будет использован для обучения модели.

Материалы к занятию

- lesson_1_14_labeling_data_reworked.pptx (54.6 КБ)

Инструкция разметчика для практикума

В этом практикуме используется фиксированная инструкция. Она нужна, чтобы разные разметчики принимали решения по одним и тем же правилам, а результат можно было проверить автоматически.
Для каждого примера учитываются только два признака: наличие ссылки (`has_link`) и наличие слова, связанного с деньгами или призом (`has_money_or_prize_word`). Значение `yes` означает, что признак обнаружен, а `no` — что он не обнаружен.

Условие	Метка
has_link = yes и has_money_or_prize_word = yes	spam
has_link = no и has_money_or_prize_word = no	normal
любая другая ситуация	needs_review

Таким образом, метка `spam` ставится только тогда, когда одновременно обнаружены оба признака: и ссылка, и слово о деньгах или призе. Например, сообщение со ссылкой и упоминанием выигрыша по этой инструкции получает метку `spam` .
Метка `normal` ставится только при одновременном отсутствии обоих признаков. Если в сообщении нет ссылки и нет слов, связанных с деньгами или призом, результатом будет `normal` .
Метка `needs_review` означает, что пример спорный: его нельзя уверенно отнести к `spam` или `normal` только по двум признакам. Такой пример лучше отправить на дополнительную проверку, а не угадывать. К этой категории относятся обе смешанные ситуации: ссылка есть, но слова о деньгах или призе нет; либо такого рода слово есть, но ссылки нет.

> **Важно:**
>
> наличие только одного признака недостаточно для метки `spam` . Частая ошибка — считать любое сообщение со ссылкой спамом. В рамках этой инструкции такое сообщение получит `needs_review` , если второй признак отсутствует.

При разметке следует использовать названия меток точно в указанном виде: `spam` , `normal` или `needs_review` . Изменение регистра, пробелы или другие варианты написания могут помешать автоматической проверке.

> **Мини-проверка:**

> если `has_link = yes`, а `has_money_or_prize_word = no`, нужно выбрать `needs_review`, потому что выполнено условие «любая другая ситуация».

Материалы к практике

Для выполнения заданий используются CSV-файлы с данными и стартовый Jupyter Notebook в формате IPYNB. При работе с файлами важно применять одну и ту же инструкцию ко всем примерам и сохранять метки в точном написании.

- annotations_by_students_1_14.csv (1.0 КБ)
- image_pairs_for_labeling_1_14.csv (843 Б)
- lesson_1_14_labeling_data_start.ipynb (5.9 КБ)
- messages_for_labeling_1_14.csv (1.1 КБ)
- messages_labeled_example_1_14.csv (1.2 КБ)