1.14. Разметка данных для задач ИИ

Практикум: метки, инструкция, согласованность и проверяемый результат

объекты
сообщения и пары изображений

метки
spam / normal / needs_review

проверка
stdout и согласованность

Главный вопрос: кто даёт модели правильные ответы?

- Модель видит примеры, но не знает, какой ответ считать верным.
- Человек или правило добавляет метку.
- По размеченным данным модель позже учится классифицировать новые объекты.

До разметки	После разметки
текст сообщения	label = spam
описание картинки	best_match = B
пример без ответа	класс известен

Понятия урока

Понятие	Коротко	Пример
Объект	один пример	одно сообщение
Метка	правильный ответ	spam
Класс	категория	spam / normal
Инструкция	правило разметки	когда ставить needs_review

Инструкция разметчика для практикума

Условие	Метка
has_link = yes и has_money_or_prize_word = yes	spam
has_link = no и has_money_or_prize_word = no	normal
другая ситуация	needs_review

Спорный пример не угадываем — отправляем на дополнительную проверку.

Учебная таблица сообщений

id	text	has_link	money/prize	label
1	Получите подарок по ссылке	yes	yes	
2	Домашнее задание проверено	no	no	
5	Бесплатный приз уже ждёт вас	no	yes	
9	Оплата прошла успешно	no	yes	

Цель: заполнить label по единой инструкции и получить проверяемый результат.

Практика теперь проверяется автоматически

Задание	Что выводит программа
размер таблицы	12 5
число пустых меток	12
подсчёт классов	needs_review=2;normal=5;spam=5
спорные id	5,9

Важно: в stdout не должно быть лишнего текста — только ожидаемый ответ.

Уровни практики

Уровень	Что делаем	Проверяемый продукт
1	работаем по образцу	размер таблицы, пустые метки
2	применяем правило в изменённых условиях	метки, counts, спорные id
3	групповая проверка	роли, файл, список расхождений

L1 — 2 задания из 8 платформенных; основная часть — L2.

Согласованность разметчиков

id	разметчик 1	разметчик 2	разметчик 3	итог
1	spam	spam	spam	совпало
5	spam	unclear	spam	обсудить
9	normal	unclear	normal	обсудить

Проверяемый результат: совпадений — 8, расхождения — 5,9.

Разметка бывает не только текстовой

Запрос	A	B	Ответ
робот помогает школьнику	робот без школьника	школьник и робот	B
кот на подоконнике	кот у окна	собака на ковре	A
плакат про сон	сон и отдых	еда и спорт	A

Идея та же: объект получает метку по инструкции.

Исправляем код, сгенерированный ИИ

```
def make_label(row):
    if row['has_money_or_prize_word'] == 'yes':
        return 'spam'
    return 'normal'
```

Ошибка: код отправляет все сообщения с призовым словом в spam.

Нужно учитывать ссылку.

Спорные случаи получают needs_review.

Ожидаемый вывод

needs_review=2;normal=5;spam=5

Частые ошибки разметки

- размечать слишком быстро
- не читать пример целиком
- менять правило в середине работы
- не использовать needs_review
- путать метку и признак
- не проверять расхождения разметчиков

Итоговый продукт практикума

Что должно получиться	Как проверяется
таблица с label	подсчёт классов
список спорных id	stdout
проверка разметчиков	совпадения и расхождения
исправленный код	ожидаемый вывод

Финальная мысль: качество разметки напрямую влияет на качество будущей модели.