Работа с CSV-файлом в Python

Урок 1.15 • практикум • 10–11 классы и СПО

CSV → DataFrame → фильтрация → sep/encoding

Основной CSV

60 строк и 12 столбцов

Фильтрация

считаем строки по условиям

CSV с ;

читаем sep и cp1251

Результат урока — программа первичной обработки таблицы с точным проверяемым выводом.

Проблема практикума

Файл есть, но Python должен прочитать его правильно

- посмотреть первые строки
- определить размер таблицы
- вывести названия столбцов
- найти нужные записи
- понять, почему файл иногда читается неверно

```
student_id,age,country,sleep_hours,stress_level
1,16,Japan,7.2,6
2,17,Brazil,6.1,8
```

Сегодня не обучаем модель: готовим первый технический шаг к анализу данных.

CSV — текстовая таблица

Внутри файла нет “магических ячеек”

```
student_id,age,country,sleep_hours,stress_level
1,16,Japan,7.2,6
2,17,Brazil,6.1,8
3,15,Germany,8.0,4
```

```
student_id | age | country | sleep | stress
1          | 16  | Japan   | 7.2   | 6
2          | 17  | Brazil  | 6.1   | 8
3          | 15  | Germany | 8.0   | 4
```

- значения разделяются запятой или другим символом
- pandas превращает текст в DataFrame
- перед анализом проверяем, что чтение прошло корректно

Файлы урока

Два CSV для разных ситуаций чтения

UTF-8 CSV

student_lifestyle_1_15_10_11_spo.csv
60 строк, 12 столбцов

Русский CSV

student_lifestyle_ru_semicolon_cp1251_1_15.csv
20 строк, 7 столбцов

- основной файл читается стандартно
- русскоязычный файл требует sep=";" и encoding="cp1251"
- данные учебные и не являются реальными персональными данными

Открываем CSV

Минимальный код

```
import pandas as pd

df =
pd.read_csv("student_lifestyle_1_15_10_11_spo.csv")
df.head()
```

- pandas подключается как pd
- read_csv открывает файл
- df — имя таблицы в Python
- head() показывает начало таблицы

Имя файла должно совпадать точно: расширение, подчёркивания, регистр букв.

Осматриваем таблицу

Команды первого знакомства

Структура

df.head() — первые строки
df.tail() — последние строки
df.sample(5) — случайные строки
df.columns — названия столбцов

Размер и типы

len(df) — количество записей
df.shape — строки и столбцы
df.dtypes — типы столбцов
df.info() — заполненность и типы

df.columns показывает названия столбцов. Не каждый столбец автоматически является признаком.

Первый проверяемый вывод

Размер таблицы

```
df =
pd.read_csv("student_lifestyle_1_15_10_11_spo.csv")
rows, cols = df.shape
print(rows, cols)
```

Ожидаемый stdout

60 12

- 60 — количество записей
- 12 — количество столбцов
- только два числа: без лишних слов

Фильтрация по одному условию

Таблице можно задавать вопросы

```
print(len(df[df["country"] == "Japan"]))
print(len(df[df["uses_ai_for_study"] == "Yes"]))
print(len(df[df["stress_level"] >= 8]))
```

Japan

4

AI = Yes

37

stress ≥ 8

9

- для текста используем ==
- для чисел можно использовать >=, <, >
- для автопроверки выводим количество найденных строк

Несколько условий

Более точный запрос к данным

```
result = df[(df["stress_level"] >= 8) &
            (df["sleep_hours"] < 6)]
print(len(result))
```

Ожидаемый stdout

6

- каждое условие берётся в скобки
- & означает “и”
- результат можно сохранить в переменную

CSV бывает разным

Разделитель не всегда запятая

```
df_ru = pd.read_csv(
    "student_lifestyle_ru_semicolon_cp1251_1_15.csv",
    sep=";",
    encoding="cp1251"
)
print(df_ru.shape[0], df_ru.shape[1])
```

Ожидаемый stdout

20 7

- sep сообщает, чем разделены значения
- encoding сообщает, как прочитать текст
- без этих параметров таблица может открыться неверно

Код, сгенерированный ИИ

Проверяем, а не копируем слепо

```
# ИИ предложил
df_ru = pd.read_csv("student_lifestyle_ru_semicolon_cp1251_1_15.csv")

# Исправляем
df_ru = pd.read_csv("student_lifestyle_ru_semicolon_cp1251_1_15.csv",
                    sep=";", encoding="cp1251")
print(df_ru.shape[0], df_ru.shape[1])
```

- ошибка: не указан разделитель ;
- ошибка: не указана кодировка cp1251
- результат должен быть 20 7

ИИ может написать правдоподобный код, но его надо проверять на данных.

Практика по уровням

2 задания L1 и 7 заданий L2

Уровень 1

открыть основной CSV
вывести размер таблицы
вывести количество записей

stdout: 60 12 / 60

Уровень 2

вывести столбцы
посчитать строки по условиям
прочитать CSV с sep/encoding
исправить код ИИ

Доля L1 — 22%, то есть не больше 30%.

Типовые ошибки

Что проверить, если код не работает

Ошибки файла

FileNotFoundError — имя и папка
UnicodeDecodeError — кодировка
Один столбец — не тот разделитель

Ошибки кода

NameError — import pandas
KeyError — точное имя столбца
& без скобок — ошибка условий

Итог практикума

CSV → DataFrame → первые вопросы к данным

- открыли основной CSV-файл
- получили размер таблицы и названия столбцов
- посчитали строки по одному и двум условиям
- прочитали CSV с разделителем и кодировкой
- исправили ошибочный код чтения файла

Если файл прочитан неверно, дальнейший анализ тоже будет неверным.