PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Введение

Содержание

- Учебный датасет
- Базовый код
- info() и describe()
- Частые ошибки
- Итог

После работы с CSV-файлом обучающиеся переходят к первым числовым вопросам к таблице: сколько записей есть, какие значения минимальные и максимальные, где средний уровень и какие числа выглядят подозрительно. Простые показатели помогают быстро осмотреть данные до более серьёзного анализа и до обучения модели ИИ.
Такой осмотр нужен, потому что даже одна ошибка в данных может повлиять на итоговые показатели. Например, необычно большое значение способно заметно увеличить среднее и создать неверное представление о типичном объекте. Поэтому статистические команды применяют не по отдельности, а сравнивают между собой: количество сопоставляют с числом строк, а среднее рассматривают вместе с минимумом и максимумом.
На этом этапе задача состоит не в том, чтобы сразу исправить таблицу, а в том, чтобы обнаружить места, которые требуют проверки.

Учебный датасет

В уроке используется файл student_lifestyle_stats_1_16.csv. Таблица содержит 35 строк и 11 столбцов: возраст, страну, класс обучения, часы сна, экранное время, часы подготовки, применение ИИ для учёбы и уровень стресса. В таблицу специально добавлены подозрительные значения: sleep_hours = 99 и screen_time_hours = 26. Они нужны, чтобы показать: среднее значение нельзя читать без минимума и максимума.
Значение считается подозрительным, если оно резко отличается от остальных или не соответствует смыслу признака. Однако необычное число ещё не обязательно является

ошибкой: сначала необходимо проверить исходный файл, единицы измерения и способ сбора данных. Только после такой проверки принимают решение об исправлении или удалении записи.
Числовые показатели отвечают на разные вопросы, поэтому одна команда не заменяет остальные.

Показатель	Что означает	Команда pandas
Количество	сколько заполненных значений есть в столбце	count()
Сумма	общий итог по числовым значениям	sum()
Минимум	самое маленькое значение	min()
Максимум	самое большое значение	max()
Среднее	примерный обычный уровень признака	mean()

Например, если в таблице 35 строк, а count() для некоторого столбца возвращает 34, значит, в этом столбце одно значение не заполнено. При этом count() не сообщает, в какой именно строке находится пропуск: команда показывает только количество непустых значений.
Для отдельного столбца показатели можно получить с помощью обращений вида df["sleep_hours"].min(), df["sleep_hours"].max() и df["sleep_hours"].mean(). Квадратные скобки выбирают столбец по его точному имени, а статистическая команда выполняется только для выбранных значений.
Обратите внимание: сумма имеет содержательный смысл не для каждого числового признака. Например, сумму часов подготовки можно интерпретировать как общий объём времени, а сумма возрастов обычно мало помогает описать обучающихся без дополнительного контекста.

Базовый код

Перед вычислением статистики необходимо убедиться, что файл успешно загружен и таблица имеет ожидаемый размер. Первые строки позволяют проверить названия столбцов и общий вид значений, а свойство shape показывает число строк и столбцов.

```
import pandas as pd

df = pd.read_csv("student_lifestyle_stats_1_16.csv")
print(df.head())
print(df.shape)
```

По умолчанию df.head() выводит первые пять строк таблицы. Это только небольшой фрагмент данных, поэтому отсутствие подозрительного значения среди первых строк не означает, что его нет в остальной таблице.
Для данного файла результат df.shape должен соответствовать паре (35, 11): первое число обозначает количество строк, второе — количество столбцов. shape не является функцией, поэтому после него не ставят круглые скобки.
Если файл находится не в текущей рабочей папке, read_csv() не сможет открыть его по одному имени. В этом случае необходимо указать корректный путь к файлу.

info() и describe()

Команда info() показывает устройство таблицы: названия столбцов, число заполненных значений и тип данных. Команда describe() даёт краткую статистику по числовым столбцам. Она не исправляет данные, а помогает увидеть первые сигналы: пропуски, странные минимумы и максимумы.

```
df.info()
df.describe()
```

В выводе info() количество непустых значений можно сравнить с общим числом строк. Если строк 35, а у столбца указано меньше 35 непустых значений, в нём есть пропуски. Тип данных также важен: столбец с числами может быть распознан как текст, если в нём встречаются посторонние символы или неоднородные значения. В таком случае числовая статистика для него может не рассчитываться как ожидается.
Для числовых столбцов describe() обычно показывает count, mean, std, min, квартильные значения 25%, 50% и 75%, а также max. Значение 50% соответствует медиане: половина наблюдений не превышает его, а другая половина не меньше него. Медиана и среднее отвечают на близкие, но не одинаковые вопросы, поэтому при наличии резко выделяющихся значений их полезно сопоставлять.

В учебной таблице максимумы для sleep_hours и screen_time_hours требуют отдельного внимания. Значения 99 и 26 нельзя автоматически считать правильными только потому, что pandas смог их прочитать как числа. Команды проверяют числовую структуру данных, но не знают, насколько значение правдоподобно по смыслу.
Мини-проверка: если df.shape показывает 35 строк, а count для столбца равен 33, сколько значений в этом столбце пропущено? Ответ: два, поскольку count() учитывает только заполненные значения.

Частые ошибки

- путать count() и sum(): первая команда считает количество заполненных значений, вторая складывает числа;
- делать вывод только по mean() и не смотреть min() / max(); крайнее значение может заметно сместить среднее;
- использовать неверное имя столбца: правильно screen_time_hours; имя должно совпадать с заголовком с учётом символов подчёркивания;
- думать, что describe() исправляет таблицу; на самом деле он только показывает статистику;
- сразу удалять подозрительное значение без проверки источника;
- считать, что count() всегда равен числу строк: при наличии пропусков результат будет меньше;
- принимать любое максимальное или минимальное значение за ошибку: крайнее значение может быть корректным, поэтому требуется содержательная проверка;
- ожидать, что head() покажет всю таблицу: без дополнительного аргумента метод выводит только первые пять строк.

Надёжная последовательность проверки выглядит так: сначала определить размер таблицы, затем изучить названия и типы столбцов, проверить заполненность и только после этого сравнить основные статистические показатели. Такой порядок уменьшает риск сделать вывод по неверно загруженным или неполным данным.

Итог

Простые показатели — это первый осмотр данных. Они помогают понять размер таблицы, увидеть заполненность столбцов, заметить крайние значения и подготовиться к более аккуратному анализу.

shape отвечает за размер таблицы, info() раскрывает её структуру, а describe() объединяет основные числовые характеристики. Отдельные команды count(), sum(), min(), max() и mean() позволяют точечно исследовать нужный столбец. При этом статистический результат является основанием для проверки, но не заменяет проверку смысла и источника данных.

Материалы к занятию

- lesson_1_16_simple_statistics_reworked.pptx (57.0 КБ)

Цели практикума

Содержание

- Практическая часть
- Материалы к практике

Числовая таблица может содержать десятки строк, поэтому просматривать каждое значение вручную неудобно. Простые статистические показатели помогают быстро оценить объём данных, диапазон значений, типичный уровень показателя и возможные проблемы с качеством данных.

- понять смысл показателей count, sum, min, max, mean;
- научиться считать показатели в pandas;
- использовать info() и describe() как быстрый обзор таблицы;
- найти пропуск и подозрительные значения по числовым столбцам;
- получить проверяемые результаты: числа и короткие строки вывода.

Показатель `count` сообщает количество заполненных значений, `sum` вычисляет их сумму, `min` и `max` задают границы диапазона, а `mean` показывает среднее арифметическое. Эти показатели отвечают на разные вопросы, поэтому один из них нельзя автоматически заменять другим.
Например, если в столбце 35 строк и одно значение пропущено, результат `count` для этого столбца будет равен 34. Пропуск не участвует и в вычислении среднего, однако необычно большое заполненное значение может заметно изменить результат `mean`.
Метод `info()` помогает проверить число строк, названия столбцов, типы данных и количество непустых значений. Метод `describe()` формирует краткую статистическую сводку по числовым столбцам. Эти методы удобны для первого обзора, но обнаруженное необычное значение следует дополнительно проверить по смыслу показателя.

Практическая часть

Основная практика построена как набор коротких программ. Каждая программа выводит одно число или одну строку. Такой формат подходит для автоматической проверки на платформе.

Перед выполнением отдельных заданий следует открыть CSV-файл в pandas и убедиться, что таблица считана полностью. Размер таблицы обычно получают из `shape`: первое число обозначает количество строк, второе — количество столбцов. Для этой таблицы запись `35 11` означает 35 строк и 11 столбцов.
При сравнении результата с ожидаемым выводом важны не только сами числа, но и их порядок. Если требуется вывести минимум, максимум и среднее, строка должна содержать значения именно в этой последовательности. Среднее в заданиях округляется до двух знаков после десятичной точки.
Задания расположены по возрастанию сложности. Сначала проверяются размер таблицы и количество заполненных значений, затем вычисляются статистики и применяются условия, а в заключительных заданиях оценивается влияние подозрительного значения и исправляется логическая ошибка в коде.
В столбце `sleep_hours` максимум равен 99, тогда как после исключения значений больше 16 среднее уменьшается с 9.37 до 6.74. Это показывает, что одно или несколько очень больших значений могут заметно сместить среднее. Исключать такие записи следует только по явно заданному условию: сам по себе высокий максимум ещё не доказывает ошибку в данных.
При подсчёте строк по условию сначала формируется логическое выражение, например `stress_level >= 8`. Каждая строка получает значение True или False, после чего количество подходящих строк можно определить по числу истинных результатов. Граница входит в условие `>= 8`, поэтому значение 8 также учитывается; в условии `< 6` значение 6, напротив, не учитывается.
Обратите внимание: `sum()` и `count()` выполняют разные действия. Вызов `sum()` для числового столбца складывает значения, а `count()` считает заполненные ячейки. Чтобы определить число пропусков, необходимо отдельно проверить отсутствующие значения, а не вычитать сумму столбца из числа строк.
Перед автоматической проверкой полезно убедиться, что программа выводит только требуемый результат. Дополнительные подписи, пояснения и служебные строки могут сделать правильное вычисление несовместимым с ожидаемым форматом.
Мини-проверка: если таблица содержит 35 строк, а `count` для `study_hours` равен 34, сколько пропусков находится в этом столбце? Какой показатель следует использовать, чтобы найти наибольшее значение `screen_time_hours`?

Материалы к практике

Для работы понадобятся инструкция, стартовый ноутбук и CSV-файлы. Перед запуском ячеек следует проверить, что путь в коде указывает на загруженный файл и pandas считывает нужную таблицу.

- README.md (613 Б)

- lesson_1_16_simple_statistics_start.ipynb (5.7 КБ)
- student_lifestyle_stats_1_16.csv (1.5 КБ)
- student_lifestyle_stats_clean_1_16.csv (1.4 КБ)