Простые показатели по данным

Урок 1.16 • практикум • 8–9, 10–11, СПО

- Открываем CSV-файл
- Считаем count, sum, min, max, mean
- Ищем подозрительные значения
- Получаем проверяемый вывод программы

Финальный результат

короткие программы, которые выводят конкретные числа

Важно

сначала проверяем данные, потом делаем выводы

От CSV к первым числовым вопросам

- Мы уже умеем открывать CSV-файл;
- видеть первые строки таблицы;
- узнавать названия столбцов;
- искать строки по условию.

- Сегодня добавляем:
- количество заполненных значений;
- сумму, минимум и максимум;
- среднее значение;
- поиск подозрительных чисел.

Пять простых показателей

Команда	Вопрос к данным	Пример
count()	Сколько значений заполнено?	34
sum()	Какой общий итог?	202
min()	Какое значение самое маленькое?	4
max()	Какое значение самое большое?	99
mean()	Какой примерно обычный уровень?	9.37

Учебный датасет

- Файл: student_lifestyle_stats_1_16.csv;
- 35 строк и 11 столбцов;
- одна строка описывает одного ученика;
- в таблице есть числовые и текстовые столбцы;
- часть значений специально сделана подозрительной.

Столбец	Что описывает
sleep_hours	часы сна
screen_time_hours	экранное время
study_hours	часы подготовки
stress_level	уровень стресса

info(): устройство таблицы

df.info()

показывает:

- названия столбцов;
- количество заполненных значений;
- тип данных в каждом столбце.

Сигнал

если строк 35, а в столбце 34 значения — есть пропуск

Важно

info() ничего не исправляет, только показывает структуру

describe(): краткая статистика по числам

Столбец	count	mean	min	max
sleep_hours	35	9.37	4	99
screen_time_hours	35	6.54	2	26
study_hours	34	2.18	1	4
stress_level	35	5.77	2	9

max = 99 для сна — подозрительно;

max = 26 для экранного времени — тоже сигнал;

describe() помогает увидеть проблему, но не решает её автоматически.

Отдельные команды по одному столбцу

```
df["sleep_hours"].count();
df["sleep_hours"].min();
df["sleep_hours"].max();
df["sleep_hours"].mean();
```

Как читать результат

count — заполненность; min/max — границы; mean — средний уровень, который надо проверять вместе с границами.

Почему среднее может обмануть

- Если в столбце есть одно странное значение, среднее сдвигается;
- sleep_hours = 99 делает среднее сна слишком высоким;
- после исключения sleep_hours > 16 среднее становится ближе к обычной картине.

Расчёт	mean sleep_hours
До проверки	9.37
После исключения > 16	6.74

Практика по уровням

Уровень	Что делаем	Результат
1	повторяем по образцу: shape, count	одно число или строка
2	считаем показатели по другим столбцам	проверяемый stdout
3	анализируем выброс и исправляем код ИИ	сравнение значений

Доля L1 в наборе: 2 из 10 заданий;

основа урока — L2 и L3;

каждое задание имеет точный ожидаемый вывод.

Исправляем код, сгенерированный ИИ

- ИИ предложил sum(), хотя нужно count();
- sum() складывает часы подготовки;
- count() считает заполненные значения;
- ожидаемый вывод: 34.

Было неверно:

```
print(df["study_hours"].sum())
```

Нужно:

```
print(df["study_hours"].count())
```

Частые ошибки

- путать count() и sum();
- считать среднее по столбцу со странным максимумом;
- использовать screen_time вместо screen_time_hours;
- думать, что describe() очищает данные;
- делать вывод только по mean().

Правило

mean читаем вместе с min и max

Правило

подозрительное значение сначала проверяем

Итоговый вывод

- В таблице 35 строк и 11 столбцов;
- в study_hours есть один пропуск;
- sleep_hours имеет подозрительный максимум 99;
- screen_time_hours имеет подозрительный максимум 26;
- простые показатели помогают быстро заметить такие сигналы.

Смысл урока

сначала считаем базовые показатели, затем осторожно делаем выводы

Финальная мысль

- Простые показатели — первый осмотр данных;
- они помогают увидеть размер, заполненность и крайние значения;
- они не заменяют анализ, но делают его надёжнее;
- перед обучением модели таблицу надо понять.