PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Зачем ИИ нужны функции и графики

Содержание

- Признак и результат
- Таблица значений
- График зависимости
- Положительная зависимость
- Отрицательная зависимость
- Нелинейная зависимость
- Данные без явной зависимости
- Выбросы в данных
- Почему один признак редко даёт точный прогноз
- Как ИИ использует зависимости
- Как формулировать вывод по графику
- Итоги

Искусственный интеллект работает с данными. Но данные сами по себе не всегда дают готовый ответ. Чаще всего ИИ должен найти закономерность: как одно значение связано с другим и можно ли по этой связи сделать прогноз.

Отдельные числа трудно сравнивать, особенно если наблюдений много. Функция позволяет записать зависимость в общем виде, а график — быстро увидеть её направление, форму и необычные значения. Поэтому функции и графики служат инструментами не только вычисления, но и анализа данных.

Например, образовательная платформа может анализировать, как количество решённых заданий связано с итоговым баллом. Видеосервис может смотреть, как время просмотра роликов влияет на вероятность рекомендации похожего видео. Интернет-магазин может изучать, как цена товара связана с количеством покупок.

Во всех этих ситуациях есть два важных элемента:

признак — то, что известно системе заранее;
результат — то, что система хочет объяснить или предсказать.
Если ИИ прогнозирует итоговый балл ученика, признаком может быть количество решённых заданий, а результатом — сам итоговый балл. Если ИИ прогнозирует спрос на товар, признаком может быть цена, а результатом — количество покупок.
Функции и графики помогают описывать такие зависимости. Функция показывает, как результат связан с входным значением. График помогает увидеть эту связь наглядно.
В простейшем случае зависимость можно записать как **y = f(x)**, где **x** — признак, **y** — результат, а **f** — правило, связывающее их. В задачах с реальными данными это правило не всегда известно заранее: модель должна приблизительно восстановить его по наблюдениям.
Важно: обнаруженная связь ещё не доказывает, что изменение признака является причиной изменения результата. Например, высокий процент правильных ответов может быть связан с итоговым баллом, но оба показателя также зависят от уровня подготовки ученика.

Признак и результат

В задачах искусственного интеллекта данные часто описывают объекты. Объектом может быть пользователь, ученик, товар, видео, заказ, поездка, изображение или текст.
У каждого объекта есть характеристики. Эти характеристики называются признаками. Один объект обычно описывается не одним, а несколькими признаками, которые вместе образуют его представление в данных.
Например, если объект — ученик, признаками могут быть:

- количество решённых заданий;
- процент правильных ответов;
- время подготовки;
- количество попыток;
- темы, в которых были ошибки;
- регулярность занятий.

Если объект — товар, признаками могут быть:

- цена;
- рейтинг;
- количество отзывов;
- наличие скидки;
- категория товара;

- количество просмотров карточки.

Если объект — пользователь приложения, признаками могут быть:

- время активности;
- количество входов;
- число просмотренных страниц;
- количество кликов;
- дата последнего визита.

Признаки могут иметь разный вид. Цена, время и количество кликов выражаются числами. Категория товара или тема ошибки задаются названиями категорий. Наличие скидки может принимать два значения: скидка есть или её нет. Перед обучением модели такие характеристики представляют в форме, с которой может работать выбранный алгоритм.
Результат — это значение, которое мы хотим получить или предсказать. Например:

- итоговый балл;
- вероятность покупки;
- количество продаж;
- вероятность ухода пользователя из сервиса;
- вероятность того, что видео понравится;
- уровень сложности задания, который стоит предложить.

Результат тоже может быть разного типа. Иногда требуется предсказать число, например итоговый балл или количество продаж. В других задачах модель выбирает категорию, например определяет, понравится ли видео пользователю.
ИИ-модель анализирует признаки и пытается связать их с результатом. При этом один и тот же показатель в разных задачах может играть разную роль. Например, итоговый балл будет результатом при прогнозе успеваемости, но может стать признаком при подборе следующего задания.
Мини-проверка: если система по рейтингу, цене и наличию скидки прогнозирует количество покупок, то рейтинг, цена и скидка являются признаками, а количество покупок — результатом.

Таблица значений

Один из самых простых способов представить зависимость — таблица значений. Она сохраняет точные значения наблюдений и позволяет сравнивать отдельные объекты между собой.

Рассмотрим пример. Образовательная платформа собрала данные о том, сколько тренировочных заданий решали обучающиеся и какой итоговый балл они получили.

Количество решённых заданий	Итоговый балл
2	35
4	48
6	61
8	72
10	78
12	82
14	84

В этой таблице количество решённых заданий — это признак. Итоговый балл — результат. Каждая строка таблицы показывает одно наблюдение. Например, при 2 решённых заданиях итоговый балл составил 35, а при 8 решённых заданиях — 72. Такое наблюдение можно представить парой значений: (2; 35) или (8; 72).
По таблице уже можно заметить закономерность: чем больше заданий решено, тем выше итоговый балл. Но таблица не всегда позволяет быстро увидеть форму зависимости. Для этого удобнее построить график.
При чтении таблицы важно проверять подписи столбцов и единицы измерения. Число 8 может обозначать 8 заданий, 8 часов или 8 процентов, поэтому без названия признака его нельзя правильно интерпретировать.
Кроме того, строки таблицы показывают наблюдавшиеся случаи, а не универсальное правило для каждого ученика. Если в таблице нет строки для 9 заданий, точный балл при таком значении признака пока неизвестен.

График зависимости

График показывает, как изменяется результат при изменении признака. Он особенно полезен, когда строк в таблице много и общую закономерность трудно заметить среди отдельных чисел. Обычно по горизонтальной оси откладывают признак, а по вертикальной — результат.
В нашем примере:

- по горизонтальной оси будет количество решённых заданий;
- по вертикальной оси будет итоговый балл.

Каждая строка таблицы превращается в точку на графике. Координата точки по горизонтали берётся из столбца с признаком, а координата по вертикали — из столбца с результатом. Например, строке с 6 заданиями и баллом 61 соответствует точка (6; 61).

Если соединить точки или просто посмотреть на их расположение, можно увидеть общую картину. Однако соединение точек линией не означает, что известны все промежуточные значения: линия лишь помогает проследить направление изменения.

В примере с заданиями график будет идти вверх. Это значит, что при увеличении количества решённых заданий итоговый балл обычно растёт.

Но важно заметить не только направление графика, но и характер роста. В начале балл увеличивается заметно: с 35 до 48, потом до 61, потом до 72. Позже рост становится медленнее: с 78 до 82, затем до 84.

Это означает, что зависимость не совсем линейная. При увеличении количества заданий на 2 балл меняется неодинаково: сначала на 13, затем ещё на 13, потом на 11, 6, 4 и 2. У линейной зависимости при одинаковом изменении признака результат изменялся бы на одну и ту же величину.

Сначала дополнительные задания сильно помогают увеличить результат, а затем эффект становится слабее.

Такое часто встречается в реальной жизни. Когда человек только начинает тренироваться, прогресс может быть быстрым. Но потом для дальнейшего улучшения результата уже недостаточно просто решать больше заданий. Нужно разбирать ошибки, выбирать задания подходящей сложности и работать над слабыми темами.

Обрати внимание: при анализе графика необходимо смотреть на масштаб осей. Один и тот же набор точек может визуально казаться более крутым или более пологим в зависимости от выбранного масштаба, хотя сами данные при этом не меняются.

Положительная зависимость

Если при увеличении признака результат тоже увеличивается, говорят о положительной зависимости. На графике точки такой зависимости в целом располагаются от нижней левой части к верхней правой.

Пример положительной зависимости:

Время подготовки, часов	Итоговый балл
1	40
2	52
3	61

Время подготовки, часов	Итоговый балл
4	69
5	75

Здесь чем больше времени обучающийся готовился, тем выше итоговый балл. График такой зависимости будет идти вверх.
Рост результата не обязан быть одинаковым на каждом шаге. В таблице прибавление одного часа связано сначала с ростом балла на 12, затем на 9, 8 и 6. Зависимость остаётся положительной, хотя скорость роста меняется.
В задачах ИИ положительная зависимость может встречаться часто:

- чем больше пользователь смотрит видео на тему, тем выше вероятность рекомендации похожих видео;
- чем больше правильных ответов в тренировке, тем выше прогнозируемый результат;
- чем больше положительных отзывов у товара, тем выше вероятность покупки;
- чем больше активность пользователя в приложении, тем выше вероятность его вовлечённости.

Но положительная зависимость не означает, что один признак полностью объясняет результат. Например, время подготовки может быть связано с баллом, но на итог также влияют качество подготовки, сложность заданий и начальный уровень знаний.
Не следует путать положительную зависимость с утверждением «чем больше, тем всегда лучше». Она описывает общее направление в рассмотренных данных. У отдельных объектов результат может отличаться от общей закономерности.

Отрицательная зависимость

Если при увеличении признака результат уменьшается, говорят об отрицательной зависимости. На графике такая зависимость в целом направлена от верхней левой части к нижней правой.
Рассмотрим пример интернет-магазина. Система анализирует, как цена товара связана с количеством покупок.

Цена товара, рублей	Количество покупок
500	120
700	105
900	87

Цена товара, рублей	Количество покупок
1100	70
1300	55
1500	42
1700	34

Здесь цена — признак, а количество покупок — результат.
По таблице видно: чем выше цена, тем меньше покупок. График такой зависимости будет идти вниз. Например, при увеличении цены с 500 до 900 рублей число покупок уменьшается со 120 до 87.
Отрицательная зависимость также не обязана быть строго линейной. При каждом увеличении цены на 200 рублей число покупок уменьшается на разную величину, но общее направление сохраняется.
ИИ-система может использовать такую зависимость для прогноза спроса или анализа цен. Например, если цена слишком высокая, количество покупок может снизиться. Но и здесь нельзя делать вывод только по одному признаку.
На продажи влияют и другие факторы:

- качество товара;
- бренд;
- отзывы;
- скидки;
- сезон;
- наличие рекламы;
- доставка;
- действия конкурентов;
- срочность потребности покупателя.

Поэтому цена — важный признак, но не единственный. Кроме того, по одной таблице нельзя уверенно утверждать, что именно цена вызвала снижение покупок: одновременно могли измениться сезон, реклама или состав покупателей.
Мини-проверка: если с увеличением времени ожидания доставки вероятность покупки уменьшается, то между этими величинами наблюдается отрицательная зависимость.

Нелинейная зависимость

Не все зависимости похожи на прямую линию. Иногда результат сначала быстро растёт, а затем рост замедляется. Иногда наоборот: долго почти ничего не меняется, а потом происходит резкий рост.

Такие зависимости называют нелинейными. Для них одинаковое изменение признака может приводить к разному изменению результата на разных участках графика.

Рассмотрим пример с рекомендациями видео.

Время просмотра видео по теме, минут	Вероятность рекомендации похожего видео, %
1	15
3	28
5	45
8	63
12	76
16	84
20	88

Сначала вероятность рекомендации растёт быстро. Если пользователь посмотрел видео на тему 1 минуту, система ещё не очень уверена в его интересе. Если он смотрит 5–8 минут, уверенность заметно увеличивается. Но после 16–20 минут рост становится слабее: система уже почти уверена, что тема пользователю интересна.

Такую зависимость можно назвать зависимостью с насыщением. После определённого уровня дополнительные значения признака уже не так сильно меняют результат. В таблице увеличение времени просмотра с 16 до 20 минут связано с ростом вероятности только с 84 до 88 процентов.

Для ИИ это важно. Если модель считает, что результат всегда будет расти одинаково быстро, она может ошибиться. В реальных данных часто есть участки быстрого роста, замедления, насыщения или резкого изменения.

Например, если продолжить прямую линию без учёта насыщения, прогнозируемая вероятность может оказаться больше 100 процентов, что невозможно. Модель должна учитывать допустимые границы результата и форму зависимости.

Прогноз внутри диапазона уже наблюдавшихся значений называют прогнозом по известному участку зависимости. Прогноз далеко за пределами этого диапазона обычно менее надёжен, потому что неизвестно, сохранится ли прежняя закономерность.

Данные без явной зависимости

Иногда график показывает, что явной зависимости между признаком и результатом нет. В таком случае точки не образуют заметного направления вверх или вниз и располагаются разрозненно.
Например, образовательное приложение анализирует, связано ли количество открытий приложения в день с итоговым баллом за тест.

Количество открытий приложения в день	Итоговый балл
1	74
2	61
3	82
4	67
5	79
6	65
7	77

На первый взгляд может показаться, что чем чаще пользователь открывает приложение, тем лучше он должен учиться. Но таблица показывает, что это не обязательно так.
При 1 открытии результат 74, при 2 — 61, при 3 — 82, при 4 — 67. Значения не выстраиваются в понятный рост или спад.
Это означает, что количество открытий приложения само по себе плохо объясняет итоговый балл. По такому признаку будет трудно сделать устойчивый прогноз: одинаковое направление изменения результата не прослеживается.
Возможно, важнее не сколько раз ученик открыл приложение, а что именно он делал внутри:

- решал ли задания;
- разбирал ли ошибки;
- смотрел ли объяснения;
- возвращался ли к сложным темам;
- сколько времени реально работал;
- улучшился ли его результат со временем.

Такой пример показывает, что не каждый признак полезен для модели. Иногда признак кажется важным, но на практике плохо связан с результатом.

Отсутствие явной зависимости в небольшой таблице не всегда означает, что связи нет вообще. Возможно, данных недостаточно, измерения содержат шум или зависимость проявляется только вместе с другими признаками. Поэтому вывод нужно формулировать осторожно: в рассмотренных данных явная зависимость не обнаружена.
Частая ошибка: пытаться обязательно найти рост или спад в любом наборе чисел. Если точки расположены беспорядочно, это тоже содержательный результат анализа: выбранный признак может быть малоинформативным.

Выбросы в данных

В данных могут встречаться необычные значения, которые сильно отличаются от остальных. Такие значения называют выбросами. На графике выброс часто выглядит как точка, расположенная далеко от основной группы или общей линии зависимости.
Рассмотрим пример:

Количество решённых заданий	Итоговый балл
2	35
4	48
6	61
8	72
10	30
12	82
14	84

Почти во всех строках итоговый балл растёт вместе с количеством решённых заданий. Но при 10 решённых заданиях балл равен 30. Это значение сильно выбивается из общей картины: оно ниже не только соседних результатов, но и балла при 2 решённых заданиях.
Такую точку нельзя автоматически считать ошибкой. Возможны разные причины:

- данные внесли неправильно;
- ученик решал задания невнимательно;
- задания были слишком простыми и не помогли подготовиться;
- итоговый тест был по другой теме;
- ученик плохо себя чувствовал;
- произошёл технический сбой;

- результат относится к другому периоду.

Сначала необходимо проверить источник наблюдения: правильно ли записаны значения, относятся ли они к одному объекту и периоду, совпадают ли условия измерения. Только после такой проверки можно решать, исправлять запись, исключать её или оставлять в данных.
Для ИИ выбросы важны, потому что они могут повлиять на обучение модели. Если не проверять данные, модель может сделать неверные выводы. Например, необычная точка может изменить направление или форму найденной зависимости, особенно если наблюдений мало.
Но удалять все выбросы тоже неправильно. Если необычное значение отражает реальный случай, оно содержит полезную информацию и может показать ситуацию, которую модель должна учитывать.
Поэтому перед построением ИИ-модели данные нужно анализировать: смотреть на таблицы, строить графики, искать странные значения и понимать, что они означают.

Почему один признак редко даёт точный прогноз

В учебных примерах часто рассматривают зависимость между одним признаком и одним результатом. Это удобно для понимания функций и графиков. Но реальные ИИ-системы обычно работают с большим количеством признаков.
Например, два ученика могут решить одинаковое количество заданий, но получить разные баллы.
Почему так происходит?
Один ученик мог решать сложные задания и разбирать ошибки. Другой мог решать простые задания и не возвращаться к неправильным ответам. Один готовился регулярно, другой — в последний день. У одного был высокий начальный уровень, у другого — пробелы в базовых темах.
Количество решённых заданий важно, но оно не описывает всю ситуацию. Если использовать только этот признак, модель будет считать двух учеников с одинаковым количеством заданий похожими, хотя качество их подготовки может заметно различаться.
Поэтому для более точного прогноза ИИ может использовать несколько признаков одновременно:

- количество решённых заданий;
- процент правильных ответов;
- сложность заданий;
- время решения;
- темы ошибок;

- регулярность занятий;
- динамику прогресса;
- результаты прошлых тестов.

В этом случае результат можно представить как зависимость от нескольких входных значений. График с двумя осями уже не сможет полностью показать такую модель, но анализ отдельных признаков всё равно помогает понять данные.
Чем лучше подобраны признаки, тем больше шансов, что модель найдёт полезные закономерности. Однако большое количество признаков само по себе не гарантирует точность: признаки должны быть связаны с задачей, корректно измерены и доступны в момент прогноза. Например, нельзя использовать итоговый балл как признак для прогноза этого же итогового балла: в момент составления прогноза результат ещё неизвестен. Признаки должны содержать только ту информацию, которой система действительно располагает заранее.

Как ИИ использует зависимости

ИИ-модель обучается на данных. Она получает примеры, в которых уже известны признаки и результаты, и пытается найти закономерность. Такие примеры образуют обучающие данные. Например, модель видит данные о прошлых учениках:

- сколько заданий они решали;
- сколько времени готовились;
- какой процент ответов был правильным;
- какие темы вызывали ошибки;
- какой итоговый балл они получили.

Во время обучения модель подбирает правило, которое связывает признаки с известными результатами. Это правило не обязано точно проходить через каждое наблюдение: реальные данные могут содержать шум, выбросы и влияние неучтённых факторов. Важно, чтобы модель передавала общую устойчивую закономерность.
После обучения модель может получить данные нового ученика и предположить его возможный результат. Например, на вход поступают количество заданий, время подготовки и процент правильных ответов, а на выходе получается прогноз итогового балла.
Это не означает, что ИИ знает будущее. Он делает прогноз на основе похожих закономерностей из прошлых данных. Поэтому прогноз является оценкой, а не гарантированным результатом.
Чтобы проверить, действительно ли найденная зависимость работает, модель оценивают на примерах, которые не использовались при подборе правила. Если модель хорошо описывает

только обучающие примеры, но ошибается на новых, её прогнозы нельзя считать надёжными. Если данные качественные, признаков достаточно и зависимость устойчивая, прогноз может быть полезным. Если данных мало, они шумные или признак плохо связан с результатом, прогноз может быть слабым.
Качество данных включает не только их количество. Важно, чтобы значения были корректными, единицы измерения совпадали, пропуски были замечены, а обучающие примеры соответствовали тем объектам, для которых модель будет делать прогноз.
Именно поэтому специалисту важно уметь анализировать данные до обучения модели.

Как формулировать вывод по графику

После построения графика важно не просто сказать: «график растёт» или «график падает». Нужно связать график с задачей и указать, что именно означает направление точек.
Хороший вывод обычно отвечает на несколько вопросов:

1. Что является признаком?
2. Что является результатом?
3. Как меняется результат при изменении признака?
4. Можно ли использовать эту зависимость для прогноза?
5. Какие есть ограничения?
6. Какие дополнительные признаки могут понадобиться?

Также полезно уточнить форму зависимости: линейная она или нелинейная, есть ли насыщение, разброс точек и выбросы. Если данных недостаточно для уверенного заключения, это ограничение следует прямо указать.
Пример вывода:

> Мы анализировали зависимость между количеством решённых заданий и итоговым баллом. Количество решённых заданий является признаком, а итоговый балл — результатом. По графику видно, что при увеличении количества заданий балл обычно растёт, но рост постепенно замедляется. Эту зависимость можно использовать для примерного прогноза результата, но одного признака недостаточно. Для более точной модели нужно учитывать процент правильных ответов, сложность заданий, регулярность подготовки и работу с ошибками.

В этом выводе используется слово «обычно», а не «всегда». Такая формулировка учитывает, что реальные наблюдения могут отклоняться от общей закономерности.

Такой вывод показывает не только математическое понимание графика, но и понимание прикладной задачи ИИ.
Мини-проверка: для графика зависимости цены от количества покупок недостаточно написать «график падает». Полный вывод должен назвать цену признаком, количество покупок результатом, описать отрицательную зависимость и указать, что на спрос могут влиять другие факторы.

Итоги

Функции и графики помогают описывать связи между признаками и результатами. В задачах искусственного интеллекта это один из первых шагов к пониманию данных.
Таблица значений показывает отдельные наблюдения. График помогает увидеть общую закономерность, оценить направление и форму связи, а также заметить выбросы. Функция описывает, как результат зависит от входного значения.
Зависимость может быть положительной, отрицательной, нелинейной или слабой. В данных могут встречаться выбросы и шум. Один признак редко объясняет результат полностью, поэтому реальные ИИ-системы обычно используют много признаков.
При интерпретации важно отличать связь от причины, учитывать масштаб осей и не переносить найденную закономерность без проверки далеко за пределы наблюдавшихся данных. Любой прогноз следует рассматривать вместе с его ограничениями.
Умение читать графики помогает не доверять ИИ слепо. Оно позволяет понять, на каких данных может быть основан прогноз, где модель может ошибиться и какие дополнительные данные нужны для более точного результата.

Материалы к занятию

- presentation_Функции и графики в задачах ИИ.pptx (1.3 МБ)