CODE FUTURE ACADEMY / M02-L08

PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Параметр	Значение
Формат	Практическое занятие
Объём	2 академических часа
Аудитория	СПО
Практический результат	Заполненный ноутбук: исходы, события, частоты, вероятности, выбор класса модели и вывод.

Идея урока

Содержание

- Ключевые понятия
- Вероятность как число, дробь и процент
- Формула для простых таблиц частот
- Практические задания
- Памятка команд
- Частые ошибки
- Итоговый вывод

Во многих задачах невозможно заранее указать единственный точный результат. Данных может быть недостаточно, условия могут меняться, а один и тот же набор признаков иногда соответствует разным ответам. В таких ситуациях важно не угадывать, а оценивать степень неопределённости.

Вероятность помогает описывать неопределённость. Когда точный ответ заранее неизвестен, можно оценить, какой исход выглядит более ожидаемым: дождь или ясная погода, спам или обычное сообщение, фильм A или фильм C.

Вероятность выражается числом от 0 до 1. Это число позволяет не только выбрать наиболее ожидаемый вариант, но и сравнить варианты между собой. Например, значения 0,7 и 0,2 показывают более заметное различие, чем значения 0,51 и 0,49.

В задачах ИИ модель часто не говорит: «я абсолютно уверена». Она сравнивает вероятности нескольких классов или вариантов и выбирает тот, у которого вероятность выше. Но высокая вероятность не делает ответ гарантированно правильным: результат модели всё равно нужно проверять.

Важно: вероятность, рассчитанная моделью, отражает её оценку на основе данных и настроек. Это не доказательство правильности ответа и не характеристика того, насколько хорошо модель работает на всех примерах.

Ключевые понятия

Чтобы правильно читать таблицы частот и результаты модели, необходимо различать результат отдельного наблюдения, интересующее событие и числовую оценку этого события.

Понятие	Простое объяснение	Пример
Исход	Один возможный результат.	сообщение — спам; выпало число 4
Событие	То, что нас интересует и что мы проверяем.	сообщение оказалось спамом; выпало чётное число
Частота	Сколько раз исход или событие встретились в данных.	12 спам-сообщений из 50
Вероятность	Доля подходящих исходов среди всех исходов.	12 / 50 = 0,24 = 24%
Класс модели	Один из вариантов ответа модели.	spam, normal, promo
Уверенность модели	Насколько сильно максимальная вероятность отличается от остальных.	0,82 против 0,12 — уверенно; 0,51 против 0,49 — слабо

Одно событие может включать несколько исходов. Например, при броске игрального кубика исходами являются отдельные числа, а событие «выпало чётное число» объединяет исходы 2, 4 и 6.

Частота — это количество наблюдений, поэтому она записывается целым числом: 12 сообщений. Вероятность или относительная частота — это доля, поэтому её можно записать дробью, десятичным числом или процентом: 12/50, 0,24 или 24%.

Если классы не пересекаются и перечисляют все возможные ответы модели, вероятности этих классов в одной строке обычно дают сумму 1, или 100%. Из-за округления отображаемых значений сумма иногда может немного отличаться от 1.

Мини-проверка: в наборе из 20 сообщений 5 отмечены как promo. Число 5 является частотой, а 5/20 = 0,25 = 25% — долей таких сообщений.

Вероятность как число, дробь и процент

Один и тот же результат можно представить в нескольких формах. Дробь показывает отношение подходящих случаев ко всем случаям, десятичная запись удобна для вычислений, а проценты часто удобнее для чтения и сравнения.
Вероятность можно записывать по-разному. Запись 0,5 означает 50%, а 0,8 — 80%. Чем ближе число к 1, тем более ожидаемым выглядит событие. Чем ближе к 0, тем менее ожидаемым оно выглядит.

Запись	Как понимать
0	событие не произойдёт
0,25 / 25%	скорее редко
0,5 / 50%	примерно поровну
0,8 / 80%	скорее произойдёт
1 / 100%	точно произойдёт

Для перевода десятичной дроби в проценты число умножают на 100. Например, 0,36 × 100 = 36%. Для обратного перевода процент делят на 100: 36% = 36/100 = 0,36.
Значение 0,5 не означает, что событие обязательно произойдёт ровно в половине каждого небольшого набора наблюдений. Оно показывает равную оценку события и его противоположного варианта в рассматриваемой модели или условии. В конкретной небольшой выборке фактическая доля может отличаться.
Обрати внимание: значения 0 и 1 обозначают невозможное и достоверное события в рамках заданных условий. Если такие значения выдала модель ИИ, их всё равно нельзя автоматически считать гарантией правильного ответа: модель может быть ошибочной или работать с неполными данными.

Формула для простых таблиц частот

Таблица частот позволяет перейти от количества наблюдений к их долям. Это удобно, когда требуется сравнить категории, встречающиеся разное число раз.
Для простых учебных задач используем правило:

вероятность = подходящие исходы / все исходы

Например, если в таблице 50 сообщений и 12 из них являются спамом, вероятность случайно выбрать спам-сообщение равна 12 / 50 = 0,24 = 24%.

Здесь числитель 12 — количество подходящих записей, а знаменатель 50 — общее количество записей. При случайном выборе одной записи каждая строка должна иметь одинаковую возможность попасть в выборку.

По таблице наблюдений такое вычисление даёт относительную частоту события. Она используется как оценка вероятности: чем больше и разнообразнее данные, тем надёжнее обычно такая оценка описывает рассматриваемый набор случаев.

Если категории не пересекаются и охватывают всю таблицу, сумма их частот должна быть равна общему числу записей, а сумма вероятностей — 1. Такая проверка помогает заметить пропущенную категорию, неверный знаменатель или ошибку вычисления.

Пример проверки: если из 50 сообщений 12 относятся к spam, 30 — к normal и 8 — к promo, то 12 + 30 + 8 = 50. Соответствующие доли равны 0,24, 0,60 и 0,16, а их сумма составляет 1.

Делить на ноль нельзя. Если таблица не содержит ни одной записи и общее количество равно 0, вероятность по этой формуле рассчитать невозможно: сначала необходимо проверить данные.

Практические задания

В этом практикуме задания оформлены отдельно, чтобы результат можно было проверить в ноутбуке или на платформе. У каждого задания есть уровень, проверяемая тема и ожидаемый результат.

Работу с каждым набором данных удобно выполнять последовательно: открыть файл, проверить названия и содержимое столбцов, найти общее число наблюдений, вычислить доли, перевести их в проценты и сформулировать вывод.

В задачах классификации необходимо отдельно определить список столбцов с вероятностями классов. Затем для каждой строки находится максимальная вероятность и соответствующий ей класс. Максимальное число показывает оценку выбранного варианта, а название столбца указывает на сам вариант ответа.

Если в данных есть столбец **true_class**, предсказанный класс следует сравнить с правильной меткой. Совпадение означает правильный ответ на конкретном примере, несовпадение — ошибку. По одному примеру нельзя судить о качестве модели в целом, поэтому проверку проводят по всему доступному набору размеченных данных.

В заполненном ноутбуке должны быть видны не только итоговые числа, но и шаги вычисления: исходные данные, найденная сумма частот, новые столбцы с вероятностями или процентами, выбранный класс и краткий вывод. Это позволяет проверить ход решения, а не только последний ответ.

Мини-проверка: если модель указала вероятности 0,51 для класса spam и 0,49 для класса normal, выбран будет spam, поскольку 0,51 больше. Однако разница между вариантами мала, поэтому такой ответ требует особенно внимательной проверки.

Памятка команд

Команды выполняют разные этапы обработки данных. Перед вычислением важно убедиться, что указанные столбцы действительно существуют в таблице и содержат числовые значения.

Команда	Что делает
pd.read_csv("file.csv")	открыть CSV-файл
df["count"].sum()	сложить значения в столбце
df["probability"] = df["count"] / total	посчитать вероятность
df["percent"] = df["probability"] * 100	перевести вероятность в проценты
df[["p_spam", "p_normal", "p_promo"]].max(axis=1)	найти максимальную вероятность в строке
df.sort_values("p_user_likes", ascending=False)	отсортировать варианты по вероятности

В выражении **df["count"].sum()** метод **sum()** складывает все значения выбранного столбца. Полученный результат используется как знаменатель при вычислении доли каждой категории.
Параметр **axis=1** означает, что максимум ищется по столбцам внутри каждой строки. Без указания нужного направления можно получить не тот результат: например, максимумы по каждому столбцу вместо максимума для каждого объекта.
Команда с **max(axis=1)** возвращает максимальное числовое значение, но сама по себе не называет класс. Чтобы выбрать ответ модели, необходимо связать максимум с тем столбцом вероятности, в котором он находится.
Параметр **ascending=False** задаёт сортировку по убыванию: в начале таблицы окажутся строки с наибольшими значениями **p_user_likes**. Сортировка меняет порядок просмотра строк, но не пересчитывает вероятности.
Важно: значение **total** должно быть вычислено до деления. Также необходимо проверить, что оно не равно нулю, иначе корректный столбец вероятностей получить нельзя.

Частые ошибки

Путать исход и событие: исход — возможный результат, событие — то, что проверяется.
Путать частоту и вероятность: 12 сообщений — частота, 12/50 — вероятность.

Использовать неверный знаменатель. Для доли категории требуется общее число рассматриваемых записей, а не частота другой категории.
Путать десятичную дробь и процент: 0,8 соответствует 80%, а не 0,8%. При переводе в проценты значение умножают на 100.
Считать 80% гарантией. На практике это высокая оценка, но модель всё равно может ошибиться.
Выбирать первый столбец вероятности, а не максимальное значение.
Смотреть только на максимальную вероятность и не сравнивать её с другими значениями. Максимум 0,51 при втором значении 0,49 указывает на менее уверенный выбор, чем максимум 0,82 при заметно меньших остальных значениях.
Искать максимум по всей таблице вместо отдельного максимума в каждой строке. В задачах классификации обычно требуется получить ответ для каждого объекта.
Забывать проверить ответ модели по правильной метке true_class.
Оценивать качество модели по одному удачному или неудачному примеру. Для вывода нужна проверка на наборе данных с правильными ответами.
Не проверять сумму вероятностей классов. Если классы взаимно исключают друг друга и охватывают все варианты, заметное отличие суммы от 1 может указывать на ошибку в данных или вычислениях.

Итоговый вывод

Вероятность помогает ИИ работать с неопределённостью: модель сравнивает возможные классы или варианты и выбирает тот, который выглядит наиболее вероятным. Но даже высокий показатель вероятности не доказывает, что ответ правильный. После выбора класса модель нужно проверять на данных с правильными ответами.
Для корректного анализа важно различать частоту и вероятность, использовать правильное общее число наблюдений, сравнивать все вероятности в строке и связывать максимальное значение с соответствующим классом. Дополнительное сравнение с **true_class** показывает, оказался ли выбор модели правильным на конкретном объекте.
Таким образом, практическая работа с вероятностями включает два связанных этапа: вычисление или чтение вероятностных оценок и проверку решений, принятых на их основе. Вероятность помогает выбрать вариант, а размеченные данные помогают оценить правильность этого выбора.

Материалы к занятию

- Урок_2_8_Вероятность_события_презентация_v2.pptx (269.3 КБ)