МОДУЛЬ 2

Условная вероятность и принятие решений по признакам

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Ключевые понятия · таблица 1/3

Понятие	Определение	Обозначение
Безусловная вероятность	Вероятность события A вне зависимости от других условий	P(A)
Условная вероятность	Вероятность события A при условии, что событие B уже выполнено	P(A | B)

Ключевые понятия · таблица 2/3

Понятие	Определение	Обозначение
Совместная вероятность	Вероятность того, что одновременно выполняются оба события A и B	$P(A \cap B)$
Зависимые события	$P(A \mid B) \neq P(A)$: знание о B меняет оценку вероятности A	–

Ключевые понятия · таблица 3/3

Понятие	Определение	Обозначение
Независимые события	$P(A \mid B) = P(A)$: знание о B не меняет оценку вероятности A	–
Информативность признака	Степень изменения вероятности класса при наличии признака: $\lvert P(A\mid B) - P(A)\rvert$	$\Delta = \lvert P(A\mid B) - P(A)\rvert$

Формула условной вероятности

01 $P(A \mid B) = n(A \cap B) / n(B)$

02 где $n(A \cap B)$ – количество объектов с признаками и A, и B

03 $n(B)$ – количество объектов, у которых выполняется B

04 $P(A \mid B) = P(A \cap B) / P(B)$

Развернутый пример: кредитный скоринг (1/2) · таблица 1/2

Переменная	Описание	Значения
Доход	Ежемесячный доход заявителя	высокий (> 80 000 руб.) / низкий
Кредитная история	Наличие просрочек в прошлом	хорошая / плохая

Развернутый пример: кредитный скоринг (1/2) · таблица 2/2

Переменная	Описание	Значения
Возраст	Возрастная группа	молодой (18–30) / зрелый (30+)

Развернутый пример: кредитный скоринг (2/2)

01 Примеры: «Возраст» – нерелевантный признак в данной таблице ($\Delta = 0$): не изменяет вероятность одобрения. При таком распределении модель не получает от него дополнительной информации о целевом классе.

02 Вывод: признак «возраст» в данном датасете независим от целевой переменной.

03 В рамках этой выборки включать его в модель только ради предсказания одобрения нецелесообразно – он не меняет оценку вероятности класса.

04 Однако вывод относится именно к представленным данным: в другой выборке распределение может оказаться иным.

Условная вероятность и классификация · таблица 1/2

Класс	P(одобрен)	P(отклонен)
Только по базовой статистике	0,60	0,40
При хорошей истории	0,82	0,18

Условная вероятность и классификация · таблица 2/2

Класс	P(одобрен)	P(отклонен)
При высоком доходе	0,80	0,20

Теорема Байеса: связь P(A|B) и P(B|A) (1/2)

01 Условную вероятность можно «развернуть» в обратную сторону.

02 $P(A \mid B) = P(B \mid A) \times P(A) / P(B)$

03 P(A) – априорная вероятность (наше знание ДО наблюдения признака)

04 $P(A \mid B)$ – апостериорная вероятность (наше знание ПОСЛЕ наблюдения)

Теорема Байеса: связь P(A|B) и P(B|A) (2/2)

01 Здесь особенно важно не путать две вероятности: P(тест+|болен) = 0,95, но P(болен|тест+) ≈ 0,16.

Наивный байесовский классификатор: принцип работы · таблица 1/2

Шаг	Действие	Что вычисляется
1	Оценить априорные вероятности классов по обучающим данным	P(спам) = 20/100 = 0,20; P(не спам) = 0,80
2	Для каждого признака объекта вычислить правдоподобие в каждом классе	P(«выиграли»|спам) = 14/20 = 0,70; P(«выиграли»|не спам) = 6/80 = 0,075

Наивный байесовский классификатор: принцип работы · таблица 2/2

Шаг	Действие	Что вычисляется
3	Перемножить априорную вероятность на правдоподобия всех признаков	Счет(спам) = 0,20 × 0,70 = 0,14; Счет(не спам) = 0,80 × 0,075 = 0,060
4	Нормировать и выбрать класс с максимальной апостериорной вероятностью	P(спам|признаки) ≈ 0,14/(0,14+0,060) = 0,70

Информативность признаков и отбор признаков · таблица 1/3

Признак B	P(A)	P(A|B)	Δ	Полезность для модели
Слово «выиграли» в теме письма	0,20	0,70	0,50	Очень высокая
Незнакомый отправитель	0,20	0,62	0,42	Высокая

Информативность признаков и отбор признаков · таблица 2/3

Признак B	P(A)	P(A|B)	Δ	Полезность для модели
Более 3 ссылок в письме	0,20	0,45	0,25	Средняя
Письмо длиной > 500 символов	0,20	0,22	0,02	Незначительная

Информативность признаков и отбор признаков · таблица 3/3

Признак B	P(A)	P(A|B)	Δ	Полезность для модели
Письмо отправлено в понедельник	0,20	0,20	0,00	Нулевая по данной оценке

Памятка · таблица 1/4

Что вычислить	Формула	На что обратить внимание
Безусловная вероятность	P(A) = n(A) / n(всего)	Делим на ВСЕ объекты
Условная вероятность	P(A|B) = n(A ∩ B) / n(B)	Делим только на объекты с признаком B; требуется n(B) > 0

Памятка · таблица 2/4

Что вычислить	Формула	На что обратить внимание
Направление изменения	$P(A\|B) - P(A)$	Знак показывает рост или снижение вероятности
Информативность признака	$\Delta = \|P(A\|B) - P(A)\|$	Δ не бывает отрицательной; чем больше – тем сильнее отклонение

Памятка · таблица 3/4

Что вычислить	Формула	На что обратить внимание
Теорема Байеса	$P(A\|B) = P(B\|A)\times P(A) / P(B)$	$P(B) = P(B\|A)\times P(A) + P(B\|\neg A)\times P(\neg A)$
Счет наивного байесовского	$P(\text{класс}) \times \prod P(\text{признак_i} \mid \text{класс})$	Условная независимость признаков – допущение

Памятка · таблица 4/4

Что вычислить	Формула	На что обратить внимание
Правило классификации	Выбрать класс с максимальным счетом	Нормировать счета, чтобы получить вероятности классов

Частые ошибки

01 Неверный знаменатель: при P(A|B) делить на n(всего), а не n(B). Мнемоника: условие – это «новый мир», и знаменатель – это размер этого нового мира.

02 Делать вывод о сочетании признаков только по отдельным условным вероятностям. Из P(A|B) и P(A|C) нельзя без дополнительных данных сразу получить P(A|B ∩ C).

03 Считать максимальную вероятность гарантией правильного ответа. Классификатор выбирает наиболее вероятный класс среди доступных, но его предсказание все равно может быть ошибочным.

Мини-рефлексия

01 Мини-рефлексия

Практическая работа

01 Задание 1. Отзывы покупателей

02 Задание 2. Медицинская диагностика

03 Задание 3. Спам-фильтр

04 Задание 4. Сегментация пользователей

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами