PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Блок 1. Вступление

Содержание

- Блок 2. Главная идея урока
- Блок 3. Ключевые понятия
- Блок 4. Среднее и медиана: в чём разница?
- Блок 5. Дисперсия и разброс данных
- Блок 6. Корреляция: есть ли связь?
- Блок 7. Доверительный интервал: насколько мы уверены?
- Блок 8. Как статистика работает в задачах ИИ
- Блок 9. Частые ошибки
- Блок 10. Памятка

👋 **Привет, будущий аналитик данных!**

Ты уже умеешь работать с вероятностями и понимаешь, как ИИ выбирает наиболее вероятный ответ.

Сегодня мы сделаем следующий шаг: познакомимся с математической статистикой — инструментом, который помогает понять данные до того, как модель начнёт на них учиться. Без такого анализа легко не заметить выбросы, сильный разброс или случайные связи. Тогда модель может показать хорошую метрику на одной выборке, но работать заметно хуже на новых данных.

Что ты узнаешь на этом уроке:

• Что такое среднее, медиана и дисперсия – и чем они отличаются друг от друга.

• Что такое корреляция и почему она не равна причинно-следственной связи.

• Что такое доверительный интервал – и почему одного значения точности недостаточно.

• Как всё это используется при оценке качества ИИ-моделей.

Формул будет минимум. Примеров – много. Поехали!

Блок 2. Главная идея урока

Прежде чем обучать модель, нужно понять данные. Математическая статистика – это набор инструментов, которые позволяют ответить на вопросы: «Что типично для этих данных? Насколько они разбросаны? Есть ли между переменными связь? Насколько мы уверены в нашем выводе?»

Статистики можно представить как краткое описание большого датасета. Вместо просмотра тысяч строк аналитик получает несколько показателей, которые помогают увидеть центр данных, разброс и возможные зависимости.

Представьте, что вы обучаете модель предсказывать цены на квартиры. Прежде чем запускать алгоритм, хочется знать: какова типичная цена? Сильно ли цены различаются? Зависит ли цена от площади? Насколько точен прогноз? На все эти вопросы отвечает статистика.

При этом одного показателя обычно недостаточно. Например, средняя цена без информации о разбросе не показывает, насколько сильно отличаются дешёвые и дорогие квартиры. Поэтому статистические характеристики рассматривают вместе.

Блок 3. Ключевые понятия

Понятие	Простое объяснение	Пример из ИИ
Среднее	Сумма всех значений, делённая на их количество	Средняя абсолютная ошибка модели по тестовой выборке
Медиана	Значение, которое делит упорядоченный набор данных на две равные по количеству части	Медианная зарплата в датасете резюме
Дисперсия	Средний квадрат отклонения значений от среднего	Разброс предсказаний модели для похожих объектов
Корреляция	Степень линейной связи между двумя переменными (от −1 до +1)	Связь площади квартиры и её цены
Доверительный интервал	Диапазон значений, рассчитанный по выборке для оценки неизвестного параметра	«Точность модели 87% ± 3%» при 95%-м уровне доверия

Эти понятия отвечают на разные вопросы. Среднее и медиана описывают центр данных, дисперсия – разброс, корреляция – совместное изменение признаков, а доверительный интервал – неопределённость оценки.

Блок 4. Среднее и медиана: в чём разница?

4.1. Среднее значение

Среднее – это самый привычный способ описать «типичное» значение. Сложите все числа и поделите на их количество.

Пример. Пять студентов сдали тест, их баллы: 60, 65, 70, 75, 80. Среднее = (60+65+70+75+80) / 5 = 70.

Среднее учитывает каждое наблюдение. Если изменить хотя бы одно значение, среднее тоже изменится. Это полезно, когда важен вклад всех объектов, но делает показатель чувствительным к необычно большим или маленьким значениям.

Звучит просто. Но у среднего есть слабое место – оно очень чувствительно к выбросам.

Проблема среднего: выбросы

Выброс – это значение, которое сильно отличается от большинства наблюдений. Он может быть реальным редким случаем или следствием ошибки при сборе данных.

Представьте, что к пяти студентам добавился шестой, который не пришёл на тест и получил 0 баллов.

Среднее стало: (0+60+65+70+75+80) / 6 = 58,3.

Теперь среднее ниже, чем баллы пяти из шести студентов!

Один выброс «утянул» всю статистику вниз.

При анализе данных выброс не следует удалять автоматически. Сначала нужно выяснить, является ли он ошибкой или важным редким наблюдением.

4.2. Медиана

Медиана – это значение посередине, если расставить все данные по порядку. Она значительно устойчивее к выбросам, чем среднее.

Если количество значений нечётное, медианой будет одно центральное значение. Например, для набора 3, 5, 8 медиана равна 5.

Если количество значений чётное, берут среднее арифметическое двух центральных значений. Те же шесть студентов имеют баллы 0, 60, 65, 70, 75, 80. Медиана = (65+70)/2 = 67,5.

Медиана честнее показывает «типичный» балл в этом примере, потому что ноль одного студента влияет на неё намного меньше, чем на среднее.

Аналогия: средняя зарплата и медианная

Представьте офис из 9 сотрудников с зарплатой 50 000 руб. и одного директора с зарплатой 1 000 000 руб.

Средняя зарплата: (9 × 50 000 + 1 000 000) / 10 = 145 000 руб.

Медианная зарплата: 50 000 руб.

Какое число лучше описывает «типичного» сотрудника? В этом примере – медианная зарплата.
Среднее при этом тоже рассчитано правильно: оно отвечает на другой вопрос и показывает, сколько приходится на одного человека при равномерном распределении всей суммы зарплат. Именно поэтому при заметной неравномерности данных полезно указывать оба показателя и объяснять различие между ними.

4.3. Когда что использовать?

Ситуация	Лучше использовать	Почему
Данные без сильных выбросов (баллы студентов)	Среднее	Учитывает все значения
Данные с выбросами (зарплаты, цены)	Медиана	Не «утягивается» крайними значениями
Оценка средней абсолютной ошибки модели	Среднее (MAE)	Хотим учесть абсолютную ошибку на каждом объекте
Типичное время ответа сервиса	Медиана	Несколько очень медленных запросов меньше искажают картину

Выбор показателя зависит не от того, какое число выглядит лучше, а от вопроса исследования и формы распределения данных. На практике среднее и медиану часто считают одновременно: заметная разница между ними может указывать на выбросы или несимметричность данных.

> **Мини-проверка**
>
> Для набора 5, 6, 6, 7, 26 среднее равно 10, а медиана – 6. Какой показатель лучше описывает большинство значений? В этом случае медиана, потому что значение 26 заметно увеличивает среднее.

Блок 5. Дисперсия и разброс данных

Среднее говорит, где «центр» данных. Но оно не говорит, насколько данные рассеяны вокруг этого центра. Два набора могут иметь одинаковое среднее и при этом сильно различаться по стабильности. Для описания такого различия нужна дисперсия.
Аналогия: стрельба по мишени
Представьте двух стрелков. Оба попадают в среднем в центр мишени.

Стрелок А: все пули попадают близко к центру – кучно.
Стрелок Б: пули разлетаются по всей мишени – хаотично.
Среднее у обоих одинаковое. Но дисперсия у Б намного больше!
В ИИ-терминах это похоже на сравнение стабильной модели с моделью, которая иногда даёт очень точный результат, а иногда сильно ошибается.
Дисперсия показывает, насколько значения отклоняются от среднего. Для её вычисления находят отклонение каждого значения от среднего, возводят отклонения в квадрат и усредняют. Возведение в квадрат не позволяет положительным и отрицательным отклонениям взаимно уничтожить друг друга.
Чем выше дисперсия – тем больше разброс. Если все значения одинаковы, каждое из них совпадает со средним и дисперсия равна нулю.

5.1. Пример с оценками моделей

Модель	Ошибки на тесте	Среднее	Разброс
Модель А	9, 10, 10, 11, 10	10	Маленький – стабильная
Модель Б	2, 5, 10, 15, 18	10	Большой – менее стабильная

Обе модели имеют одинаковую среднюю ошибку. Но Модель А предсказуема – на приведённых объектах её ошибка остаётся около 10. Модель Б иногда ошибается мало, но иногда допускает гораздо более крупную ошибку. Для приложения, в котором важна предсказуемость результата, стабильность может стать важным критерием выбора.
Однако меньший разброс не делает модель автоматически лучшей. Нужно одновременно учитывать средний размер ошибки, разброс и требования задачи. Модель со стабильной, но очень большой ошибкой всё равно будет бесполезной.

5.2. Стандартное отклонение – «дружественный брат» дисперсии

Дисперсия измеряется в квадратных единицах, поэтому её бывает неудобно интерпретировать напрямую. Например, если ошибка выражена в баллах, единицей дисперсии будут квадратные баллы.
Поэтому часто используют стандартное отклонение – квадратный корень из дисперсии. Оно измеряется в тех же единицах, что и исходные данные.
Если средняя ошибка модели – 10 баллов, а стандартное отклонение – 2 балла, это означает, что характерный масштаб отклонения ошибок от среднего составляет около 2 баллов.

> **Обрати внимание**
>
> Нельзя без дополнительных предположений утверждать, что все или почти все ошибки находятся строго в диапазоне 8–12. Стандартное отклонение описывает масштаб разброса, а доля значений внутри конкретного диапазона зависит от распределения данных.

Блок 6. Корреляция: есть ли связь?

Корреляция показывает, насколько два числовых признака меняются вместе. Коэффициент линейной корреляции принимает значения от −1 до +1.
Знак показывает направление связи, а модуль – её силу. Чем значение ближе к +1 или −1, тем сильнее линейная связь. Чем оно ближе к нулю, тем слабее именно линейная связь.

Значение	Что означает	Пример
+1	Идеальная положительная линейная связь	Значения связаны формулой вида $y = ax + b$, где $a > 0$
0	Линейная связь не обнаружена	Один признак не показывает линейного роста или падения вместе с другим
−1	Идеальная отрицательная линейная связь	Значения связаны формулой вида $y = ax + b$, где $a < 0$
~0,8	Сильная положительная корреляция	При росте одного признака второй обычно растёт
~−0,6	Умеренная отрицательная корреляция	При росте одного признака второй обычно уменьшается

Значения +1 и −1 означают не просто общее направление изменений, а точное расположение всех наблюдений на одной прямой. В реальных данных такие крайние значения встречаются редко, потому что на результат обычно влияют сразу несколько факторов.
Корреляция около нуля не всегда означает полное отсутствие связи. Между признаками может существовать нелинейная зависимость, которую коэффициент линейной корреляции не отражает. Поэтому числовой показатель полезно дополнять графиком данных.

6.1. Корреляция ≠ причинно-следственная связь

Важнейшее правило статистики!

Если два явления коррелируют – это НЕ значит, что одно вызывает другое.
Например, продажи мороженого могут коррелировать с числом происшествий на воде. Возможная общая причина – жаркая погода: в жаркие дни люди чаще покупают мороженое и чаще купаются. Сама по себе покупка мороженого не объясняет происшествия.
Такой фактор, связанный сразу с двумя наблюдаемыми переменными, называют третьим или скрытым фактором.
В ИИ: если признак коррелирует с целевой переменной, он может быть полезен для модели. Но это не значит, что признак является причиной результата. Кроме того, обнаруженная связь может зависеть от особенностей собранной выборки.

6.2. Применение корреляции в анализе данных

Перед обучением модели аналитики могут изучить матрицу корреляций – таблицу, показывающую попарные линейные связи между числовыми признаками.

- Если признак сильно коррелирует с целевой переменной, он может быть полезен для модели.
- Если два признака сильно коррелируют между собой, они могут частично дублировать информацию. Нужно проверить, действительно ли один из них стоит убрать.
- Признаки с корреляцией, близкой к нулю по отношению к цели, могут оказаться малоинформативными для линейной модели, но сохранять нелинейную связь с целью.

Поэтому корреляция помогает сформулировать гипотезу, но не заменяет проверку качества модели. Окончательное решение о признаке принимают по результатам анализа данных и экспериментов на отложенной выборке.

6.3. Пример: признаки для предсказания цены квартиры

Рассмотрим условные результаты анализа одного датасета. Эти коэффициенты относятся только к данной выборке: в другом городе или наборе квартир значения могут отличаться.

Признак	Корреляция с ценой	Предварительный вывод
Площадь (м²)	+0,85	Сильная положительная связь – признак стоит проверить в модели
Этаж	+0,15	Слабая линейная связь – возможны другие виды зависимости
Расстояние до метро	−0,70	Сильная обратная связь – признак может быть полезен

Признак	Корреляция с ценой	Предварительный вывод
Цвет обоев	+0,02	Линейная связь почти не обнаружена

Отрицательная корреляция расстояния до метро с ценой означает, что при увеличении расстояния цена в этой выборке обычно уменьшается. Знак «минус» не делает признак плохим: для модели важно наличие устойчивой связи, а не только её направление.

Блок 7. Доверительный интервал: насколько мы уверены?

Когда мы оцениваем точность модели на тестовой выборке, мы получаем одно число: например, 87%. Но это число – оценка, а не абсолютная истина. Если бы мы взяли другую тестовую выборку из той же совокупности, точность могла бы оказаться, например, 84% или 90%.

Доверительный интервал показывает неопределённость такой оценки. Например, результат можно записать как «точность модели 87%, 95%-й доверительный интервал – от 84% до 90%».

Строгий смысл 95%-го уровня доверия связан с повторением процедуры: если много раз брать выборки одним и тем же способом и каждый раз строить интервал, примерно 95% таких интервалов накроют истинное значение параметра. Это не означает, что модель делает 95% прогнозов правильно: уровень доверия и точность модели – разные величины.

Аналогия: социологический опрос

В новостях можно увидеть сообщение: «Рейтинг кандидата – 42%, погрешность ±3 процентных пункта».

Такой результат задаёт интервал от 39% до 45% при указанном уровне доверия и выполнении условий расчёта.

Почему возникает погрешность? Опросили не всех людей, а только выборку.

Чем больше корректно собранная выборка, тем уже обычно получается интервал и тем точнее оценка.

В ИИ действует похожая логика: увеличение репрезентативной тестовой выборки обычно уменьшает неопределённость оценки качества модели.

7.1. Что влияет на ширину доверительного интервала?

Фактор	Как влияет	Пример
Размер выборки	При прочих равных больше выборка – уже интервал	Оценка по 10 000 объектам обычно точнее оценки по 100 объектам

Фактор	Как влияет	Пример
Уровень доверия	Выше уровень доверия – шире интервал	99%-й интервал обычно шире 95%-го
Разброс данных	Больше разброс – шире интервал	Сильно различающиеся результаты повышают неопределённость оценки

Большой размер выборки уменьшает случайную погрешность, но не исправляет систематические ошибки. Если тестовый набор не похож на реальные данные, даже узкий доверительный интервал может описывать качество модели в неподходящих условиях.

7.2. Почему это важно для ИИ?

- Две модели с точностью 85% могут иметь разную неопределённость оценки: например, одна – 85% ± 1 процентный пункт, другая – 85% ± 10 процентных пунктов.
- Широкий интервал может сигнализировать о малом объёме тестовой выборки или большом разбросе результатов.
- При сравнении моделей полезно учитывать не только точечные значения метрики, но и их неопределённость.
- Интервал относится к конкретной метрике и условиям тестирования. Он не гарантирует такое же качество после изменения данных.

> **Частая ошибка**
>
> Запись «87% ± 3%» неоднозначна: 3% от числа 87 и 3 процентных пункта – не одно и то же. Для диапазона от 84% до 90% корректнее говорить «±3 процентных пункта».

Блок 8. Как статистика работает в задачах ИИ

8.1. При подготовке данных

До обучения модели аналитик изучает датасет с помощью статистики. Это позволяет обнаружить проблемы до того, как они повлияют на обучение:

- Среднее и медиана – чтобы понять «типичный» объект и заметить возможную несимметричность данных.

- Дисперсия и стандартное отклонение – чтобы оценить разброс признаков и найти значения, требующие дополнительной проверки.
- Корреляция – чтобы обнаружить линейные связи между признаками и возможное дублирование информации.

Например, если средняя цена квартиры намного выше медианной, в датасете могут присутствовать несколько очень дорогих объектов. Их нужно изучить отдельно, а не автоматически считать ошибками.

8.2. При оценке качества модели

После обучения модели мы оцениваем её качество на тестовой выборке, которую модель не использовала для обучения:

- Средняя ошибка (например, MAE или RMSE) – показывает размер ошибки, сведённый к одной итоговой метрике.
- Разброс ошибок – показывает, насколько одинаково модель работает на разных объектах.
- Доверительный интервал – показывает неопределённость оценки метрики качества.

Средняя метрика может скрывать важные различия. Поэтому ошибки также полезно анализировать по отдельным группам объектов: модель может хорошо работать в среднем, но заметно хуже на определённой части данных.

8.3. При проверке выводов

Иногда нужно ответить на вопрос: «Модель A лучше модели B – это случайность или реальное улучшение?»
Статистика помогает оценить, можно ли объяснить наблюдаемую разницу случайными колебаниями выборки. Для надёжного сравнения модели должны проверяться в одинаковых условиях и на сопоставимых данных.
Перекрывающиеся доверительные интервалы сами по себе не доказывают, что различия случайны, а неперекрывающиеся не заменяют полноценную статистическую проверку. Интервалы дают полезный ориентир, но точный вывод зависит от способа их построения и метода сравнения.

Задача в ИИ	Статистический инструмент	Что показывает
Анализ признаков	Среднее, медиана, дисперсия	Типичные значения и разброс

Задача в ИИ	Статистический инструмент	Что показывает
Отбор признаков	Корреляция	Линейную связь признака с целевой переменной или другими признаками
Оценка точности	Метрика + доверительный интервал	Качество модели и неопределённость его оценки
Сравнение моделей	Доверительные интервалы и статистическая проверка	Насколько убедительна наблюдаемая разница в качестве
Поиск выбросов	Среднее, медиана, стандартное отклонение	Значения, которые требуют отдельной проверки

Блок 9. Частые ошибки

Ошибка	Как думать правильно
Считать, что среднее всегда описывает «типичное»	При наличии сильных выбросов медиана часто лучше описывает центр большинства значений
Путать корреляцию с причинно-следственной связью	Совместное изменение переменных не доказывает, что одна вызывает другую
Считать нулевую корреляцию отсутствием любой связи	Коэффициент линейной корреляции может не заметить нелинейную зависимость
Доверять точечной оценке точности без интервала	Одна и та же метрика может иметь разную неопределённость на выборках разного размера
Считать, что дисперсия – это всегда плохо	Дисперсия – характеристика, а не оценка. В некоторых задачах большой разброс естественен
Автоматически удалять все выбросы	Сначала нужно определить, является значение ошибкой или реальным редким случаем
Убирать все коррелирующие признаки	Сильная корреляция – повод проверить дублирование, а не команда автоматически удалить признак

Главная защита от этих ошибок – рассматривать показатели вместе и помнить, какой именно вопрос решает каждый из них. Ни среднее, ни корреляция, ни доверительный интервал по отдельности не дают полного описания данных.

Блок 10. Памятка

📌 **Ключевые тезисы урока**

Среднее – сумма всех значений, делённая на их количество. Оно учитывает все наблюдения и чувствительно к выбросам.

Медиана – центральное значение упорядоченного набора. Она устойчива к выбросам и часто лучше описывает типичное значение в несимметричных данных.

Дисперсия – средний квадрат отклонения значений от среднего. Она описывает разброс данных.

Стандартное отклонение – корень из дисперсии. Оно выражается в тех же единицах, что и исходные значения.

Корреляция – показатель линейной связи между переменными от −1 до +1. Корреляция не доказывает причинно-следственную связь.

Корреляция около нуля не исключает нелинейную зависимость.

Доверительный интервал – диапазон, построенный по выборке для оценки неизвестного параметра. Чем он шире, тем выше неопределённость оценки.

В ИИ статистика нужна на трёх этапах:

1. Анализ данных до обучения модели.
2. Оценка качества модели после обучения.
3. Проверка выводов при сравнении моделей и поиске закономерностей.

Перед итоговым выводом полезно задать три вопроса: что показывает выбранная статистика, какие данные могли на неё повлиять и насколько надёжна полученная оценка?

Материалы к занятию

- Statistics_for_AI.pptx (11.1 МБ)