Ismart

Математическая статистика в задачах искусственного интеллекта

Теоретическое занятие · 2 академических часа · 10–11 классы, СПО

SMART

Привет, будущий аналитик данных!

Прошлый шаг



Ты уже **понимаешь вероятности** и как ИИ выбирает наиболее вероятный ответ.

Текущий шаг



Сегодня изучаем **статистику**. Прежде чем обучать ИИ-модель, нужно **понять данные**.

Математическая статистика — инструмент, который помогает понять данные до того, как модель начнёт на них учиться. Минимум формул. Много примеров.

SMART

5 главных инструментов статистики для ИИ

Среднее

Сумма всех значений / количество.

В ИИ: Средняя ошибка модели.

Медиана

Значение ровно посередине.

В ИИ: Медианная зарплата в датасете.

Дисперсия

Насколько сильно данные «разлетаются».

В ИИ: Разброс предсказаний для похожих объектов.

Корреляция

Степень связи двух переменных (-1 до +1).

В ИИ: Связь площади квартиры и её цены.

Доверительный интервал

Диапазон истинного значения.
В ИИ: «Точность модели 87% ± 3%».

SMART

Проблема выбросов: Среднее vs. Медиана



СРЕДНЕЕ

$$\frac{(9 \times 50\text{к} + 1\text{М})}{10} = \textbf{145 000 руб.}$$

Чувствительно к выбросам. Выброс «утянул» статистику вверх. Это число не описывает «типичного» сотрудника!

Best for **Где применять:** Данные без выбросов (например, баллы тестов).

МЕДИАНА

Значение строго посередине **= 50 000 руб.**

Устойчива к выбросам. Честно показывает «типичный» показатель. Ноль или миллион на неё почти не влияют.

Best for **Где применять:** Данные с выбросами (зарплаты, цены, время ответа сервера).

SMART

Дисперсия: Насколько стабильна ваша модель?

Модель А: Низкая дисперсия



Ошибки: 9, 10, 10, 11, 10 (Среднее = 10)

Кучно. Маленький разброс — стабильная, предсказуемая модель.

Модель Б: Высокая дисперсия



Ошибки: 2, 5, 10, 15, 18 (Среднее = 10)

Хаотично. Большой разброс — нестабильная модель, которая иногда катастрофически ошибается.

Стандартное отклонение: Корень из дисперсии. Показывает отклонение в исходных единицах измерения (например, ошибка 10 ± 2 балла).

SMART

Корреляция: Как связаны данные?

Пример: Предсказание цены квартиры



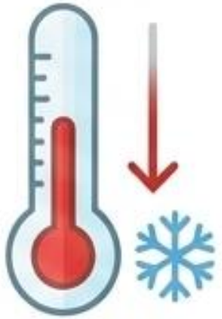
ПРАВИЛО: Перед обучением ИИ аналитики строят матрицу корреляций, чтобы убрать дублирующие признаки и оставить самые полезные для предсказания.

SMART

Важнейшее правило: Корреляция ≠ Причинность

Пираты и Климат





В XVIII веке было много пиратов и меньше глобального потепления.

Реальность: Пираты не охлаждают планету! Оба показателя связаны со временем.

Мороженое и Утопления





Продажи мороженого коррелируют с числом утоплений.

Реальность: Мороженое не убивает! Третий фактор — жаркая летняя погода.

Takeaway for AI: В ИИ: Если признак коррелирует с целью — он полезен для предсказания. Но это НЕ значит, что он является первопричиной результата.

SMART

Доверительный интервал: Зона уверенности

Точность модели 87%



Мы уверены на 95%, что точность находится в диапазоне 84–90% (87% ± 3%)



Как в соцопросах:
«Рейтинг кандидата 42%, погрешность ±3%»

Что влияет на ширину интервала?

Размер выборки	Мало данных (100) = широкий интервал (±10%). Много данных (10 000) = узкий интервал (±1%).
Уровень уверенности	99% уверенность требует более широкого интервала, чем 95%.
Разброс (Дисперсия)	Нестабильная модель с сильным разбросом ошибок = широкий интервал.

SMART

Как статистика работает в пайплайне ИИ

1. До обучения (Подготовка данных)

Инструменты:

Среднее, Медиана, Дисперсия, Корреляция.

Понять «типичный» объект, найти аномалии (выбросы), отобрать полезные признаки, убрать дубли.

2. После обучения (Оценка качества)

Инструменты:

Средняя ошибка (MAE), Дисперсия ошибок, Доверительный интервал.

Оценить среднюю точность, стабильность и надёжность оценки на тестовой выборке.

3. Проверка выводов (Сравнение)

Инструменты:

Доверительные интервалы.

Сравнить модель А и модель Б. Отличить реальное улучшение от случайного шума в данных.

SMART

5 частых ошибок начинающего аналитика

Ошибка	Как думать правильно
Среднее всегда описывает «типичное».	При выбросах честнее использовать медиану.
Корреляция = причинно-следственная связь.	Связь ≠ одно вызывает другое.
Слепо доверять точечной точности (напр. 87%).	Без доверительного интервала на малой выборке это число ненадёжно.
Дисперсия — это всегда плохо.	Это просто характеристика разброса, иногда он ожидаем.
Убирать все коррелирующие признаки.	Убирают только те, что дублируют друг друга, а не те, что связаны с целью.

SMART

Памятка: Главный итог занятия

ЦЕНТР

- **Среднее:** Чувствительно к выбросам.
- **Медиана:** Устойчива к выбросам (честнее для зарплат/цен).

РАЗБРОС

Дисперсия: Показывает хаотичность/стабиль-ность данных данных вокруг центра.

СВЯЗИ И УВЕРЕННОСТЬ

- **Корреляция:** Сила связи от -1 до +1. Не является причиной!
- **Интервал:** Честный диапазон точности (зависит от размера выборки).

3 этапа работы: 1. Анализ данных → 2. Оценка модели → 3. Проверка выводов.

SMART

Текущий контроль: Вопросы для обсуждения

1. Объясните своими словами: почему медиана зарплат честнее описывает «типичного» сотрудника, чем среднее значение?

2. Почему сильная корреляция между продажами мороженого и числом утоплений не означает, что мороженое опасно?

3. Две модели ИИ показали точность 82%. У первой доверительный интервал ±1%, у второй ±8%. Какую модель вы выберете для реального проекта и почему?

SMART

Текущий контроль: Тест

1. В датасете 9 человек получают 50 000 руб., один – 900 000 руб. Что лучше описывает «типичную» зарплату?

А. Среднее | ✓ **Б. Медиана** | В. Дисперсия | Г. Корреляция

2. Корреляция между признаками равна +0,9. Что это значит?

А. Одно вызывает другое | ✓ **Б. Признаки сильно связаны, но причинность не доказана** | В. Признак бесполезен

3. Модель А (ошибка 10, отклонение 1). Модель В (ошибка 10, отклонение 5). Какая стабильнее?

А. Модель В | ✓ **В. Модель А** | Г. Одинаково стабильны

SMART

Финальная мысль

> **Статистика — это язык, на котором данные рассказывают о себе.**

— Среднее и медиана показывают центр.
— Дисперсия показывает разброс.
— Корреляция показывает связи.
— Доверительный интервал гарантирует честность.

Хороший специалист по ИИ не просто запускает модель — он сначала разговаривает с данными на языке статистики.