МОДУЛЬ 2

Математическая статистика в задачах искусственного интеллекта

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Блок 2. Главная идея урока

01 Прежде чем обучать модель, нужно понять данные.

02 Статистики можно представить как краткое описание большого датасета.

03 Представьте, что вы обучаете модель предсказывать цены на квартиры.

04 При этом одного показателя обычно недостаточно.

Блок 3. Ключевые понятия · таблица 1/3

Понятие	Простое объяснение	Пример из ИИ
Среднее	Сумма всех значений, делённая на их количество	Средняя абсолютная ошибка модели по тестовой выборке
Медиана	Значение, которое делит упорядоченный набор данных на две равные по количеству части	Медианная зарплата в датасете резюме

Блок 3. Ключевые понятия · таблица 2/3

Понятие	Простое объяснение	Пример из ИИ
Дисперсия	Средний квадрат отклонения значений от среднего	Разброс предсказаний модели для похожих объектов
Корреляция	Степень линейной связи между двумя переменными (от −1 до +1)	Связь площади квартиры и её цены

Блок 3. Ключевые понятия · таблица 3/3

Понятие	Простое объяснение	Пример из ИИ
Доверительный интервал	Диапазон значений, рассчитанный по выборке для оценки неизвестного параметра	«Точность модели 87% ± 3%» при 95%-м уровне доверия

4.1. Среднее значение

01 Среднее – это самый привычный способ описать «типичное» значение.

02 Пять студентов сдали тест, их баллы: 60, 65, 70, 75, 80.

03 Среднее учитывает каждое наблюдение.

04 Но у среднего есть слабое место – оно очень чувствительно к выбросам.

4.2. Медиана

01 Медиана – это значение посередине, если расставить все данные по порядку.

02 Если количество значений нечётное, медианой будет одно центральное значение.

03 Если количество значений чётное, берут среднее арифметическое двух центральных значений.

04 Медиана честнее показывает «типичный» балл в этом примере, потому что ноль одного студента влияет на неё намного меньше, чем на среднее.

4.3. Когда что использовать? · таблица 1/2

Ситуация	Лучше использовать	Почему
Данные без сильных выбросов (баллы студентов)	Среднее	Учитывает все значения
Данные с выбросами (зарплаты, цены)	Медиана	Не «утягивается» крайними значениями

4.3. Когда что использовать? · таблица 2/2

Ситуация	Лучше использовать	Почему
Оценка средней абсолютной ошибки модели	Среднее (MAE)	Хотим учесть абсолютную ошибку на каждом объекте
Типичное время ответа сервиса	Медиана	Несколько очень медленных запросов меньше искажают картину

Блок 5. Дисперсия и разброс данных

01 Среднее говорит, где «центр» данных.

02 Аналогия: стрельба по мишени

03 Представьте двух стрелков.

04 Стрелок А: все пули попадают близко к центру – кучно.

5.1. Пример с оценками моделей

Модель	Ошибки на тесте	Среднее	Разброс
Модель А	9, 10, 10, 11, 10	10	Маленький – стабильная
Модель Б	2, 5, 10, 15, 18	10	Большой – менее стабильная

5.2. Стандартное отклонение – «дружественный брат» дисперсии

01 Дисперсия измеряется в квадратных единицах, поэтому её бывает неудобно интерпретировать напрямую.

02 Поэтому часто используют стандартное отклонение – квадратный корень из дисперсии.

03 Если средняя ошибка модели – 10 баллов, а стандартное отклонение – 2 балла, это означает, что характерный масштаб отклонения ошибок от среднего составляет около 2 баллов.

04 Нельзя без дополнительных предположений утверждать, что все или почти все ошибки находятся строго в диапазоне 8–12.

Блок 6. Корреляция: есть ли связь? · таблица 1/3

Значение	Что означает	Пример
+1	Идеальная положительная линейная связь	Значения связаны формулой вида y = ax + b, где a > 0
0	Линейная связь не обнаружена	Один признак не показывает линейного роста или падения вместе с другим

Блок 6. Корреляция: есть ли связь? · таблица 2/3

Значение	Что означает	Пример
−1	Идеальная отрицательная линейная связь	Значения связаны формулой вида y = ax + b, где a < 0
~0,8	Сильная положительная корреляция	При росте одного признака второй обычно растёт

Блок 6. Корреляция: есть ли связь? · таблица 3/3

Значение	Что означает	Пример
~−0,6	Умеренная отрицательная корреляция	При росте одного признака второй обычно уменьшается

6.1. Корреляция ≠ причинно-следственная связь

01 Важнейшее правило статистики!

02 Если два явления коррелируют – это НЕ значит, что одно вызывает другое.

03 Например, продажи мороженого могут коррелировать с числом происшествий на воде.

04 Возможная общая причина – жаркая погода: в жаркие дни люди чаще покупают мороженое и чаще купаются.

6.2. Применение корреляции в анализе данных

01 Перед обучением модели аналитики могут изучить матрицу корреляций – таблицу, показывающую попарные линейные связи между числовыми признаками.

02 Если признак сильно коррелирует с целевой переменной, он может быть полезен для модели.

03 Если два признака сильно коррелируют между собой, они могут частично дублировать информацию. Нужно проверить, действительно ли один из них стоит убрать.

04 Признаки с корреляцией, близкой к нулю по отношению к цели, могут оказаться малоинформативными для линейной модели, но сохранять нелинейную связь с целью.

6.3. Пример: признаки для предсказания цены квартиры · таблица 1/2

Признак	Корреляция с ценой	Предварительный вывод
Площадь (м²)	+0,85	Сильная положительная связь – признак стоит проверить в модели
Этаж	+0,15	Слабая линейная связь – возможны другие виды зависимости

6.3. Пример: признаки для предсказания цены квартиры · таблица 2/2

Признак	Корреляция с ценой	Предварительный вывод
Расстояние до метро	−0,70	Сильная обратная связь – признак может быть полезен
Цвет обоев	+0,02	Линейная связь почти не обнаружена

Блок 7. Доверительный интервал: насколько мы уверены?

01 Когда мы оцениваем точность модели на тестовой выборке, мы получаем одно число: например, 87%.

02 Доверительный интервал показывает неопределённость такой оценки.

03 Строгий смысл 95%-го уровня доверия связан с повторением процедуры: если много раз брать выборки одним и тем же способом и каждый раз строить интервал, примерно 95% таких интервалов накроют истинное значение параметра.

04 Аналогия: социологический опрос

7.1. Что влияет на ширину доверительного интервала? · таблица 1/2

Фактор	Как влияет	Пример
Размер выборки	При прочих равных больше выборка – уже интервал	Оценка по 10 000 объектам обычно точнее оценки по 100 объектам
Уровень доверия	Выше уровень доверия – шире интервал	99%-й интервал обычно шире 95%-го

7.1. Что влияет на ширину доверительного интервала? · таблица 2/2

Фактор	Как влияет	Пример
Разброс данных	Больше разброс – шире интервал	Сильно различающиеся результаты повышают неопределённость оценки

7.2. Почему это важно для ИИ?

01 Две модели с точностью 85% могут иметь разную неопределённость оценки: например, одна – 85% ± 1 процентный пункт, другая – 85% ± 10 процентных пунктов.

02 Широкий интервал может сигнализировать о малом объёме тестовой выборки или большом разбросе результатов.

03 При сравнении моделей полезно учитывать не только точечные значения метрики, но и их неопределённость.

04 Интервал относится к конкретной метрике и условиям тестирования. Он не гарантирует такое же качество после изменения данных.

8.1. При подготовке данных

01 Например, если средняя цена квартиры намного выше медианной, в датасете могут присутствовать несколько очень дорогих объектов.

8.2. При оценке качества модели

01 Средняя метрика может скрывать важные различия.

8.3. При проверке выводов · таблица 1/3

Задача в ИИ	Статистический инструмент	Что показывает
Анализ признаков	Среднее, медиана, дисперсия	Типичные значения и разброс
Отбор признаков	Корреляция	Линейную связь признака с целевой переменной или другими признаками

8.3. При проверке выводов · таблица 2/3

Задача в ИИ	Статистический инструмент	Что показывает
Оценка точности	Метрика + доверительный интервал	Качество модели и неопределённость его оценки
Сравнение моделей	Доверительные интервалы и статистическая проверка	Насколько убедительна наблюдаемая разница в качестве

8.3. При проверке выводов · таблица 3/3

Задача в ИИ	Статистический инструмент	Что показывает
Поиск выбросов	Среднее, медиана, стандартное отклонение	Значения, которые требуют отдельной проверки

Блок 9. Частые ошибки · таблица 1/4

Ошибка	Как думать правильно
Считать, что среднее всегда описывает «типичное»	При наличии сильных выбросов медиана часто лучше описывает центр большинства значений
Путать корреляцию с причинно-следственной связью	Совместное изменение переменных не доказывает, что одна вызывает другую

Блок 9. Частые ошибки · таблица 2/4

Ошибка	Как думать правильно
Считать нулевую корреляцию отсутствием любой связи	Коэффициент линейной корреляции может не заметить нелинейную зависимость
Доверять точечной оценке точности без интервала	Одна и та же метрика может иметь разную неопределённость на выборках разного размера

Блок 9. Частые ошибки · таблица 3/4

Ошибка	Как думать правильно
Считать, что дисперсия – это всегда плохо	Дисперсия – характеристика, а не оценка. В некоторых задачах большой разброс естественен
Автоматически удалять все выбросы	Сначала нужно определить, является значение ошибкой или реальным редким случаем

Блок 9. Частые ошибки · таблица 4/4

Ошибка	Как думать правильно
Убирать все коррелирующие признаки	Сильная корреляция – повод проверить дублирование, а не команда автоматически удалить признак

Блок 10. Памятка

01 📌 Ключевые тезисы урока

02 Среднее – сумма всех значений, делённая на их количество.

03 Медиана – центральное значение упорядоченного набора.

04 Дисперсия – средний квадрат отклонения значений от среднего.

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами