PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Признаки и целевая переменная

Содержание

- Вступление
- Четыре главных понятия
- Разбор четырёх реальных задач
- Хорошие и плохие признаки
- Потренируемся: найди признаки и целевую переменную
- Формальная запись: матрица признаков X и вектор Y
- Feature Engineering: создание новых признаков
- Признаки и целевая переменная в Python
- Итоги урока
- Материалы к занятию

Вступление

На прошлом уроке мы поняли главное: модель ИИ учится на примерах.
Сегодня – шаг глубже: разберёмся, из чего состоит «пример».
Представь себя на месте врача. К тебе приходит пациент.
Ты смотришь на симптомы: температура, кашель, давление, анализы...
И ставишь диагноз: «грипп» или «ангина» или «просто простуда».
У тебя есть ВХОДНЫЕ ДАННЫЕ (симптомы) и ВЫХОДНОЙ ВЫВОД (диагноз).
Модель ИИ работает точно так же:

- → Входные данные = **признаки** (features)
- → Выходной вывод = **целевая переменная** (target)

Понять разницу между ними – значит понять, что именно делает модель.
Что ты узнаешь на этом уроке:

- Чем признак отличается от целевой переменной – точно и однозначно.
- Как выглядят признаки в разных задачах: текст, число, категория.
- Как формулировать задачу МО: что на входе, что на выходе.
- Как «плохие признаки» делают модель бесполезной.

Четыре главных понятия

Понятие	Определение	Аналогия из жизни
Объект (instance / sample)	Один элемент данных, который описывается набором признаков. Каждая строка датасета – один объект.	Один пациент в базе данных больницы. Одна фотография в галерее. Одно письмо в почтовом ящике.
Признак (feature / X)	Одна измеримая характеристика объекта, которую модель получает на входе. Может быть числом, текстом, категорией, изображением.	Симптом пациента: температура 38,5°. Цвет пикселя в изображении. Длина письма в символах.
Целевая переменная (target / label / Y)	То, что модель должна предсказать или классифицировать. Всегда одна – это и есть «правильный ответ».	Диагноз: «грипп» или «здоров». Категория: «кот» / «собака». Цена квартиры в рублях.
Класс (class)	Одно из возможных значений целевой переменной в задаче классификации. При двух классах – бинарная классификация.	Классы «спам» и «не спам». Классы «высокий риск» и «низкий риск». Классы цифр 0–9 в распознавании почерка.

В рабочих задачах объект — это, например, одна заявка в службу поддержки. Признаки — канал обращения, время поступления, длина и текст заявки. Целевая переменная — отдел, который должен её обработать (данные учебные).

Главная формула урока

Модель ИИ – это функция:

$$f(X_1, X_2, X_3, ..., X_n) \rightarrow Y$$

Где:

- X_1, X_2, ..., X_n – признаки (входные данные)

- Y – целевая переменная (что нужно предсказать)
- f – то, что модель ВЫУЧИЛА из примеров

Весь процесс обучения – это поиск наилучшей функции f, которая верно отображает признаки в целевую переменную.
Это та же функция, что в программировании: признаки — аргументы, Y — возвращаемое значение. Разница в том, что тело функции пишет не программист, а алгоритм обучения: он подбирает f по примерам.

Разбор четырёх реальных задач

Разберём детально четыре задачи ИИ: для каждой – объект, признаки, целевая переменная, класс (если есть).

Задача 1. Распознавание сообщений: спам или не спам?

Здесь объект — одно сообщение.

Признаки (X)

- X_1 = длина сообщения: 42 символа
- X_2 = есть слово «выиграй»: да (1)
- X_3 = знакомый отправитель: нет (0)
- X_4 = количество восклицаний: 3
- X_5 = ссылки в тексте: 2
- X_6 = время отправки: 03:41

Целевая переменная (Y)

→ Y = «СПАМ» (1)

Классификация

2 класса:

- 1 = Спам
- 0 = Не спам

Разбор признаков

Числовые: длина (42), кол-во восклицаний (3), кол-во ссылок (2).

Бинарные: есть слово «выиграй» (0/1), знакомый отправитель (0/1).

Временной: час отправки – можно преобразовать в цифру.

Бинарный признак отвечает на вопрос «да или нет?». Поэтому у него всего два значения: 1 — «да», 0 — «нет». **Числовой** признак отвечает на вопрос «сколько?».

Что НЕ является признаком в этой задаче:

- Сама метка «спам/не спам» – это целевая переменная Y, а не X.
- Настроение получателя – это не измеримая характеристика объекта (сообщения).

Вопрос для самопроверки

Представьте, что в текст письма добавили скрытый пиксель для отслеживания.
Это признак? Если да – числовой или бинарный?

Подсказка

Посмотрите на разбор признаков выше и решите, на какой вопрос отвечает этот признак.

Задача 2. Оценка кредитного риска

Здесь объект — один человек, который просит у банка кредит.

Признаки (X)

- X_1 = возраст: 34 года
- X_2 = ежемесячный доход: 65 000 руб.
- X_3 = наличие долгов: нет (0)
- X_4 = стаж работы: 4 года
- X_5 = кредитная история: 7/10
- X_6 = количество иждивенцев: 1

Целевая переменная (Y)

→ Y = «ОДОБРИТЬ» (1)

Классификация

2 класса:

- 1 = Одобрить
- 0 = Отказать

Разбор: признаки высокого качества и «шумные» признаки

Полезные признаки (сильная связь с Y):

- Кредитная история: прямо показывает надёжность клиента.
- Доход: чем выше – тем больше вероятность возврата.
- Наличие долгов: прямой «красный флаг».

Менее надёжные признаки:

- Возраст: корреляция есть, но слабая и нелинейная.
- Иждивенцы: зависит от дохода – не всегда информативен.

Корреляция — это связь между двумя показателями: меняется один — меняется и другой. «Нелинейная» значит, что связь не прямая: нельзя сказать «чем старше человек, тем он всегда надёжнее».

Потенциально вредные признаки (предвзятость):

- Пол, национальность, место жительства – могут создать дискриминирующую модель, даже если технически «работают».

Задача 3. Прогноз цены квартиры

Здесь объект — одна квартира.

Признаки (X)

- X_1 = площадь: 52 м²
- X_2 = этаж: 5 из 9
- X_3 = расстояние до метро: 800 м
- X_4 = год постройки: 1987
- X_5 = район: «Центральный»
- X_6 = наличие ремонта: да (1)

Целевая переменная (Y)

→ Y = 6 850 000 руб.

Регрессия

(число, а не категория)

Задачи классификации (Y – категория)

Метка = одно из конечного набора значений.
Примеры Y:

- «спам» / «не спам»
- «кот» / «собака» / «птица»
- «0», «1», «2», ..., «9»
- «высокий риск» / «низкий риск»

Задачи регрессии (Y – число)

Метка = произвольное число.
Примеры Y:

- Цена квартиры: 6 850 000 руб.
- Температура завтра: 18,4°
- Оценка удовлетворённости клиента: 78 из 100
- Время доставки: 42 мин

Как отличить классификацию от регрессии

Задайте себе вопрос: «Ответ – это имя из списка или число из диапазона?»

- «Кот или собака?» → имя из списка → классификация
- «Сколько весит животное?» → число из диапазона → регрессия

Граничный случай: «Оценка от 1 до 5» – зависит от задачи.

- Если нас волнует именно «1, 2, 3, 4 или 5» – классификация.
- Если нас волнует «насколько хорошо» непрерывно – регрессия.

«Непрерывно» значит, что между числами есть промежуточные значения: например, 4,3 тоже имеет смысл.

Задача 4. Классификация изображений

Распознавание рукописных цифр – одна из классических задач МО. Датасет MNIST содержит 70 000 изображений цифр 28×28 пикселей.
Картинка 28×28 — это 28 строк по 28 точек (пикселей). Яркость точки — число: чем оно больше, тем светлее точка. Здесь объект — одно изображение цифры.

Признаки (X)

- X_1 = яркость пикселя (0,0): 0
- X_2 = яркость пикселя (0,1): 0
- ...
- X_{392} = яркость пикселя (13,13): 255
- ...
- X_{784} = яркость пикселя (27,27): 0

Целевая переменная (Y)

→ Y = «5»

Классификация

10 классов:

0, 1, 2, 3, 4, 5, 6, 7, 8, 9

Всего: 784 признака на одно изображение

Что важно понять на этом примере

1. Признаков может быть ОЧЕНЬ МНОГО.
   784 пикселя на изображение 28×28. Реальные фото: миллионы пикселей.
   Человек не может написать правила для 784 пикселей – но модель справляется.
2. Признаки могут быть «бессмысленными» по отдельности.
   Один пиксель ничего не говорит. Вместе – форма цифры.
   Модель находит комбинации признаков, которые важны.
3. Целевая переменная – всегда одна.
   Даже если классов 10 – это всё равно один Y.

Хорошие и плохие признаки

Не все признаки одинаково полезны. Качество модели напрямую зависит от качества признаков. Рассмотрим типичные проблемы.

Проблема признака	Что происходит	Пример	Как исправить
Не связан с Y	Признак не несёт информации о целевой переменной – «шум»	Порядковый номер записи в базе данных для предсказания цены квартиры	Удалить признак (feature selection)

Утечка данных (data leakage)	Признак содержит информацию о Y, которой НЕ БУДЕТ при реальном использовании	Признак «дата одобрения кредита» при предсказании «одобрят ли кредит»	Убрать все признаки, которые появляются ПОСЛЕ целевого события
Пропущенные значения	Часть строк не имеет значения признака	У 30% пациентов нет данных об уровне холестерина	Заполнить средним / медианой / отдельной категорией «неизвестно»
Масштаб различается на порядки	Признак с большими числами «перекрывает» признак с маленькими	Доход в рублях (0–1 000 000) и возраст (0–100)	Нормализация: привести все признаки к диапазону [0, 1]
Предвзятость (bias)	Признак дискриминирует группу людей	Использование пола или национальности в кредитном скоринге	Удалить или применить fairness-ограничения
Мультиколлинеарность	Два признака содержат одну и ту же информацию	«Площадь кухни» и «площадь квартиры» – тесно связаны	Оставить один из двух или создать новый комбинированный

Утечка данных похожа на контрольную, где рядом с задачей случайно напечатан ответ. На тренировке ученик «решает» всё правильно. Но на настоящей контрольной ответа рядом не будет — и он растеряется. С моделью так же: дату одобрения кредита мы узнаём только после решения банка, а модель должна дать ответ до него.

Правило «мусор на входе – мусор на выходе»

В машинном обучении это называется GIGO: Garbage In – Garbage Out.

Даже самый мощный алгоритм не поможет, если признаки некачественные.

90% работы хорошего аналитика данных – это подготовка и отбор признаков.

Сам алгоритм – это лишь 10%.

Потренируемся: найди признаки и целевую переменную

Для каждой задачи определите: что является признаком (X), а что – целевой переменной (Y). Затем определите тип задачи: классификация или регрессия.

№	Задача ИИ	Признаки X (что на входе)?	Целевая переменная Y?	Тип задачи?
1	Автоматическое определение языка текста сообщения	?	?	?

2	Прогноз температуры воздуха на завтра	?	?	?
3	Определение мошеннической транзакции банковской карты	?	?	?
4	Оценка сложности текста (для какого класса он подходит)	?	?	?
5	Рекомендация фильма пользователю	?	?	?
6	Автоматический перевод с русского на английский	?	?	?

Подсказки для размышления

Задача 1: «Здравствуйте» – русский, «Hello» – английский, «Bonjour» – французский.
Задача 6: Перевод – это особая задача. Y – не одно число и не категория, а целая последовательность слов. Это называется «seq2seq».

Формальная запись: матрица признаков X и вектор Y

В машинном обучении данные записываются в формализованном виде, который позволяет применять к ним математические операции.

Матрица признаков X

Структура датасета в матричном виде

	X_1 Площадь	X_2 Этаж	X_3 Метро	X_4 Ремонт	Y Цена
Объект 1	52	5	800	1	6 850 000
Объект 2	35	2	200	0	4 200 000
Объект 3	80	9	1500	1	9 100 000

...					

X – матрица размерности (n × m):

- n = число объектов (строк)
- m = число признаков (столбцов)

y – вектор длиной n: один правильный ответ для каждого объекта.
Задача обучения: найти f такую, что f(X) ≈ y.

$$f(X) \approx y$$

В программе матрица X — это двумерный массив: элемент X[i][j] хранит значение j-го признака у i-го объекта. Столбец Y в матрицу X не входит, он хранится отдельно как вектор y.

Разделение на train/test

Датасет принято делить на две части перед обучением:

Часть	Размер (типично)	Для чего	Когда используется
Train (обучающая)	70–80% датасета	Модель учится на этих данных	`model.fit(X_train, y_train)`
Test (тестовая)	20–30% датасета	Проверка качества на новых данных	`model.predict(X_test)` → сравнить с `y_test`

```
import numpy as np
from sklearn.model_selection import train_test_split
# X - матрица признаков, y - вектор меток
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

- `test_size=0.2` означает: 20% данных – в тест, 80% – в обучение.
- `random_state=42` – фиксирует случайное разбиение для воспроизводимости.
- После этого: `model.fit(X_train, y_train)` → `model.predict(X_test)`

Тестовая часть нужна, чтобы поймать переобучение: если проверять модель на тех же данных, на которых она училась, не отличить понимание закономерности от запоминания примеров.

One-Hot Encoding: как превратить категорию в числа

Большинство алгоритмов работают только с числами. Категориальные признаки нужно преобразовать:

Исходный признак «Район»	→ One-Hot Encoding
Центральный	Центральный=1, Северный=0, Южный=0
Северный	Центральный=0, Северный=1, Южный=0
Южный	Центральный=0, Северный=0, Южный=1

Почему не просто 1, 2, 3?
Если закодировать «Центральный=1, Северный=2, Южный=3» — модель решит, что «Южный в 3 раза больше Центрального».
Это неверно: районы не имеют числового порядка.
One-Hot Encoding не создаёт ложного числового отношения.
Цена за это — число столбцов: один категориальный признак с k значениями превращается в k бинарных признаков.

Feature Engineering: создание новых признаков

Иногда признаки, собранные напрямую, не дают модели нужной информации. Тогда аналитик создаёт новые признаки из существующих – это называется Feature Engineering.

Исходные признаки	Новый признак (Feature Engineering)	Зачем это нужно
Дата рождения: 15.03.1992	Возраст: 32 года	Модель работает с числом, а не с датой
Площадь квартиры: 52 м² Цена: 6 850 000 руб.	Цена за м²: 131 731 руб./м²	Нормализует по площади – честное сравнение
Дата транзакции: 02:47	Ночное время: 1 (0=день, 1=ночь)	Ночные транзакции – признак мошенничества
Текст отзыва (строка)	Длина текста: 347 символов Количество эмодзи: 4 Тональность: −0,7	Числовые признаки из текста для анализа
GPS-координаты: 55.75, 37.61	Расстояние до центра Москвы: 3,2 км	Геометрическое расстояние как признак

> **Важно**
>
> «Цена за м²» подходит, чтобы сравнивать квартиры между собой. Для прогноза цены её брать нельзя: она вычислена из самой цены, то есть из Y. Это утечка данных — при реальном прогнозе цены ещё нет.

Почему Feature Engineering важен
Хороший признак = лучше модель. Это важнее, чем выбор алгоритма.
Пример: модель предсказания мошенничества.

- Без Feature Engineering: «сумма транзакции» – слабый признак.
- С Feature Engineering: «сумма / среднее_за_последние_30_дней» – сильный признак.
- Один и тот же алгоритм, другие признаки → точность +15%.

Почему второй признак сильнее: 5 000 руб. — обычная покупка для одного клиента и подозрительная для другого. Отношение к среднему показывает, насколько операция необычна именно для этого человека (данные учебные).

Признаки и целевая переменная в Python

Работа с датасетом в pandas

```
import pandas as pd
# Загрузка данных
df = pd.DataFrame({
    'площадь':  [52, 35, 80, 65],
    'этаж':     [ 5,  2,  9,  7],
    'метро_м':  [800, 200, 1500, 600],
    'ремонт':   [  1,   0,    1,   1],
    'цена':     [6850000, 4200000, 9100000, 7500000]
})
# Разделение на X (матрица признаков) и y (целевая переменная)
X = df.drop(columns=['цена'])   # все столбцы КРОМЕ целевого
y = df['цена']                  # только целевой столбец
print(f'X: {X.shape}')  # → X: (4, 4)  – 4 объекта, 4 признака
print(f'y: {y.shape}')  # → y: (4,)    – 4 значения целевой переменной
```

`shape` возвращает размер таблицы: (строки, столбцы). У вектора `y` один столбец, поэтому после запятой ничего нет — `(4,)`.

One-Hot Encoding в pandas

```
# Если есть категориальный признак
df_with_district = df.copy()
df_with_district['район'] = ['Центральный', 'Южный', 'Северный', 'Центральный']
# One-Hot Encoding
df_encoded = pd.get_dummies(df_with_district, columns=['район'])
print(df_encoded.columns.tolist())
# → ['площадь', 'этаж', 'метро_м', 'ремонт', 'цена',
#     'район_Северный', 'район_Центральный', 'район_Южный']
```

`pd.get_dummies` делает то же, что таблица One-Hot Encoding выше: вместо одного столбца «район» появляются три бинарных столбца, по одному на каждое значение.

Feature Engineering пример

```
# Создаём новый признак «цена за квадратный метр»
df['цена_за_м2'] = df['цена'] / df['площадь']
# Создаём бинарный признак «большая квартира»
df['большая'] = (df['площадь'] > 60).astype(int)
# Обновляем X с новыми признаками
X = df.drop(columns=['цена'])
print(X.columns.tolist())
# → ['площадь', 'этаж', 'метро_м', 'ремонт', 'цена_за_м2', 'большая']
```

> **Важно**
>
> Если по такому `X` прогнозировать цену, столбец `цена_за_м2` — утечка данных: он вычислен из самой цены. Для прогноза его нужно убрать из `X`. Признак `большая` утечкой не является: он построен только из площади.

Итоги урока

1. **Объект** – один элемент данных (строка таблицы).
2. **Признак (X)** – что модель получает на входе. Столбцов может быть от 1 до миллионов.
3. **Целевая переменная (Y)** – что модель должна предсказать. Всегда одна.
4. **Класс** – одно из значений Y при классификации.
   Классификация: Y – категория. Регрессия: Y – число.
5. Плохие признаки = плохая модель, даже при отличном алгоритме.
6. **Утечка данных** – скрытая информация о Y в признаках. Делает модель «жуликом».
7. **Feature Engineering** – создание новых признаков – часто важнее выбора алгоритма.

Материалы к занятию

- AI_Features_and_Target_Variables.pptx (13.8 МБ)