МОДУЛЬ 3

Признаки и целевая переменная

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Вступление

01 На прошлом уроке мы поняли главное: модель ИИ учится на примерах.

02 Сегодня – шаг глубже: разберёмся, из чего состоит «пример».

03 Представь себя на месте врача.

04 Ты смотришь на симптомы: температура, кашель, давление, анализы...

Четыре главных понятия · таблица 1/2

Понятие	Определение	Аналогия из жизни
Объект (instance / sample)	Один элемент данных, который описывается набором признаков. Каждая строка датасета – один объект.	Один пациент в базе данных больницы. Одна фотография в галерее. Одно письмо в почтовом ящике.
Признак (feature / X)	Одна измеримая характеристика объекта, которую модель получает на входе. Может быть числом, текстом, категорией, изображением.	Симптом пациента: температура 38,5°. Цвет пикселя в изображении. Длина письма в символах.

Четыре главных понятия · таблица 2/2

Понятие	Определение	Аналогия из жизни
Целевая переменная (target / label / Y)	То, что модель должна предсказать или классифицировать. Всегда одна – это и есть «правильный ответ».	Диагноз: «грипп» или «здоров». Категория: «кот» / «собака». Цена квартиры в рублях.
Класс (class)	Одно из возможных значений целевой переменной в задаче классификации. При двух классах – бинарная классификация.	Классы «спам» и «не спам». Классы «высокий риск» и «низкий риск». Классы цифр 0–9 в распознавании почерка.

Главная формула урока

01 $f(X_1, X_2, X_3, ..., X_n) \rightarrow Y$

02 Где: $X_1, X_2, ..., X_n$ – признаки (входные данные), Y – целевая переменная (что нужно предсказать), f – то, что модель ВЫУЧИЛА из примеров.

03 Весь процесс обучения – это поиск наилучшей функции f, которая верно отображает признаки в целевую переменную.

04 Это та же функция, что в программировании: признаки — аргументы, Y — возвращаемое значение.

Задача 1. Распознавание сообщений: спам или не спам?

01 Здесь объект — одно сообщение.

02 Примеры: X_1 = длина сообщения: 42 символа, X_2 = есть слово «выиграй»: да (1), X_3 = знакомый отправитель: нет (0), X_4 = количество восклицаний: 3, X_5 = ссылки в тексте: 2, X_6 = время отправки: 03:41.

03 Целевая переменная (Y)

04 2 класса: 1 = Спам, 0 = Не спам.

Задача 2. Оценка кредитного риска

01 Здесь объект — один человек, который просит у банка кредит.

02 Примеры: X_1 = возраст: 34 года, X_2 = ежемесячный доход: 65 000 руб, X_3 = наличие долгов: нет (0), X_4 = стаж работы: 4 года, X_5 = кредитная история: 7/10, X_6 = количество иждивенцев: 1.

03 Целевая переменная (Y)

04 2 класса: 1 = Одобрить, 0 = Отказать.

Задача 3. Прогноз цены квартиры

01 Здесь объект — одна квартира.

02 Примеры: X_1 = площадь: 52 м², X_2 = этаж: 5 из 9, X_3 = расстояние до метро: 800 м, X_4 = год постройки: 1987, X_5 = район: «Центральный», X_6 = наличие ремонта: да (1).

03 Целевая переменная (Y)

04 (число, а не категория)

Задача 4. Классификация изображений

01 Распознавание рукописных цифр – одна из классических задач МО.

02 Картинка 28×28 — это 28 строк по 28 точек (пикселей).

03 Примеры: X_1 = яркость пикселя (0,0): 0, X_2 = яркость пикселя (0,1): 0, , X_{392} = яркость пикселя (13,13): 255, , X_{784} = яркость пикселя (27,27): 0.

04 Всего: 784 признака на одно изображение

Хорошие и плохие признаки · таблица 1/3

Проблема признака	Что происходит	Пример	Как исправить
Не связан с Y	Признак не несёт информации о целевой переменной – «шум»	Порядковый номер записи в базе данных для предсказания цены квартиры	Удалить признак (feature selection)
Утечка данных (data leakage)	Признак содержит информацию о Y, которой НЕ БУДЕТ при реальном использовании	Признак «дата одобрения кредита» при предсказании «одобрят ли кредит»	Убрать все признаки, которые появляются ПОСЛЕ целевого события

Хорошие и плохие признаки · таблица 2/3

Проблема признака	Что происходит	Пример	Как исправить
Пропущенные значения	Часть строк не имеет значения признака	У 30% пациентов нет данных об уровне холестерина	Заполнить средним / медианой / отдельной категорией «неизвестно»
Масштаб различается на порядки	Признак с большими числами «перекрывает» признак с маленькими	Доход в рублях (0–1 000 000) и возраст (0–100)	Нормализация: привести все признаки к диапазону [0, 1]

Хорошие и плохие признаки · таблица 3/3

Проблема признака	Что происходит	Пример	Как исправить
Предвзятость (bias)	Признак дискриминирует группу людей	Использование пола или национальности в кредитном скоринге	Удалить или применить fairness-ограничения
Мультиколлинеарность	Два признака содержат одну и ту же информацию	«Площадь кухни» и «площадь квартиры» – тесно связаны	Оставить один из двух или создать новый комбинированный

Потренируемся: найди признаки и целевую переменную · таблица 1/3

№	Задача ИИ	Признаки X (что на входе)?	Целевая переменная Y?	Тип задачи?
1	Автоматическое определение языка текста сообщения	?	?	?
2	Прогноз температуры воздуха на завтра	?	?	?

Потренируемся: найди признаки и целевую переменную · таблица 2/3

№	Задача ИИ	Признаки X (что на входе)?	Целевая переменная Y?	Тип задачи?
3	Определение мошеннической транзакции банковской карты	?	?	?
4	Оценка сложности текста (для какого класса он подходит)	?	?	?

Потренируемся: найди признаки и целевую переменную · таблица 3/3

№	Задача ИИ	Признаки X (что на входе)?	Целевая переменная Y?	Тип задачи?
5	Рекомендация фильма пользователю	?	?	?
6	Автоматический перевод с русского на английский	?	?	?

Матрица признаков X

01 Структура датасета в матричном виде

02 X – матрица размерности (n × m): n = число объектов (строк), m = число признаков (столбцов).

03 y – вектор длиной n: один правильный ответ для каждого объекта.

04 Задача обучения: найти f такую, что f(X) ≈ y.

Разделение на train/test

Часть	Размер (типично)	Для чего	Когда используется
Train (обучающая)	70–80% датасета	Модель учится на этих данных	model.fit(X_train, y_train)
Test (тестовая)	20–30% датасета	Проверка качества на новых данных	model.predict(X_test) → сравнить с y_test

One-Hot Encoding: как превратить категорию в числа · таблица 1/2

Исходный признак «Район»	→ One-Hot Encoding
Центральный	Центральный=1, Северный=0, Южный=0
Северный	Центральный=0, Северный=1, Южный=0

One-Hot Encoding: как превратить категорию в числа · таблица 2/2

Исходный признак «Район»	→ One-Hot Encoding
Южный	Центральный=0, Северный=0, Южный=1

Feature Engineering: создание новых признаков · таблица 1/3

Исходные признаки	Новый признак (Feature Engineering)	Зачем это нужно
Дата рождения: 15.03.1992	Возраст: 32 года	Модель работает с числом, а не с датой
Площадь квартиры: 52 м² Цена: 6 850 000 руб.	Цена за м²: 131 731 руб./м²	Нормализует по площади – честное сравнение

Feature Engineering: создание новых признаков · таблица 2/3

Исходные признаки	Новый признак (Feature Engineering)	Зачем это нужно
Дата транзакции: 02:47	Ночное время: 1 (0=день, 1=ночь)	Ночные транзакции – признак мошенничества
Текст отзыва (строка)	Длина текста: 347 символов Количество эмодзи: 4 Тональность: −0,7	Числовые признаки из текста для анализа

Feature Engineering: создание новых признаков · таблица 3/3

Исходные признаки	Новый признак (Feature Engineering)	Зачем это нужно
GPS-координаты: 55.75, 37.61	Расстояние до центра Москвы: 3,2 км	Геометрическое расстояние как признак

Работа с датасетом в pandas

```
import pandas as pd
# Загрузка данных
df = pd.DataFrame({
    'площадь':  [52, 35, 80, 65],
    'этаж':     [ 5,  2,  9,  7],
    'метро_м':  [800, 200, 1500, 600],
    'ремонт':   [  1,   0,    1,   1],
    'цена':     [6850000, 4200000, 9100000, 7500000]
})
# Разделение на X (матрица признаков) и y (целевая переменная)
X = df.drop(columns=['цена'])   # все столбцы КРОМЕ целевого
y = df['цена']                  # только целевой столбец
print(f'X: {X.shape}')  # → X: (4, 4)  – 4 объекта, 4 признака
```

Фрагмент примера. Полный код приведён в тексте лекции.

One-Hot Encoding в pandas

```
# Если есть категориальный признак
df_with_district = df.copy()
df_with_district['район'] = ['Центральный', 'Южный', 'Северный', 'Центральный']
# One-Hot Encoding
df_encoded = pd.get_dummies(df_with_district, columns=['район'])
print(df_encoded.columns.tolist())
# → ['площадь', 'этаж', 'метро_м', 'ремонт', 'цена',
#     'район_Северный', 'район_Центральный', 'район_Южный']
```

pd.get_dummies делает то же, что таблица One-Hot Encoding выше: вместо одного столбца «район» появляются три бинарных столбца, по одному на каждое значение.

Feature Engineering пример

```
# Создаём новый признак «цена за квадратный метр»
df['цена_за_м2'] = df['цена'] / df['площадь']
# Создаём бинарный признак «большая квартира»
df['большая'] = (df['площадь'] > 60).astype(int)
# Обновляем X с новыми признаками
X = df.drop(columns=['цена'])
print(X.columns.tolist())
# → ['площадь', 'этаж', 'метро_м', 'ремонт', 'цена_за_м2', 'большая']
```

Если по такому X прогнозировать цену, столбец цена_за_м2 — утечка данных: он вычислен из самой цены.

Итоги урока

01 Объект – один элемент данных (строка таблицы).

02 Признак (X) – что модель получает на входе. Столбцов может быть от 1 до миллионов.

03 Целевая переменная (Y) – что модель должна предсказать. Всегда одна.

04 Класс – одно из значений Y при классификации. Классификация: Y – категория. Регрессия: Y – число.

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами