SMART

Урок 3.2 Признаки и целевая переменная

Модуль 3. Алгоритмы и модели искусственного интеллекта.
Теоретическое занятие · 8–9 классы, 10–11 классы, СПО ·
2 академических часа.

Навигация по уровням

8–9 классы

Блоки 1–6
+ контроль.

Акцент на аналогиях и разборе задач.

10–11 классы

Блоки 1–8
+ контроль.

Дополнительно – формальная запись X и и Y.

СПО

Все блоки 1–9.

Python-иллюстрации и профессиональный контекст.

SMART

Как работает модель ИИ? Аналогия с врачом

Врач



Входные данные:
Врач смотрит на симптомы (температура, кашель, давление).



Выходной вывод:
Ставит диагноз («грипп» или «ангина»).

Модель ИИ



Входные данные (симптомы) = **Признаки (features)**



Выходной вывод (диагноз) = **Целевая переменная (target)**

Понять разницу между ними – значит понять, что именно делает модель.

SMART

4 главных понятия машинного обучения

Объект (instance/sample)



Один элемент данных (пациент, фото, письмо). Каждая строка датасета.

Признак (feature/X)



Измеримая характеристика на входе (симптомы, цвет пикселя, длина текста).

Целевая переменная (target/Y)



То, что предсказываем. Всегда одна (правильный ответ).

Класс (class)



Одно из возможных значений Y в задаче классификации («спам» / «не спам»).

SMART

Главная формула урока

SMART

f: То, что модель ВЫУЧИЛА из примеров.

$$f(X_1, X_2, X_3, \dots, X_n) \rightarrow Y$$

$X_1, X_2, \dots, X_n$: Признаки (входные данные).

Y: Целевая переменная (что нужно предсказать).

Весь процесс обучения – это поиск наилучшей функции f.

Типы задач: Как определить?

SMART

Классификация

Y = Категория. Ответ – имя из списка.
Примеры: «спам» / «спам» / «не спам»; «кот» / «собака»; «высокий риск» / «низкий риск».

Регрессия

Y = Число. Ответ – число из диапазона.
Примеры: Цена квартиры (6 850 000 руб.); Температура (18,4°); Балл ЕГЭ.

Отличай так: ответ — это имя из списка или число из диапазона?

Признаки и целевая переменная на практике

Задача: Спам

X: длина, слова, ссылки. → **Y**: Спам (1/0).

Классификация

Задача: Кредитный риск

X: доход, долги, история. → **Y**: Одобрить (1/0).

Классификация

Задача: Цена квартиры

X: площадь, этаж, метро. → **Y**: Цена в руб.

Регрессия

Задача: MNIST Фото

X: 784 пикселя (яркость). → **Y**: Цифра (0-9).

Классификация

SMART

Хорошие и плохие признаки (GIGO) ⚠

«Мусор на входе – мусор на выходе» (Garbage In, Garbage Out). 90% работы аналитика – отбор признаков.

Проблема	Пример / Следствие
Утечка данных	Скрытая инфа о Y (напр., дата доставки для предсказания срока). —> Решение: Удалить.
Предвзятость (bias)	Дискриминация (напр., использование пола в кредитах).
Мультиколлинеарность	Дублирование инфы (площадь кухни и площадь квартиры).
Шум	Не связан с Y (напр., порядковый номер в БД).

SMART

Формальная запись (10–11 классы и СПО)

Матрица признаков **X** и вектор **Y**



- **X**: матрица размерности (**n** × **m**), где **n** = объекты, **m** = признаки.
- **y**: вектор длиной **n** (правильные ответы).

SMART

Разделение данных (Train / Test)

Обучающая выборка. Модель учится (model.fit(X_train, y_train)).

Тестовая выборка. Проверка качества на новых данных (model.predict(X_test)).



Переобучение: когда модель идеально работает на Train, но проваливает Test («зазубрил учебник, провалил экзамен»).

SMART

Как превратить категорию в числа? (One-Hot Encoding)

Почему нельзя закодировать районы как 1, 2, 3? Модель решит, что «Южный (3) в 3 раза больше Центрального (1)».

Исходный: «Северный»



Центральный = 0

Северный = 1

Южный = 0

SMART

Feature Engineering (Конструирование признаков)

Хороший признак часто важнее выбора алгоритма.

Сырые данные: Площадь (52 кв.м) + Цена (6.85 млн)	→	**Новый сильный признак:** Цена за кв.м. (Честное сравнение).
Сырые данные: Время транзакции (02:47)	→	**Новый сильный признак:** Ночное время (1/0) (Признак мошенничества).
Сырые данные: Текст отзыва	→	**Новый сильный признак:** Длина текста, Тональность.

SMART

Практика в Python (pandas) [СПО]

```python
import pandas as pd

# Разделение на X и y
X = df.drop(columns=['цена'])  # все столбцы КРОМЕ целевого
y = df['цена']                 # только целевой столбец

# Feature Engineering
df['цена_за_м2'] = df['цена'] / df['площадь']
```

SMART

Ключевые мысли урока 3.2

SMART

1	**Объект:** Один элемент данных (строка таблицы).
2	**Признак (X):** Входные данные (от 1 до миллионов столбцов).
3	**Целевая переменная (Y):** Что предсказываем (всегда одна).
4	**Два типа задач:** Классификация (Y = категория), Регрессия (Y = число).
5	**GIGO:** Плохие признаки = плохая модель. Берегитесь утечки данных.
6	**Feature Engineering:** Создание новых признаков – ключ к высокой точности.

Текущий контроль: Проверь себя

1. Что является целевой переменной в определении настроения отзыва?

Ответ: *«Позитивный/негативный» - Y, категория, задача классификации.*

2. Задача: предсказать сумму следующей покупки. Какой это тип задачи?

Ответ: *Регрессия, Y - число.*

3. Почему нельзя закодировать районы цифрами 1,2,3?

Ответ: *Алгоритм воспримет категории как математическое неравенство.*

Анонс урока 3.3: Деревья решений – как алгоритм выбирает признаки для разделения данных.

SMART