PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Обучающая и тестовая выборки

Содержание

- Ключевые понятия
- Аналогия: тренировка и контрольная
- Как данные делят на части
- Почему тестовые данные нельзя показывать заранее
- Демонстрационный пример проверки
- Переобучение простыми словами
- Как интерпретировать проверку
- Памятка
- Материалы к занятию

На предыдущих занятиях уже разбиралось, как модель учится на примерах: у каждого объекта есть признаки, а у задачи есть правильный ответ или целевая переменная. Теперь появляется важный вопрос: как понять, что модель действительно научилась, а не просто запомнила знакомые строки?

Для этого датасет делят на две части: обучающую и тестовую. На одной части модель учится, а на другой её проверяют. Это похоже на подготовку к контрольной: тренировочные задачи помогают разобраться, но проверка должна проходить на новых задачах.

Такое разделение помогает оценить способность модели **обобщать**, то есть применять найденную закономерность к объектам, которых не было среди примеров для обучения. Именно это свойство требуется в реальной задаче: например, фильтр спама должен распознавать не только известные сообщения, но и новые.

Главная мысль урока: модель нужно проверять на новых примерах. Только так можно честнее оценить, будет ли она работать в реальной задаче.

При этом результат тестирования является оценкой качества, а не гарантией безошибочной работы. Чем лучше тестовая выборка похожа на будущие реальные данные, тем полезнее полученная оценка.

Ключевые понятия

Понятие	Смысл
Обучающая выборка	Часть данных, на которой модель учится находить связь между признаками и правильными ответами.
Тестовая выборка	Часть данных, которую модель не видела во время обучения. Она нужна для проверки на новых примерах.
Новые примеры	Объекты, которые модель не запоминала заранее. Именно на них видно, умеет ли она применять найденную закономерность.
Честная проверка	Оценка модели на тестовой выборке, а не только на тренировочных данных.
Переобучение	Ситуация, когда модель хорошо работает на обучающих данных, но хуже справляется с новыми примерами.

Обучающая и тестовая выборки имеют разные назначения, поэтому их нельзя смешивать. Обучающая часть отвечает на вопрос «на каких данных модель ищет закономерность?», а тестовая — на вопрос «насколько хорошо найденная закономерность работает на новых данных?».

Слово «выборка» здесь означает набор объектов, взятых из общего датасета. Каждый объект целиком относят только к одной части: например, одно и то же сообщение не должно одновременно находиться и в обучающей, и в тестовой выборке.

Аналогия: тренировка и контрольная

Представьте ученика, который готовится к контрольной. Если ему заранее дали ровно те же задачи и он выучил ответы, высокая оценка ещё не доказывает, что он понял тему. Он мог просто запомнить решения.

С моделью происходит похожая история. Если проверять её только на тех строках датасета, которые она уже видела, результат может выглядеть слишком хорошим. Но такая проверка не отвечает на главный вопрос: что будет с новым объектом?

Если же на контрольной изменились числа, формулировки или порядок действий, ученику нужно применить общий способ решения. Так и модель на тестовой выборке должна использовать найденные связи между признаками и ответом, а не воспроизводить запомненные строки.

Аналогия не означает, что модель понимает тему так же, как человек. Она лишь подчёркивает общий принцип проверки: тренировочные и проверочные примеры должны различаться.

Как данные делят на части

Датасет можно представить как стопку карточек. Часть карточек отдаём модели для обучения, а часть временно откладываем. После обучения показываем модели отложенные карточки и смотрим, насколько точно она отвечает.

Часто данные делят примерно так: 70% или 80% — для обучения, 30% или 20% — для проверки. Точные доли могут меняться, но смысл остаётся тем же: тестовые данные не должны участвовать в обучении.

Например, если в датасете 100 объектов и выбрано разделение 80% на 20%, то 80 объектов попадут в обучающую выборку, а 20 — в тестовую. Модель настраивается по первым 80 объектам, после чего для остальных 20 получает только признаки и должна предсказать ответы.

Разделение обычно выполняют так, чтобы обе части достаточно хорошо отражали данные исходной задачи. В задаче классификации сообщений важно, чтобы проверка не оказалась случайно составлена только из обычных сообщений или только из спама. Иначе результат будет описывать слишком узкий случай.

№	Сообщение	Класс	Часть данных
1	Получите подарок по ссылке	спам	обучение
2	Во сколько встречаемся?	обычное	обучение
3	Срочно подтвердите карту	спам	обучение
4	Завтра урок в 10:00	обычное	обучение
5	Скидка только сегодня	спам	обучение
6	Пришли домашнее задание	обычное	тест
7	Перейдите по ссылке для приза	спам	тест
8	Встреча перенесена на пятницу	обычное	тест

В таблице первые пять сообщений используются для обучения, а последние три — только для проверки. Хотя в обеих частях встречаются классы «спам» и «обычное», сами сообщения различаются. Поэтому ответы для строк 6–8 нельзя получить простым воспроизведением соответствующих обучающих строк.

Частая ошибка — считать, что тестовая выборка обязательно должна быть больше обучающей. Обычно модели требуется достаточно много примеров для поиска закономерностей, поэтому обучающая часть чаще оказывается больше. Однако единой обязательной доли для всех датасетов нет.

Почему тестовые данные нельзя показывать заранее

Тестовая выборка играет роль новых задач. Если модель заранее увидит правильные ответы из теста, проверка перестанет быть честной. Мы уже не поймём, научилась ли модель работать по признакам или просто запомнила строки.

Поэтому в машинном обучении тестовую часть обычно держат отдельно. Модель учится на обучающей части, а потом её проверяют на тестовой. Если ошибка на тестовых данных небольшая, модель, скорее всего, лучше готова к новым примерам.

Недостаточно скрыть от модели только названия правильных классов во время самой проверки. Тестовые объекты и ответы к ним не должны использоваться для обучения или подстройки модели заранее. Иначе информация из проверки косвенно повлияет на модель, а оценка может оказаться завышенной.

Также важно следить за повторяющимися объектами. Если одинаковое сообщение попало в обучение и в тест, для модели оно уже не является по-настоящему новым. Даже если строки имеют разные номера, такое совпадение делает проверку менее надёжной.

Важно: после получения предсказаний правильные ответы тестовой выборки открывают и сравнивают с ответами модели. Они нужны для оценки, но не для предварительного обучения модели.

Демонстрационный пример проверки

Модель обучалась на первых пяти сообщениях из таблицы. Затем она получила три новых сообщения и дала ответы. Этот пример нужен не как практическое задание, а как иллюстрация проверки на тестовой части.

Во время проверки для каждого сообщения сравниваются два значения: известный правильный класс и предсказание модели. Если значения одинаковы, ответ считается верным; если различаются — фиксируется ошибка.

Сообщение	Правильный класс	Ответ модели	Итог
Пришли домашнее задание	обычное	обычное	совпало
Перейдите по ссылке для приза	спам	обычное	ошибка
Встреча перенесена на пятницу	обычное	обычное	совпало

В этом примере два ответа из трёх совпали с правильными. Один ответ оказался неверным. Значит, даже на тестовой выборке модель может ошибаться, и эти ошибки нужно учитывать при оценке качества.

Долю правильных ответов здесь можно вычислить как отношение числа совпадений к общему числу проверенных сообщений: $2 / 3$, то есть примерно 67%. Доля ошибок равна $1 / 3$, то есть примерно 33%. Эти числа описывают результат именно на показанных трёх тестовых объектах.

Тестовая выборка в примере очень мала, поэтому по ней нельзя делать уверенный вывод о работе модели на всех возможных сообщениях. Одна дополнительная ошибка или один дополнительный правильный ответ заметно изменили бы итоговую долю. На большем и достаточно разнообразном наборе проверка обычно даёт более устойчивую оценку.

Мини-проверка: если бы модель ошиблась в двух сообщениях из трёх, число правильных ответов было бы равно одному, а доля правильных ответов составила бы $1 / 3$.

Переобучение простыми словами

Переобучение возникает, когда модель слишком хорошо подстроилась под тренировочные примеры. На знакомых строках она показывает высокий результат, но на новых объектах ошибается заметно чаще.

Признаком возможного переобучения может быть большой разрыв между результатами: например, почти все ответы на обучающей выборке верны, а на тестовой ошибок намного больше. Сам по себе высокий результат на обучении не является проблемой, но его недостаточно для вывода о качестве.

Причина такого разрыва состоит в том, что модель могла учесть особенности отдельных тренировочных объектов, которые не выражают общую закономерность. Тогда эти особенности помогают на знакомых данных, но не помогают распознавать новые сообщения.

Для 8–9 классов это можно понимать как «модель зазубрила примеры». Для 10–11 классов и СПО важно добавить: качество модели нельзя оценивать только по результату на обучении, потому что он может быть завышен.

Не каждую ошибку на тесте следует сразу называть переобучением. Модели могут ошибаться и по другим причинам, а отдельная ошибка ещё не показывает устойчивого разрыва между обучением и тестированием. Для вывода нужно сравнить результаты на обеих выборках.

Как интерпретировать проверку

Результат на обучающей выборке показывает, насколько хорошо модель справляется со знакомыми примерами. Результат на тестовой выборке показывает, насколько успешно она переносит найденную закономерность на новые объекты. Эти результаты отвечают на разные вопросы, поэтому полезно рассматривать их вместе.

- Высокий результат на обучении и высокий результат на тесте означают, что модель хорошо справилась и со знакомыми, и с новыми примерами из имеющихся данных.
- Высокий результат на обучении и заметно более низкий результат на тесте могут указывать на переобучение.
- Низкий результат и на обучении, и на тесте означает, что модель пока плохо справляется даже с доступными примерами.

При этом слово «высокий» всегда зависит от задачи и выбранного способа оценки. В рамках данного урока важен не конкретный порог, а сравнение качества на знакомых и новых данных.

Памятка

- Обучающая выборка — данные для тренировки модели.
- Тестовая выборка — новые данные для проверки модели.
- Тестовые данные нельзя заранее показывать модели.
- Один и тот же объект не должен одновременно использоваться и для обучения, и для тестирования.
- Обе части должны соответствовать задаче и содержать подходящие для неё примеры.
- Хороший результат на обучении ещё не означает хорошее качество модели.
- Честная проверка показывает, как модель работает на новых примерах.
- Переобучение — это ситуация, когда модель хорошо помнит тренировочные данные, но хуже обобщает.
- Ошибки на тесте нужно учитывать, а результат маленькой тестовой выборки интерпретировать осторожно.

Материалы к занятию

- Урок_3_3_Обучающая_и_тестовая_выборки_презентация_обновленная.pptx (125.3 КБ)