iSMART

Урок 3.3
Обучающая и тестовая выборки

Зачем данные делят на две части и почему модель проверяют на новых примерах

Теоретическое занятие · 2 академических часа

Главный вопрос урока

- Модель училась отличать спам от обычных сообщений.
- Потом её проверили на тех же самых сообщениях.
- Модель почти не ошиблась. Можно ли сразу сказать, что она хорошо работает?
- Проблема: модель могла понять закономерность, но могла и просто запомнить примеры.

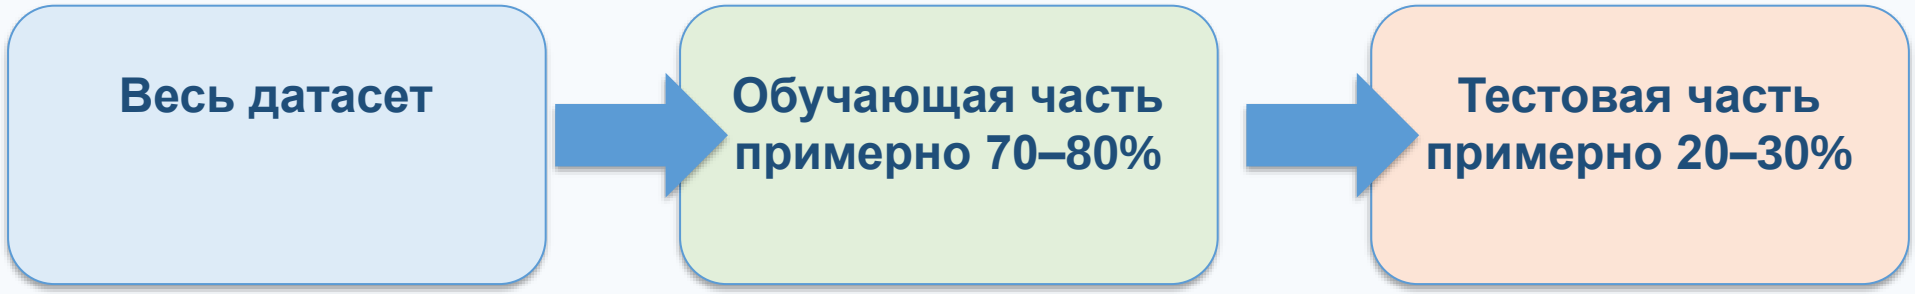
Обучающая выборка

- Это часть данных, на которой модель учится.
- Модель видит объекты, признаки и правильные ответы.
- На этих примерах она ищет связь между признаками и ответом.
- Аналогия: обучение похоже на тренировочные задачи.

Тестовая выборка

- Это часть данных, которую модель не видела во время обучения.
- Она нужна для проверки на новых примерах.
- На тесте можно честнее посчитать ошибку и оценить качество.
- Аналогия: контрольная должна содержать новые задачи.

Одна таблица превращается в две части



Главное: примеры для проверки отделяют от примеров для обучения.

Иначе результат может быть слишком хорошим, но нечестным.

Почему знакомые данные могут обмануть

- На обучении модель видит примеры и правильные ответы.
- Если снова дать те же строки, результат может быть слишком хорошим.
- Это не доказывает, что модель справится с новыми объектами.
- Честная проверка требует тестовых примеров.

Переобучение простыми словами

- Модель слишком хорошо подстроилась под тренировочные примеры.
- На обучающих данных ошибка маленькая.
- На новых данных ошибка заметно больше.
- Для 8–9 класса: модель как будто зазубрила ответы, но не научилась решать новые задачи.

Демонстрационный мини-кейс: сообщения

№	Сообщение	Класс	Часть
1	Получите подарок по ссылке	спам	обучение
2	Во сколько встречаемся?	обычное	обучение
3	Срочно подтвердите карту	спам	обучение
4	Завтра урок в 10:00	обычное	обучение
5	Скидка только сегодня	спам	обучение
6	Пришли домашнее задание	обычное	тест
7	Перейдите по ссылке для приза	спам	тест
8	Встреча перенесена на пятницу	обычное	тест

Как проверяют модель на тесте

- Модель получает новый пример.
- Она делает предсказание.
- Предсказание сравнивают с правильным ответом.
- Если ответ не совпал, это ошибка. Качество честнее оценивать на тестовой выборке.

Чем отличается глубина для разных групп

Группа	Акцент	Слова
8–9 класс	визуальное деление карточек	тренировка, проверка, новые примеры
10–11 класс	train/test, ошибка на тесте	обучающая выборка, тестовая выборка
СПО	качество модели, переобучение	обобщение, честная оценка, тестовые данные

Частые ошибки в понимании

- Если модель хорошо ответила на обучении, значит она точно хорошая.
- Тестовые данные можно показывать модели заранее.
- Достаточно проверить один пример.
- Обучающая и тестовая части ничем не отличаются.

Итог урока

- Обучающая выборка нужна, чтобы модель училась на примерах.
- Тестовая выборка нужна, чтобы проверить модель на новых данных.
- Проверка только на знакомых примерах может дать слишком хороший результат.
- Учить на train, проверять на test — честнее.

Текущий контроль: открытые вопросы

• Объясните своими словами, почему модель нельзя проверять только на тех данных, на которых она училась.

• Чем обучающая выборка отличается от тестовой? Приведите пример через аналогию с тренировкой и контрольной работой

Текущий контроль: тест 1

1. Для чего нужна обучающая выборка?

А. Чтобы модель училась на примерах и правильных ответах.

Б. Чтобы скрыть часть данных от преподавателя.

В. Чтобы удалить неправильные строки из таблицы.

Г. Чтобы заменить признаки случайными числами.

Текущий контроль: тест 2

2. Что показывает тестовая выборка?

А. Как модель работает только на знакомых строках.

Б. Как модель работает на новых примерах, которые не участвовали в обучении.

В. Сколько строк нужно удалить из датасета.

Г. Какие признаки надо обязательно переименовать.

Текущий контроль: тест 3

3. Что такое переобучение?

А. Модель плохо видит признаки и поэтому не запускается.

Б. Модель слишком хорошо подстроилась под обучающие данные и хуже работает на новых примерах.

В. Модель учится только на тестовых данных.

Г. Модель всегда даёт случайные ответы.

Ответы для преподавателя: 1 — А, 2 — Б, 3 — Б.