PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

> **Главная идея: тип задачи машинного обучения определяется тем, какой ответ должна дать модель: категорию, число или группу похожих объектов.**

1. Зачем различать типы задач

Содержание

- 2. Общая схема
- 3. Классификация: выбрать класс
- 4. Регрессия: предсказать число
- 5. Кластеризация: найти похожие объекты
- 6. Сравнение трёх типов задач
- 7. Один датасет — разные задачи
- 8. Как проверять результат
- 9. Частые ошибки
- 10. Памятка

На предыдущих уроках вы уже обсуждали, что модель получает признаки объекта и должна вернуть ответ. Теперь важно уточнить: ответы бывают разными. Иногда модель выбирает класс, иногда предсказывает число, а иногда ищет похожие объекты без заранее готовых классов.

От типа ответа зависит постановка задачи, подготовка данных и способ проверки качества. Поэтому перед любой задачей машинного обучения сначала задают вопрос: какой результат должна вернуть модель?

Если определить тип задачи неправильно, можно выбрать неподходящий способ обучения и получить результат, который невозможно корректно оценить. Например, прогноз точного балла и определение результата «сдал / не сдал» могут использовать похожие признаки, но требуют разных ответов модели.

Полезно сформулировать цель одним предложением с глаголом: «выбрать категорию», «предсказать значение» или «найти группы». Такая формулировка помогает отделить цель от темы датасета.

2. Общая схема

Работу модели можно представить как преобразование входных данных в результат. На вход поступают признаки, то есть измеримые или описываемые свойства объекта. На выходе появляется ответ, ради которого решается задача.

Что получает модель	Что делает модель	Какой ответ получается
признаки объекта	сравнивает, ищет закономерности	класс, число или группа похожих объектов

Например, для сообщения признаками могут быть слова, длина текста и наличие ссылки. Эти данные ещё не определяют тип задачи. Тип станет понятен из цели: выбрать метку «спам / обычное» означает решить задачу классификации, а объединить сообщения по сходству содержания — задачу кластеризации.

> **Подсказка: смотрите не только на тему данных, а именно на ожидаемый ответ модели.**
> Одинаковые признаки могут использоваться в разных задачах. Решающее значение имеет не формат исходной таблицы, а смысл её целевого результата.

3. Классификация: выбрать класс

Классификация — это задача, в которой модель относит объект к одному из заранее известных классов. Она отвечает на вопрос: «к какому типу относится объект?»
Класс — это отдельная категория из заданного набора возможных ответов. Если вариантов два, например «спам» и «обычное сообщение», классификация является бинарной. Если вариантов больше двух, например «оплата», «доставка» и «техника», модель выбирает один класс из нескольких.

Ситуация	Признаки	Ответ модели
Сообщение	текст, наличие ссылки, рекламные слова	спам / обычное

Ситуация	Признаки	Ответ модели
Обращение в поддержку	текст, срочность, тема запроса	оплата / доставка / техника
Изображение	визуальные признаки	кот / собака / птица
Отзыв	слова, тональность, оценки	положительный / нейтральный / отрицательный

В классификации правильный ответ обычно есть в обучающих данных. Затем предсказанный класс можно сравнить с правильной меткой на тестовой выборке.
Например, если правильная метка сообщения — «спам» и модель также выбрала «спам», ответ считается верным. Если модель выбрала «обычное», произошло ошибочное определение класса.

> **Обратите внимание: метки классов иногда записывают числами, например 0 и 1. Это не превращает задачу в регрессию.**
> Если числа служат только обозначениями категорий и над ними не требуется выполнять содержательные числовые действия, ответ модели остаётся классом.

4. Регрессия: предсказать число

Регрессия — это задача, в которой модель предсказывает числовое значение. Она отвечает на вопрос: «какое число получится?»
Числовой результат имеет измеримый смысл: это могут быть баллы, минуты, стоимость или количество объектов. В отличие от названия класса, такое значение можно сравнивать с другим числом по величине и вычислять разницу.

Ситуация	Признаки	Ответ модели
Прогноз балла за тест	время подготовки, попытки, прошлые результаты	число баллов
Прогноз времени доставки	расстояние, загруженность, погода	минуты
Прогноз цены товара	характеристики, бренд, состояние	цена
Прогноз количества обращений	день недели, акции, нагрузка	число обращений

Связь с прошлыми уроками простая: если модель предсказала число, можно посчитать ошибку между настоящим значением и ответом модели.

Например, настоящее время доставки составило 42 минуты, а модель предсказала 39 минут. Разница между настоящим и предсказанным значениями равна 3 минутам. Чем меньше такие ошибки на множестве тестовых примеров, тем точнее числовой прогноз.
При этом сам факт наличия чисел в данных ещё не означает регрессию. Возраст, число попыток и время подготовки могут быть входными признаками задачи классификации, если итоговый ответ — «сдал / не сдал».

5. Кластеризация: найти похожие объекты

Кластеризация — это задача, в которой модель ищет похожие объекты и объединяет их в группы. В отличие от классификации, готовых правильных классов обычно нет.
Такие группы называют кластерами. Объекты внутри одного кластера должны быть похожи по выбранным признакам, а объекты из разных кластеров — отличаться. Поэтому результат зависит от того, какие признаки использованы для определения сходства.

Ситуация	Что ищем	Что получается
Пользователи сервиса	похожее поведение	группы пользователей
Фильмы	похожие жанры, рейтинги, тематика	группы похожих фильмов
Товары	сходные характеристики	группы похожих товаров
Учебная платформа	похожие действия учеников	группы стилей работы

Например, учеников можно группировать по времени работы на платформе, числу выполненных заданий и количеству попыток. Модель не получает заранее заданных названий групп, а обнаруживает сходство в самих данных. После этого получившиеся кластеры можно анализировать и описывать.

> **Главное отличие: в классификации классы известны заранее, а в кластеризации модель сама ищет группы по сходству.**
> Номер кластера, например «кластер 1», является обозначением найденной группы, а не заранее известным правильным ответом.

6. Сравнение трёх типов задач

Чтобы различить типы задач, удобно последовательно проверить две вещи: существует ли заранее известный правильный ответ и какую форму имеет результат модели.

Тип задачи	Что делает модель	Какой ответ	Пример
Классификация	выбирает класс	категория	спам / не спам
Регрессия	предсказывает число	число	балл за тест
Кластеризация	ищет похожие объекты	группа	сегменты пользователей

Классификацию и регрессию объединяет наличие известных ответов в обучающих данных: меток классов или числовых значений. При кластеризации модель обычно работает без готового правильного распределения объектов по группам.

> **Мини-проверка: модель должна определить, относится ли отзыв к положительным, нейтральным или отрицательным. Это классификация, потому что результатом является одна из заранее заданных категорий.**

7. Один датасет — разные задачи

Один и тот же набор данных можно применять по-разному. Всё зависит от цели. Например, есть таблица о студентах: время подготовки, число попыток, активность на платформе, итоговый балл и результат.
Перед обучением выбирают, какие столбцы будут признаками, а какой результат нужно получить. Итоговый балл может быть целевым числом для регрессии, а результат «сдал / не сдал» — целевой меткой для классификации. Для кластеризации можно использовать признаки поведения и не задавать целевой столбец с готовыми группами.

Цель	Тип задачи
предсказать, сдаст студент или не сдаст	классификация
предсказать итоговый балл	регрессия
найти группы студентов с похожим поведением	кластеризация

Следовательно, название датасета не определяет задачу автоматически. Таблица «Данные о студентах» может применяться для всех трёх типов задач, если по-разному сформулированы цель и ожидаемый результат.

8. Как проверять результат

Способ оценки должен соответствовать форме ответа модели. Нельзя одинаково проверять категорию, числовой прогноз и найденную группу, потому что смысл ошибки в этих случаях различается.

- Классификация: сравниваем предсказанный класс с правильным. Проверку выполняют на объектах, правильные метки которых известны, но не использовались моделью для обучения.
- Регрессия: считаем размер ошибки между настоящим и предсказанным числом. Обычно рассматривают ошибки на множестве примеров, а не только один удачный прогноз.
- Кластеризация: оцениваем, насколько получившиеся группы имеют понятный смысл, насколько похожи объекты внутри групп и насколько различаются разные группы.

Для классификации и регрессии тестовые данные позволяют сопоставить предсказание с известным ответом. В кластеризации единственного заранее записанного правильного распределения обычно нет, поэтому результат требует анализа структуры и полезности найденных групп.

> **Важно: качество модели нельзя надёжно оценить только по тем данным, на которых она обучалась.**
> Проверка на отдельных тестовых примерах показывает, как модель работает с объектами, ответы для которых не использовались при обучении.

9. Частые ошибки

Ошибка	Как думать правильно
Смотреть на тему, а не на тип ответа	Сначала спросить: какой ответ должна вернуть модель?
Путать классификацию и кластеризацию	В классификации классы заданы заранее; в кластеризации группы ищутся.

Ошибка	Как думать правильно
Считать регрессию любым графиком	Регрессия — это прогноз числа, а не просто линия на графике.
Забывать про цель задачи	Один датасет может подходить для разных типов задач.

Ещё одна распространённая путаница возникает из-за числовой записи ответов. Если категории «не сдал» и «сдал» обозначены числами 0 и 1, модель всё равно выбирает класс. Если же она предсказывает итоговый балл, например 74, это регрессия, потому что число выражает величину.
Также не следует считать любую разбивку объектов на группы кластеризацией. Если названия групп и правильные примеры для них заданы до обучения, речь идёт о классификации. При кластеризации группы формируются на основе обнаруженного сходства.

10. Памятка

- Ответ — категория: классификация.
- Ответ — число: регрессия.
- Ответ — группа похожих объектов без готовых меток: кластеризация.
- Тип задачи выбирают по ожидаемому результату модели, а не только по теме данных.
- Один датасет может подойти для разных типов задач, если меняется цель.
- Числовое обозначение класса не превращает классификацию в регрессию.
- Способ проверки качества выбирают в соответствии с типом ответа.

> **Проверьте понимание:**
>
> 1. Определить, будет ли доставка своевременной или задержится, — классификация, потому что модель выбирает категорию.
> 2. Предсказать время доставки в минутах — регрессия, потому что модель возвращает число.
> 3. Объединить доставки в группы по расстоянию, времени и загруженности маршрута без готовых меток — кластеризация.
>
> Во всех трёх случаях тема данных одинакова, но тип задачи меняется вместе с ожидаемым ответом.

Материалы к занятию

- Урок_3_4_Типы_задач_машинного_обучения_презентация_обновленная.pptx (441.0 КБ)