МОДУЛЬ 3

# Классификация в Python - первые предсказания

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

# Цель урока

01 Показать, как в Python запустить готовую модель классификации, передать ей признаки и правильные ответы, а затем получить предсказание для нового объекта.

# Планируемые результаты

01 обучающийся объясняет, что такое классификация и чем признак отличается от целевой переменной.

02 запускает готовый шаблон с библиотекой Scikit-learn и определяет назначение основных этапов программы.

03 отделяет X и y , делит данные на обучающую и тестовую части.

04 объясняет, почему тестовые объекты не должны участвовать в обучении модели.

# Ключевые понятия

01 классификация — задача, в которой модель выбирает один из заранее заданных классов; например, сообщение может относиться к классу обычных сообщений или к классу спама.

02 объект — отдельный пример из набора данных, например одно сообщение.

03 признаки — характеристики объекта, по которым модель учится; в таблице они обычно занимают отдельные столбцы.

04 целевая переменная — правильный ответ, который модель должна предсказать; для каждого обучающего объекта этому ответу соответствует значение в столбце label.

# Проблемная ситуация

01 Представим, что у нас есть много коротких сообщений.

02 Сам текст сообщения модель из этого практикума напрямую не анализирует.

03 Например, у сообщения может быть большая длина, ссылка и слово про скидку, но не быть срочного призыва.

04 При этом один признак сам по себе не обязан однозначно определять ответ.

# Короткое объяснение темы (1/2)

01 В этом практикуме берётся маленький табличный датасет сообщений.

02 Затем признаки отделяются от целевой переменной: X — это признаки, y — правильные ответы.

03 После этого данные делятся на обучающую и тестовую части.

04 Загрузить таблицу и проверить её структуру.

# Короткое объяснение темы (2/2)

01 Обучение и предсказание — разные действия. fit() изменяет состояние модели, используя примеры и правильные ответы. predict() применяет уже найденные правила к переданным объектам и не заменяет этап обучения.

02 Маленький учебный датасет нужен для понимания последовательности действий, но по нескольким примерам нельзя делать вывод о надёжности классификатора в реальной задаче.

03 Определите роль каждого элемента: четыре характеристики сообщения, столбец label , метод fit() и метод predict() .

# Частые ошибки

01 в X случайно оставили столбец label . Тогда правильный ответ попадает во входные данные, и модель получает подсказку, которой не будет у настоящего нового объекта.

02 при создании нового примера нарушили порядок признаков. Даже если количество значений верное, каждое из них должно соответствовать тому же столбцу, что и при обучении.

03 передали в predict не четыре признака, а меньше. Число признаков нового объекта должно совпадать с числом столбцов в обучающем наборе X.

# Итог урока

01 После практикума обучающиеся получают первую рабочую связку: таблица признаков, простая модель Scikit-learn и предсказание для нового объекта.

02 На каждом этапе важно сохранять соответствие строк, столбцов и значений признаков.

# Краткая памятка

01 X — признаки, y — правильные ответы.

02 каждой строке в X должен соответствовать один ответ в y.

03 столбец label не должен оставаться среди входных признаков.

04 обучающая часть нужна для поиска закономерностей, а тестовая — для проверки на не использованных при обучении примерах.

# Материалы к практике

01 Ноутбук содержит рабочую последовательность действий, а CSV-файлы — данные для обучения и отдельные примеры для предсказания.

02 Проверьте точное имя файла, его расширение и папку, из которой запущен ноутбук.

# Практическая работа

01 Задание №1

02 Задание №2

03 Задание №3

# Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами