Урок 3.5

iSMART

Классификация в Python: первые предсказания

Практикум для 10–11 классов и СПО

от таблицы с признаками → к обученной модели → к новому предсказанию



Что должно получиться

- к концу занятия обучающийся запускает готовый шаблон классификации;
- понимает роль признаков и целевой переменной;
- обучает простую модель и получает первое предсказание для нового объекта.

1. Подготовить данные

увидеть признаки и правильные классы

2. Обучить модель

запустить шаблон Scikit-learn и передать модели обучающие примеры

3. Сделать прогноз

проверить новый пример сообщения

Главная идея: модель не «угадывает».
Она учится на примерах и потом переносит найденную закономерность на новый случай.

От ручного правила к модели

Раньше классификацию разбирали вручную; теперь те же шаги выполняет Python.

Ручное правило
если есть ссылка и слово «скидка», сообщение похоже на spam

Python-код
мы передаём таблицу признаков и правильные ответы

Модель
алгоритм учится связывать признаки с классами

Новый объект
получаем класс для сообщения, которого не было в обучении

Такой переход важен: одно правило удобно обсуждать на доске, но реальные данные быстро становятся больше и

Классификация: модель выбирает класс

Классификация — это задача, где ответом является категория, а не число.

Примеры: spam / normal / unclear, риск / нет риска, кот / собака, подходит / не подходит.

В практикуме мы берём маленький датасет сообщений: признаки легко объяснить, а результат быстро проверить глазами.

Объект	Признаки	Класс
Сообщение 1	длина, ссылка, скид	spam
Сообщение 2	длина, ссылка, скид	normal

Учебный датасет сообщений

Каждая строка — одно сообщение.

Столбцы — признаки, по которым модель отличает обычные сообщения от подозрительных.

label — целевая переменная, то есть правильный класс.

text_len
длина сообщения

has_link
есть ли ссылка

has_discount
есть ли слово про скидку

has_urgent
есть ли срочный призыв

label
правильный класс

Scikit-learn: готовые инструменты машинного обучения

Мы не пишем алгоритм с нуля — берём модель из библиотеки Pyth
шаблону.

Scikit-learn (sklearn) — библиотека Python с готовыми моделями и функциями для обучения.

В ней можно взять модель, передать ей признаки и правильные ответы, а затем получить предсказания для новых объектов.

Для первого запуска важно понять общую цепочку: данные → обучение → предсказание.

fit()

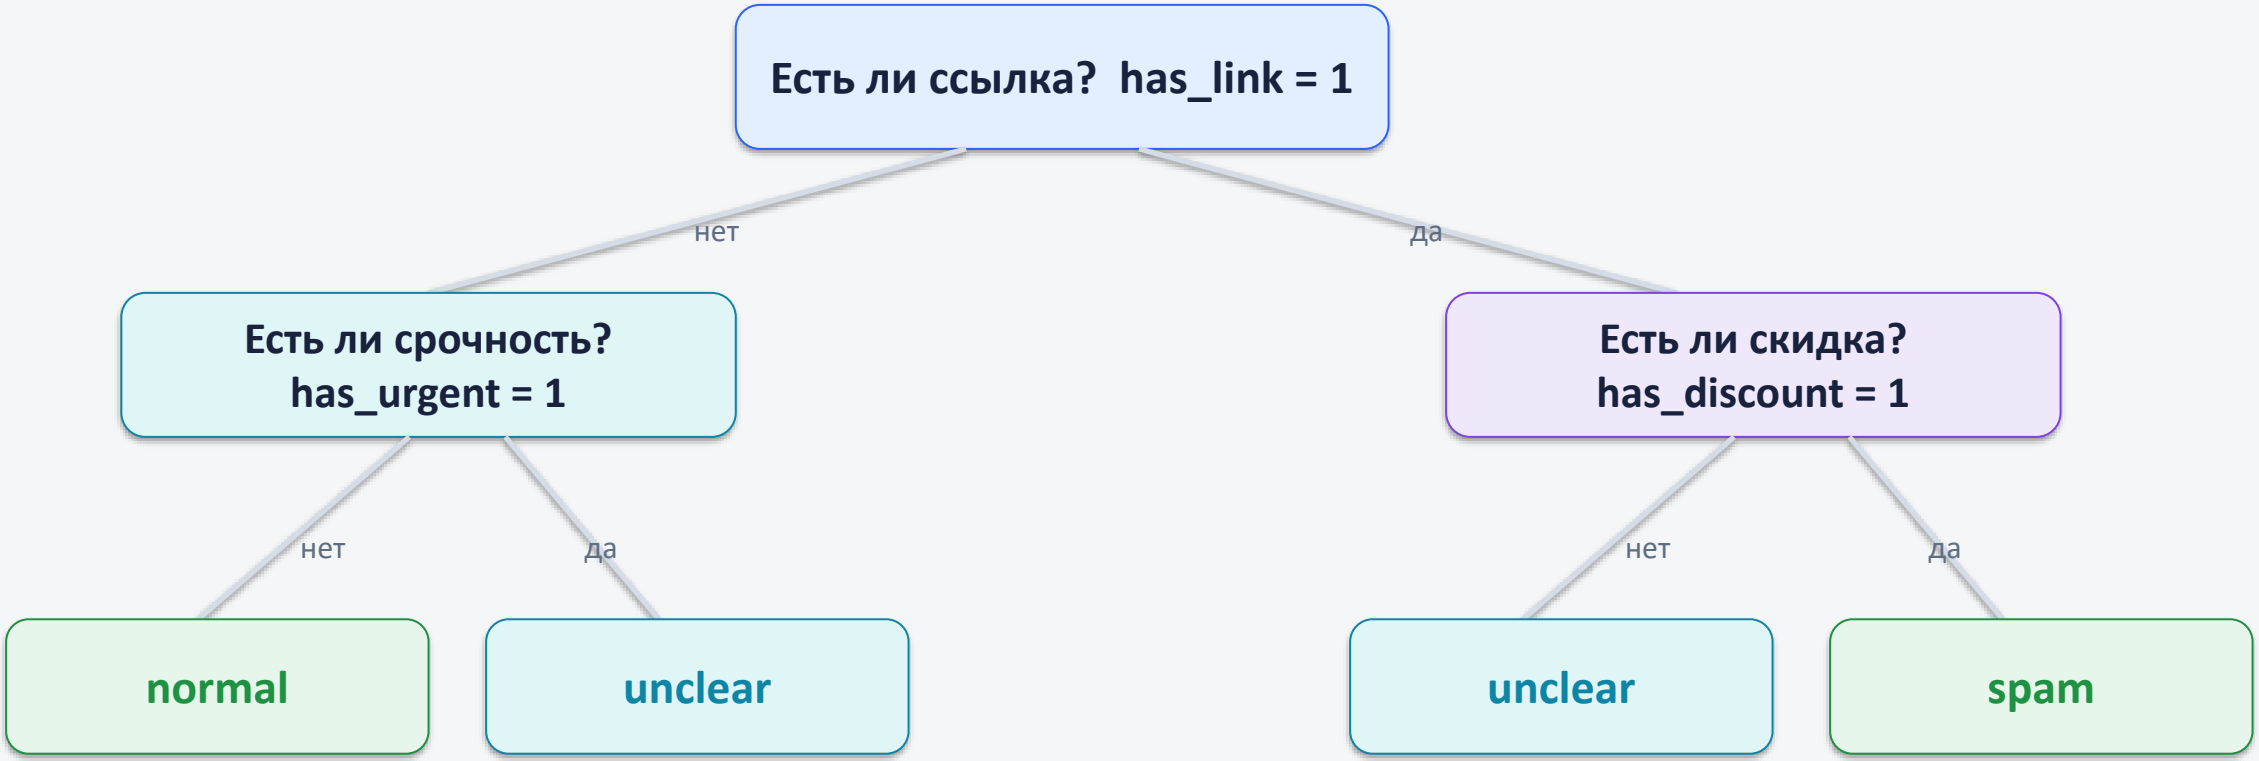
модель учится на примерах

predict()

модель выдаёт класс для нового объекта

Решающие деревья

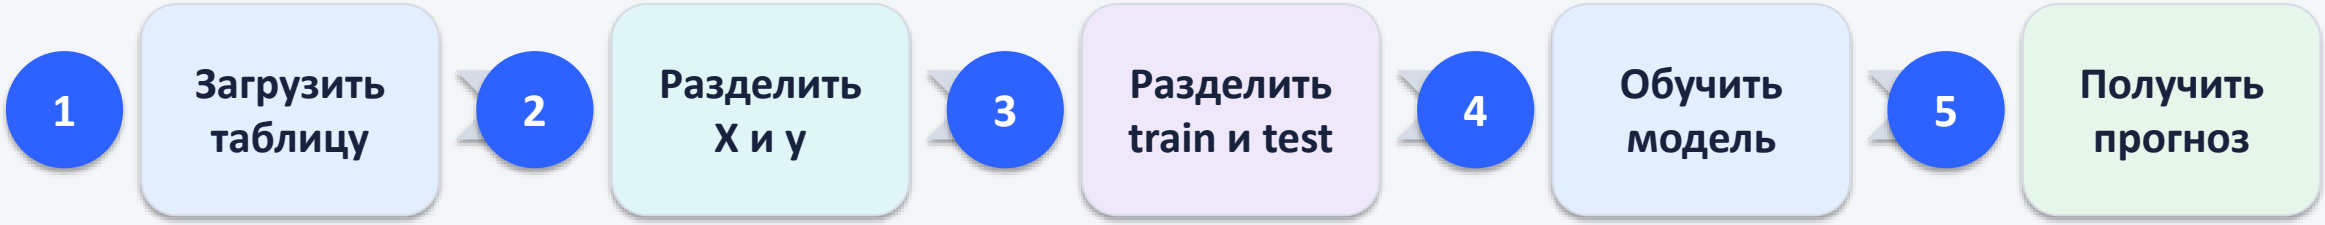
DecisionTreeClassifier строит цепочку проверок. На каждом шаге задаётся вопрос по одному признаку.



Это учебная схема. Реальное дерево может быть больше, но логика та же: вопрос → ветка → следующий вопрос → итоговый класс.

Цепочка работы модели

Код в ноутбуке идёт именно по этой схеме.



X — признаки объекта, y — правильный класс.
Это разделение надо проговаривать каждый раз: оно помогает не путаться в коде.

Шаг 1. Загружаем данные и отделяем признаки

```
import pandas as pd

df = pd.read_csv('messages_train.csv')

X = df[['text_len', 'has_link',
        'has_discount', 'has_urgent']]
y = df['label']

print(X.head())
print(y.head())
```

X содержит только признаки.

y содержит правильные ответы.

Модель не должна видеть столбец label среди признаков.

head() помогает быстро проверить таблицу.

Шаг 2. Делим данные и обучаем модель

```
from sklearn.model_selection import
train_test_split
from sklearn.tree import DecisionTreeClassifier

X_train, X_test, y_train, y_test =
train_test_split(
    X, y, test_size=0.25, random_state=42,
stratify=y
)

model = DecisionTreeClassifier(max_depth=3,
random_state=42)
model.fit(X_train, y_train)
```

train_test_split делит данные на две части: на одной модель учится, на другой её можно проверить на новых примерах.

DecisionTreeClassifier — удобная первая модель: её логику можно объяснить через цепочку вопросов.

fit() запускает обучение.

Шаг 3. Получаем первое предсказание

```
new_message = [[48, 1, 1, 1]]

prediction =
model.predict(new_message)
print(prediction[0])
```

48	1	1	1
длина	есть ссылка	есть скидка	срочно

predicted class: spam

Важно: порядок признаков в новом примере должен совпадать с порядком столбцов X. Иначе модель получит «перепута

После предсказания: что обсуждаем

- Не ограничиваемся одним числом или одной строкой вывода: смотрим, какие признаки были поданы на вход.
- Сравниваем несколько новых сообщений и обсуждаем, почему модель дала разные классы.
- Проверяем тестовую часть как набор новых примеров: где ответы совпали с ожидаемыми, а где нет.
- Делаем короткий вывод: какие признаки сильнее всего влияют на классификацию в этом учебном наборе.

Хороший вопрос

Почему сообщение со ссылкой и скидкой модель считает spam?

Ещё один вопрос

Что меняется, если убрать ссылку или срочность?

Практическая работа: уровни заданий

Уровень 1

Запустить ноутбук, загрузить CSV, отделить X и y, обучить модель и получить первое предсказание.

Уровень 2

Изменить несколько новых сообщений, сравнить прогнозы и объяснить, какие признаки повлияли на класс.

Уровень 3

Изменить глубину дерева или добавить признак, затем посмотреть, изменились ли прогнозы и что это даёт.

Для 10–11 классов и СПО доступны все три уровня.
Уровень 3 удобно давать как расширение тем, кто справился быстрее или уже уверенно работает в ноутбуке.

Типичные ошибки

Перепутали X и y

label попал в признаки или, наоборот, признаки попали в ответы

Новый пример короче

в predict передали не четыре признака, а два или три

Другой порядок признаков

модель ждёт text_len, has_link, has_discount, has_urgent

Запускают код не глядя

ячейка выполнилась, но результат никто не проверил

Полезная привычка: после каждой ячейки смотреть, что получилось.
Ошибку легче поймать сразу, чем искать её в конце ноутбука.

Что фиксируем в конце урока

X признаки объектов	**y** правильные классы	**fit()** обучение модели	**predict()** получение ответа	**tree** логика через последовательность вопросов

После практикума у обучающихся появляется первая рабочая связка: таблица признаков, готовая модель Scikit-learn и предсказание для нового объекта.

Разговор о метриках качества можно вынести на следующий урок.