PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Классификация на реальном датасете

Содержание

- Цель урока
- Планируемые результаты
- Датасет урока
- Проблемная ситуация
- Итог урока

На уроке 3.5 обучающиеся уже запускали готовую модель классификации на учебном датасете сообщений. Урок 3.6 делает следующий шаг: работа идёт с реальной табличной выборкой, где сначала нужно понять структуру данных, выделить признаки и только потом обучать модель. В готовом примере основные решения уже приняты заранее. При работе с отдельным CSV-файлом необходимо самостоятельно проверить, какие данные находятся в строках и столбцах, какие значения должна получать модель и какой столбец содержит правильные ответы. Поэтому анализ таблицы становится обязательной частью решения задачи, а не вспомогательным действием.

Цель урока

Сформировать практический навык запуска простой модели классификации на реальном табличном датасете: от чтения CSV-файла и подготовки признаков до получения предсказаний. Особое внимание уделяется правильной последовательности действий. Даже подходящий алгоритм не сможет корректно обучиться, если данные загружены неверно, целевая переменная попала в признаки или структура новых объектов отличается от структуры обучающей выборки.

Планируемые результаты

- обучающийся загружает реальный CSV-файл в pandas и просматривает его первые строки;
- объясняет, что в таблице является объектом, признаком и целевой переменной;
- проверяет размер таблицы, названия и типы столбцов, а также наличие пропущенных значений;
- отделяет признаки X от целевой переменной y;
- делит данные на обучающую и тестовую части и объясняет назначение каждой из них;
- обучает DecisionTreeClassifier и получает предсказания;
- сопоставляет предсказанные классы с правильными ответами для отдельных тестовых объектов;
- поясняет, почему у нового объекта должен быть тот же набор признаков.

Датасет урока

В практикуме используется классический датасет Iris. Каждая строка описывает один цветок ириса. В таблице есть четыре числовых признака: длина и ширина чашелистика, длина и ширина лепестка. Целевая переменная species показывает вид ириса: setosa, versicolor или virginica.
Таким образом, объектом классификации является отдельный цветок, а его описанием служит набор из четырёх измерений. Модель должна установить связь между этими измерениями и одним из трёх возможных классов. Название вида не является входным измерением: это ответ, который требуется научиться предсказывать.

Столбец	Смысл	Роль
sepal_length_cm	длина чашелистика, см	признак
sepal_width_cm	ширина чашелистика, см	признак
petal_length_cm	длина лепестка, см	признак
petal_width_cm	ширина лепестка, см	признак
species	вид ириса	целевая переменная

Четыре признака образуют описание одного объекта. Если в таблице 150 строк, это означает, что в ней записаны 150 объектов, но количество строк конкретного файла следует проверять командой shape, а не предполагать заранее.

> ✅ **Мини-проверка**
>
> Столбец petal_width_cm содержит измерение, поэтому относится к признакам. Столбец species содержит класс объекта, поэтому относится к целевой переменной.

Проблемная ситуация

Есть таблица с измерениями цветков. Человек может смотреть на отдельные строки и пытаться угадать вид по признакам, но при росте количества данных ручной подход быстро становится неудобным. Модель классификации должна научиться связывать измерения с видом цветка и затем применить эту закономерность к новым объектам.
Задача относится к классификации, потому что требуется выбрать один из заранее заданных классов, а не вычислить произвольное числовое значение. Во время обучения модели известны и измерения цветков, и их виды. Для нового цветка модели передаются только измерения, а вид становится результатом предсказания.
Важно различать найденную моделью закономерность и запоминание конкретных строк. Для проверки работы модели часть объектов заранее не используется при обучении: они образуют тестовую выборку и играют роль новых примеров.

Итог урока

К концу занятия обучающиеся должны пройти полный путь от реального CSV-файла до первых предсказаний модели классификации. Главный результат — не идеальная модель, а уверенное понимание цепочки: данные, признаки, целевая переменная, обучение, предсказание.
В этой цепочке каждый этап зависит от предыдущего. Сначала проверяется структура таблицы, затем формируются X и y, после этого данные разделяются на обучающую и тестовую части. Только затем модель обучается и применяется к объектам, которых не использовала в fit.
Итоговая проверка понимания: для нового цветка известны четыре измерения, но неизвестен species. Эти измерения образуют вход модели, а предсказанный вид становится результатом классификации. Если состав или смысл признаков изменится, использовать обученную модель без соответствующей подготовки данных нельзя.

Материалы к занятию

- lesson_3_6_classification_real_dataset_regenerated.pptx (127.4 КБ)