МОДУЛЬ 3

Регрессия в Scikit-learn

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Идея урока

01 Не во всех задачах достаточно выбрать один вариант из нескольких классов.

02 В классификации модель выбирает класс, например friend / enemy или setosa / virginica.

03 Предсказание модели необходимо проверять на данных, которые не использовались при обучении.

Кейс урока

01 ИИ должен предсказать новый результат игрока по двум признакам: времени тренировки и прошлому результату.

02 Каждая строка таблицы описывает один пример: значения training_minutes и previous_score используются как входные данные, а score содержит правильный ответ для этого примера.

03 Например, для игрока с определённым временем тренировки и прошлым результатом модель может спрогнозировать 71.3 очка.

Ключевые понятия

01 регрессия — задача машинного обучения, где модель предсказывает числовое значение.

02 признаки — данные, по которым модель строит прогноз; в этом кейсе признаками являются training_minutes и previous_score.

03 целевая переменная — число, которое нужно предсказать; здесь это столбец score.

04 LinearRegression — простая регрессионная модель из Scikit-learn, которая описывает зависимость целевого значения от признаков с помощью линейной функции.

Классификация и регрессия

Тип задачи	Ответ модели	Пример
Классификация	класс	enemy, friend, setosa
Регрессия	число	72 очка, 18 минут, 4500 рублей

Основная цепочка работы

01 Работа с регрессионной моделью состоит из последовательных этапов.

02 загрузить таблицу и убедиться, что нужные столбцы доступны.

03 выделить признаки X и числовой результат y.

04 разделить данные на обучающую и тестовую части.

Фрагменты кода

```
import pandas as pd
df = pd.read_csv('game_scores_regression.csv')
X = df[['training_minutes', 'previous_score']]
y = df['score']
```

Сначала библиотека pandas загружает CSV-файл в DataFrame.

Как понимать ошибку

01 Обычная разница может быть положительной или отрицательной: модель способна как завысить, так и занизить результат.

02 Если фактический результат равен 74, а прогноз модели равен 71, абсолютная ошибка равна 3 очкам.

03 Если средняя абсолютная ошибка равна 4.2, это означает, что модель в среднем ошибается примерно на 4.2 очка.

04 MAE рассчитывается по всем проверяемым примерам: сначала для каждого прогноза находят абсолютную ошибку, затем складывают полученные значения и делят сумму на количество примеров.

Почему прогноз не обязан совпадать с фактом

01 Модель видит только признаки, которые мы ей передали.

02 Кроме того, LinearRegression ищет линейную зависимость.

03 Наличие ошибки само по себе не означает, что код работает неправильно.

Итог

01 К концу занятия обучающиеся должны объяснять, что в регрессии модель предсказывает число, а качество прогноза проверяется через ошибку между фактическим и предсказанным значением.

02 Также необходимо уметь выделять X и y, разделять таблицу на обучающую и тестовую части, обучать LinearRegression, получать predictions и интерпретировать абсолютную ошибку и MAE в единицах целевой переменной.

03 Для проверки понимания можно определить тип следующих задач: предсказать количество очков игрока, выбрать жанр игры и оценить время прохождения уровня.

Практическое задание. Урок 3.9 «Регрессия в Scikit-learn»

01 Работа выполняется в Jupyter Notebook по готовому шаблону.

02 Примеры: game_scores_regression.csv - основной датасет, game_scores_new_players.csv - новые игроки для прогноза, lesson_3_9_regression_sklearn.ipynb - ноутбук с шаблоном.

Практическая работа

01 Задание №1

02 Задание №2

03 Задание №3

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами