Урок 3.9

iSMART

Регрессия в Scikit-learn

Практикум для 10–11 классов и СПО

обучение модели → прогноз → сравнение с фактом → ошибка

таблица игроков

LinearRegression

предсказание числа

ошибка прогноза

В этом уроке модель впервые оценивается не по совпадению класса, а по расстоянию между двумя числами.

Классификация и регрессия

Классификация

модель отвечает классом:

enemy, friend, setosa, virginica

Регрессия

модель отвечает числом:

72 очка, 18 минут, 4500 рублей

Проверка тоже меняется: в классификации мы спрашивали «совпал ли класс?», а в регрессии спрашиваем «насколько число отличается от факта?»

Кейс урока: прогноз результата игрока

- ИИ получает данные о прошлых игроках.
- По времени тренировки и прошлому результату он прогнозирует новый score.
- Ответ модели — число, а не класс.
- Прогноз может быть близким, но не обязан совпадать точно.

training_minutes

сколько минут игрок тренировался

previous_score

какой результат был раньше

score

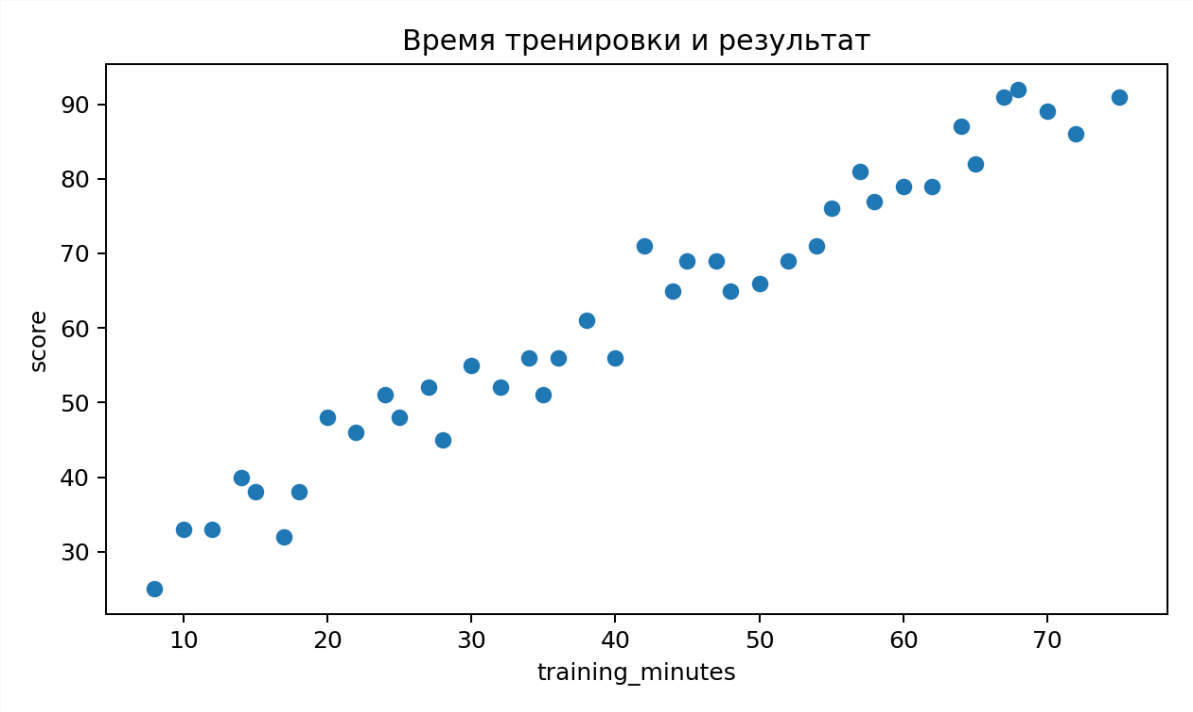
число, которое модель должна предсказать

Смотрим на таблицу данных

player_id	training_minutes	previous_score	score
1	8	26	25
2	10	32	33
3	12	32	33
4	14	30	40
5	15	31	38
6	17	31	32

Строка — один игрок. Признаки — training_minutes и previous_score. Целевой результат — score.

График: один признак и результат



Ось X — время тренировки.

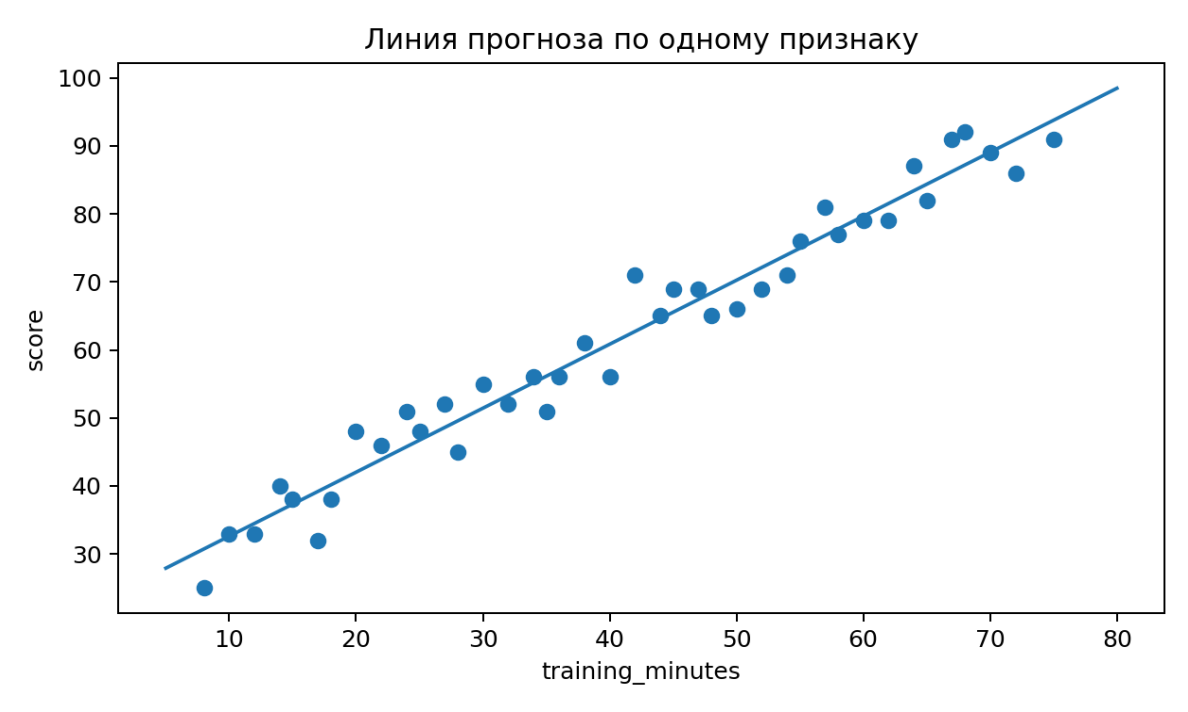
Ось Y — результат игрока.

Точки не лежат идеально ровно.

Но видно общее направление: чаще больше тренировки — выше результат.

График нужен для понимания. Модель дальше сможет учитывать не один, а два признака.

Линия прогноза простыми словами



Точки — реальные данные.

Линия — общая закономерность.

Новая точка на линии — примерный прогноз.

Линия не обязана проходить через каждую точку.

Шаг 1. Готовим X и y

```
import pandas as pd

df = pd.read_csv('game_scores_regression.csv')

X = df[['training_minutes', 'previous_score']]
y = df['score']
```

X

признаки, которые модель получает на вход

y

число, которое модель должна предсказать

Важно: score нельзя оставлять в X, потому что это ответ, а не входной признак.

Шаг 2. Делим данные на train и test

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42
)
```

train

на этой части модель учится

test

на этой части проверяем прогнозы

Шаг 3. Обучаем LinearRegression

```
from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X_train, y_train)
```

- LinearRegression ищет связь между признаками и числовым результатом.
- fit() запускает обучение на известных примерах.
- На этом уроке не выводим формулу модели — работаем с практической цепочкой.

Шаг 4. Получаем предсказания

```
predictions = model.predict(X_test)

result = X_test.copy()
result['real_score'] = y_test.values
result['predicted_score'] = predictions.round(1)
result['error'] = abs(
    result['real_score'] - result['predicted_score']
)

result.head(10)
```

real_score — фактический результат.

predicted_score — прогноз модели.

error — величина ошибки.

abs() нужен, чтобы ошибка не была отрицательной.

Что значит ошибка прогноза

Факт
74 очка

Прогноз
71 очко

Ошибка
3 очка

Ошибка измеряется в тех же единицах, что и целевая переменная.

Если score измеряется в очках, MAE тоже измеряется в очках.

Средняя абсолютная ошибка

```
mean_error = result['error'].mean()
print(mean_error)

from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(y_test, predictions)
print(mae)
```

- Сначала считаем среднюю ошибку через pandas.
- Потом проверяем через готовую функцию sklearn.
- MAE показывает, на сколько единиц модель обычно ошибается.

Прогноз для нового игрока

```
new_player = pd.DataFrame({
    'training_minutes': [35],
    'previous_score': [60]
})

model.predict(new_player)
```

Правило

у нового объекта должны быть те же признаки, что были в X

Вопрос для анализа

как меняется прогноз, если увеличить время тренировки или прошлый результат?

Практическая работа: уровни

Уровень 1

обучить LinearRegression, получить предсказания, создать error и посчитать среднюю ошибку

Уровень 2

сравнить модель по одному признаку и модель по двум признакам

Уровень 3

для СПО: найти большие ошибки или сравнить LinearRegression с DecisionTreeRegressor

Главный вывод должен быть не только числовым: нужно объяснить, почему один набор признаков или одна модель дала меньшую ошибку.

Типичные ошибки

score попал в X
модель получила ответ среди признаков

ошибка со знаком
забыли abs() и получили отрицательные значения

MAE приняли за процент
это ошибка в очках, а не доля

новый объект не совпал по столбцам
predict получил другой набор признаков

После каждой ячейки смотрим на результат: ошибка в данных часто видна раньше, чем ошибка в модели.

Что фиксируем в конце урока

регрессия
модель предсказывает число

LinearRegression
простая модель из sklearn

error
расхождение факта и прогноза

MAE
средняя абсолютная ошибка

Смысловой финал: в классификации мы проверяли, совпал ли класс; в регрессии смотрим, насколько число прогноза отличается от фактического значения.