Урок 3.10

iSMART

Ошибка регрессии: насколько модель промахнулась

Факт
настоящее значение

Прогноз
ответ модели

Ошибка
расстояние между числами

Практикум для 8–9, 10–11 классов и СПО

Главная задача урока: научиться измерять и объяснять промах модели в задаче регрессии.

Регрессия: модель предсказывает число

Классификация

модель отвечает классом: enemy / friend, setosa / virginica, подходит / не подходит

Регрессия

модель отвечает числом: 72 очка, 18 минут, 4500 рублей

В классификации мы проверяли совпадение класса. В регрессии сравниваем два числа: факт и прогноз.

Факт и прогноз

Факт: 80
реальный результат игрока

Прогноз: 79
модель почти попала

Ошибка: 1
маленький промах

Факт: 80
реальный результат игрока

Прогноз: 45
модель сильно промахнулась

Ошибка: 35
большой промах

Абсолютная ошибка простыми словами

Ошибка = расстояние между фактом и прогнозом

берём разницу без минуса

74
факт

70
прогноз

4
ошибка

74
факт

78
прогноз

В обоих случаях модель промахнулась на 4 очка.

Таблица ошибок

Игрок	Факт	Прогноз	Ошибка
1	36	33	3
2	42	44	2
3	49	45	4
4	57	60	3
5	64	59	5

Сначала считаем ошибку по каждой строке.

Потом ищем самый точный прогноз.

Затем ищем самый большой промах.

Самый точный прогноз и самый большой промах

Самый точный прогноз

там, где ошибка меньше всего. Например, ошибка 1 очко.

Самый большой промах

там, где ошибка больше всего. Например, ошибка 35 очков.

Важно смотреть не только среднее число, но и отдельные строки: иногда одна ошибка заметно выбивается из общей ка

Средняя ошибка

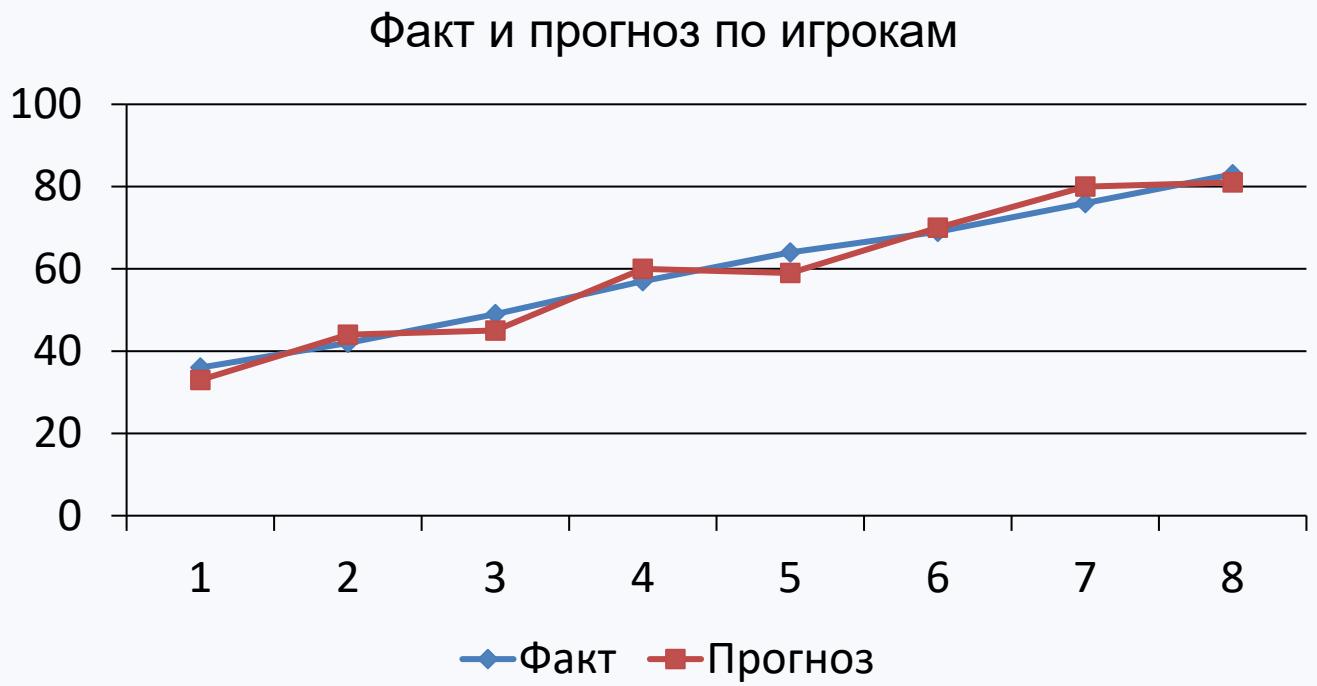
Ошибки: 3, 2, 4, 3
несколько промахов модели

3 + 2 + 4 + 3
складываем

12 / 4 = 3
делим на число строк

Средняя ошибка = 3 очка
модель обычно промахивается примерно на 3 очка

Визуальное сравнение факта и прогноза



Если линии близко - ошибка маленькая.

Если линии расходятся - промах больше.

График помогает быстро увидеть проблемные строки.

Расчёт ошибки в Python

```
import pandas as pd

df = pd.read_csv('regression_predictions_basic.csv')

df['error'] = abs(df['real_score'] - df['predicted_score'])

mean_error = df['error'].mean()

print(mean_error)
```

- abs() убирает знак минус.
- mean() считает среднее значение.
- Результат измеряется в очках, а не в процентах.

MAE: готовая метрика из sklearn

```
from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(
    df['real_score'],
    df['predicted_score']
)

print(mae)
```

MAE

средняя абсолютная ошибка: на сколько единиц модель обычно промахивается

Сначала полезно посчитать ошибку руками или через pandas, а потом показать готовую функцию.

Уровень 3: сравниваем две модели

```
two = pd.read_csv('regression_predictions_two_models.csv')

two['error_A'] = abs(two['real_score'] - two['model_A_prediction'])
two['error_B'] = abs(two['real_score'] - two['model_B_prediction'])

print(two['error_A'].mean())
print(two['error_B'].mean())
```

- Какая модель ошибается меньше в среднем?
- Есть ли у неё отдельные крупные промахи?
- Почему одного среднего числа не всегда достаточно?

Практика по уровням

Уровень 1
ручной расчёт абсолютной ошибки по таблице

Уровень 2
средняя ошибка и чтение графика факта и прогноза

Уровень 3
расчёт ошибки в Python и сравнение двух моделей

8–9 классы работают с уровнями 1–2. Для 10–11 классов и СПО добавляется уровень 3.

Типичные ошибки

Оставляют отрицательные ошибки.

Путают абсолютную и среднюю ошибку.

Думают, что средняя ошибка - это процент.

Делают вывод по одной строке.

Как исправлять

после расчёта всегда задаём вопрос: “на сколько очков модель обычно промахивается?”

Что фиксируем в конце урока

Факт
реальное число

Прогноз
ответ модели

Ошибка
промах по строке

Средняя ошибка
обычный промах модели

Итог: в регрессии мы не проверяем совпадение класса, а измеряем расстояние между фактом и прогнозом.