iSMART

Кластеризация в Python

Практикум для 10–11 классов и СПО: KMeans, визуализация групп, интерпретация результата

Данные
игровые персонажи и их признаки

Алгоритм
KMeans ищет похожие объекты

Карта
точки раскрашиваются по группам

Вывод
что означают кластеры?

Главная мысль: Python может найти группы, но смысл этих групп объясняет человек.

Что ищем в кластеризации

Классификация

есть правильные классы y: friend, enemy, setosa...

Регрессия

есть правильное число y: score, цена, время...

Кластеризация

готового y нет: группы нужно найти по признакам

Кластер — группа объектов, которые похожи по выбранным признакам. В этом уроке признаки будут числовыми.

Датасет персонажей

character	speed	power	defense
Rys	9	3	4
Grom	2	9	8
Klinok	6	7	5
Medik	4	4	8
Ten	10	2	3
Strazh	3	8	9

Строка

один игровой персонаж

Признаки

speed, power, defense

Готовых групп нет

алгоритм найдёт их сам

Карта признаков до кластеризации

Сначала смотрим на точки без цветов. Так проще увидеть возможные группы глазами.



X-ось: скорость персонажа

Y-ось: сила персонажа

точка: один персонаж

близкие точки похожи по признакам

На этом шаге алгоритм ещё не запускался. Мы только рассматриваем данные.

KMeans простыми словами

n_clusters

сколько групп мы просим найти

fit_predict()

запускает алгоритм и возвращает номер группы

cluster

новый столбец с номерами групп

Важно: номер кластера — это не название. Кластер 0 не значит «лучший», а кластер 1 не значит «второй по качеству».

Подготовка данных для KMeans

```
import pandas as pd
from sklearn.cluster import KMeans

df = pd.read_csv('game_characters_sklearn.csv')

X = df[['speed', 'power']]

X.head()
```

Здесь нет y

в кластеризации нет правильного класса для обучения

X

таблица признаков, по которым ищем сходство

Запуск алгоритма

```
model = KMeans(
    n_clusters=3,
    random_state=42,
    n_init=10
)

df['cluster'] = model.fit_predict(X)

df.head()
```

Что получилось?

в таблице появился столбец cluster

Как читать?

каждый персонаж получил номер группы: 0, 1 или 2

Визуализация найденных групп




```
sns.scatterplot(
    data=df,
    x='speed',
    y='power',
    hue='cluster'
)

plt.show()
```

Цвет показывает, к какому кластеру алгоритм отнёс объект.

Номера кластеров нужно объяснить

cluster 0

может оказаться группой быстрых персонажей

cluster 1

может быть группой сильных персонажей

cluster 2

может быть группой сбалансированных

Алгоритм не знает слов «быстрые» или «сильные». Он выдаёт только номера. Название кластера появляется после анализа признаков.

Средние значения помогают понять группы

```
df.groupby('cluster')[['speed', 'power', 'defense']]
  .mean()
  .round(1)
```

cluster	speed	power	defense
0	9.0	3.5	3.5
1	2.8	8.6	8.8
2	5.8	6.0	6.2

- если speed высокий, а power ниже — группа похожа на быстрых персонажей
- если power и defense высокие — это могут быть сильные защитники
- если значения средние — группа может быть сбалансированной

Что будет, если изменить число кластеров?

n_clusters = 2

крупные группы, проще, но грубее

n_clusters = 3

часто хорошо читается по смыслу

n_clusters = 4

детальнее, но может быть труднее объяснить

```
for k in [2, 3, 4]:
    model_k = KMeans(n_clusters=k, random_state=42, n_init=10)
    df[f'cluster_{k}'] = model_k.fit_predict(X)
```

Расширение для СПО: третий признак

```
X = df[['speed', 'power', 'defense']]

model = KMeans(n_clusters=3, random_state=42, n_init=10)

df['cluster_3_features'] = model.fit_predict(X)
```

Что меняется?

алгоритм учитывает защиту, даже если на графике видны только speed и power

Что проверить?

изменились ли группы и стало ли объяснение понятнее

Практическая работа: уровни

Уровень 1

загрузить датасет, выбрать speed и power, запустить KMeans, построить карту кластеров

Уровень 2

посчитать средние значения по кластерам и дать группам смысловые названия

Уровень 3

сравнить 2, 3 и 4 кластера; для СПО добавить defense

В отчёте важен не только график, но и объяснение: какие признаки объединяют объекты внутри группы.

Что фиксируем в конце урока

нет y
готовых групп заранее нет

X
признаки объектов

KMeans
ищет похожие точки

cluster
номер найденной группы

вывод
смысл групп через признаки

Итог: обучающиеся умеют запустить KMeans, визуализировать группы и объяснить, почему объекты попали в один кластер.