МОДУЛЬ 3

Переобучение и проверка модели на новых данных

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Вступление

01 Представьте ученика, который выучил ответы на тренировочный вариант, но не понял способ решения.

02 Главная трудность состоит в том, что качество на данных, уже использованных при обучении, может создавать ложное ощущение успеха.

03 Основной вопрос занятия

04 Насколько хорошо модель решает задачу на объектах, которые не участвовали в её обучении?

1. Обучающая и тестовая выборки

01 Обучающая выборка используется для настройки модели: алгоритм ищет закономерности между признаками X и правильными ответами y .

02 При разделении исходного набора признаки и ответы должны оставаться согласованными: строке X_train соответствует ответ из y_train , а строке X_test — ответ из y_test .

03 Если тестовые объекты или их правильные ответы повлияли на обучение, оценка перестаёт быть независимой.

04 Тестовая выборка предназначена для проверки, а не для настройки модели.

2. Что такое переобучение

01 Переобучение — ситуация, когда модель слишком точно подстроилась под обучающие примеры, включая случайный шум и единичные особенности.

02 Для дерева решений риск переобучения обычно возрастает при чрезмерном усложнении структуры.

03 Однако высокая обучающая точность сама по себе ещё не доказывает переобучение.

3. Как заметить переобучение · таблица 1/2

Наблюдение	Возможная интерпретация
Высокое качество на train и заметно более низкое на test	Есть признаки переобучения
Низкое качество и на train , и на test	Модель может быть слишком простой или данные недостаточно информативны

3. Как заметить переобучение · таблица 2/2

Наблюдение	Возможная интерпретация
Сопоставимое приемлемое качество на train и test	Явных признаков переобучения нет

4. Решённый мини-пример

01 Модель получила accuracy 0,98 на обучающей выборке и 0,71 на тестовой.

02 Для сравнения рассмотрим другой результат: train accuracy = 0,84 , test accuracy = 0,81 .

03 Если train accuracy = 0,63 , а test accuracy = 0,61 , можно ли назвать модель качественной только потому, что разрыв равен 0,02?

1. Установка библиотек

01 Библиотека scikit-learn потребуется для создания данных, разделения выборки, обучения дерева решений и вычисления метрики. pandas удобно использовать для оформления результатов, а matplotlib — для построения графиков.

02 Фиксированное значение random_state позволяет повторно получить одинаковую генерацию и одинаковое случайное разделение данных.

2. Импорт инструментов

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score
```

После выполнения ячейки импортированные инструменты становятся доступны в следующих ячейках блокнота.

3. Учебный набор данных

```
X, y = make_classification(
n_samples=600,
n_features=20,
n_informative=5,
n_redundant=5,
n_repeated=0,
n_classes=2,
flip_y=0.12,
class_sep=0.8,
random_state=42,
)
```

Мы создадим синтетический набор для бинарной классификации.

4. Честное разделение данных

```
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.30,
    random_state=42,
    stratify=y,
)
```

Разделите набор до обучения любой модели.

Чек-лист самопроверки

01 ☐ Я использовал одну и ту же разбивку данных для сравниваемых моделей.

02 ☐ Я обучал модели только на X_train и y_train.

03 ☐ Я посчитал accuracy отдельно для train и test.

04 ☐ Я вычислил разрыв train_accuracy − test_accuracy.

Что сдавать

Ключевая мысль урока Качество модели оценивают не по тому, насколько хорошо она запомнила обучение, а по тому, насколько надёжно она работает на новых данных.

Практическая работа

01 Задание №1. Разделите данные и проверьте выборки

02 Задание №2. Обучите ограниченное дерево решений

03 Задание №3. Обучите дерево без ограничения глубины

04 Задание №4. Напишите функцию диагностики

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами