PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

1. Паспорт занятия

Практическое занятие по классификации изображений и оценке качества модели машинного обучения.

Содержание

- 2. Планируемые результаты
- 3. Что понадобится
- 6. Вступление
- 7. Теоретический минимум
- 8. Готовый шаблон
- 9. Практические задачи
- 10. Дополнительные задания
- 11. Итоговый контроль
- 12. Критерии оценивания
- 13. Чек-лист самопроверки
- 14. Итоги урока
- 15. Мини-глоссарий
- 16. Источники и справочные материалы

На занятии используется небольшой стандартный набор изображений рукописных цифр. Он позволяет пройти полный цикл работы с классификатором: изучить данные, разделить их на обучающую и тестовую части, получить прогнозы и проверить, какие ответы модели оказались правильными, а какие — ошибочными.

Параметр	Содержание
Цель	Запустить готовый шаблон классификации изображений и научиться обоснованно оценивать качество его работы.

Параметр	Содержание
Практический результат	Обученная модель KNN, метрики качества, матрица ошибок, анализ ошибочных изображений и вывод о выборе параметра `k`.
Форма работы	Индивидуально или в парах за компьютером.
Программная среда	Google Colab или Jupyter Notebook с Python, NumPy, Matplotlib и scikit-learn.
Итоговый продукт	Заполненный отчёт по пяти задачам и сохранённая рабочая тетрадь/ноутбук.

2. Планируемые результаты

После занятия вы сможете:

- объяснять, как изображение превращается в числовой набор признаков;
- различать признаки `X` и целевую переменную `y`;
- разделять данные на обучающую и тестовую части без утечки данных;
- обучать готовый классификатор K ближайших соседей;
- рассчитывать accuracy и читать матрицу ошибок;
- находить классы и отдельные изображения, на которых модель ошибается чаще;
- сравнивать варианты модели и формулировать вывод о качестве классификации.

Результат считается осмысленным, если он подтверждён числами. Например, недостаточно написать «модель работает хорошо»: необходимо указать accuracy, количество ошибок и классы, которые модель путает.

> **Главная идея.** Высокая точность — это только начало анализа. Важно понять, какие классы модель путает, сколько ошибок она делает и почему выбранный вариант модели можно считать приемлемым.

3. Что понадобится

- компьютер с доступом к Google Colab либо установленным Jupyter Notebook;

- браузер; интернет нужен только для открытия Colab, сам набор digits загружается из библиотеки scikit-learn;
- рабочий файл занятия или новый блокнот;
- внимательность при копировании имён переменных: `X` — признаки, `y` — правильные классы.

Перед началом работы убедитесь, что ячейка с импортом библиотек выполняется без сообщений об ошибке. Если блокнот был перезапущен, ячейки необходимо снова выполнить сверху вниз: значения переменных хранятся в памяти только в течение текущего сеанса.

> **Локальный запуск.** Если библиотек нет, выполните в терминале: `pip install scikit-learn matplotlib numpy`. В Google Colab эти библиотеки обычно уже доступны.

> **Обратите внимание.** Python различает регистр символов. Переменные `X` и `x` считаются разными, как и `X_train` и `x_train`.

6. Вступление

Представьте сервис, который должен распознать цифру на фотографии почтового индекса или в отсканированном бланке. На вход поступает изображение, а на выходе требуется один класс — цифра от 0 до 9. Сегодня вы не будете создавать сложную нейронную сеть с нуля. Вместо этого вы запустите готовый, воспроизводимый шаблон машинного обучения и сосредоточитесь на главном: как проверить, хорошо ли модель классифицирует изображения и где именно она ошибается.

Для человека цифра воспринимается как целостный образ, но алгоритму необходимо представить её в числовом виде. Поэтому путь от изображения к ответу включает несколько последовательных этапов: подготовку признаков, обучение на примерах с известными ответами, получение прогнозов и независимую проверку качества.

Проверка на тех же изображениях, которые использовались при обучении, не показывает, насколько хорошо модель распознаёт новые объекты. Для честной оценки часть примеров заранее откладывают и не используют при обучении.

Рисунок 1. Последовательность работы от данных до оценки качества

7. Теоретический минимум

7.1. Изображение как данные

Компьютер получает не «картинку цифры», а таблицу чисел. В наборе digits каждое изображение чёрно-белое и имеет размер 8 × 8 пикселей. Каждый пиксель задаётся числом яркости от 0 до 16. Чтобы передать изображение обычному классификатору, таблицу 8 × 8 разворачивают в строку из 64 признаков.
Положение значения в строке сохраняет положение соответствующего пикселя на исходном изображении. Например, первый признак относится к первому пикселю, а последний — к последнему. При разворачивании меняется форма хранения данных, но сами значения яркости не изменяются.
Одна строка таблицы `X` описывает один объект, а один элемент массива `y` содержит правильный класс этого объекта. Поэтому количество строк в `X` должно совпадать с количеством элементов в `y`.
Рисунок 2. Преобразование изображения в вектор признаков

> **Не путайте.** `digits.images` хранит изображения формы `(1797, 8, 8)`, а `digits.data` — те же изображения в виде таблицы формы `(1797, 64)`.

> **Мини-проверка.** Если в наборе 100 изображений размером 8 × 8, таблица признаков будет иметь 100 строк и 64 столбца. Число строк определяется количеством объектов, а число столбцов — количеством признаков каждого объекта.

7.2. Готовый набор digits

Набор digits уже содержит и признаки, и правильные ответы. Это позволяет сосредоточиться на логике классификации, не выполняя отдельную загрузку файлов и ручную разметку изображений.
Рисунок 3. По одному примеру каждого класса

Характеристика	Значение	Что означает
Количество объектов	1797	Столько изображений доступно в наборе.
Размер изображения	8 × 8	В изображении 64 пикселя.

Характеристика	Значение	Что означает
Количество признаков	64	Каждый признак — яркость одного пикселя.
Классы	0–9	Правильная метка — изображённая цифра.
Диапазон яркости	0–16	0 — фон, большие значения — более яркая линия цифры.

Массив `digits.target_names` содержит названия возможных классов. В данном случае они совпадают с числами от 0 до 9. При этом метка класса не является яркостью и не входит в 64 признака изображения: она хранится отдельно как правильный ответ.

7.3. Как работает K ближайших соседей

KNN (K-Nearest Neighbors) сравнивает новое изображение с известными примерами. Модель находит `k` наиболее похожих объектов обучающей выборки и выбирает класс, который встречается среди них чаще. В практикуме стартовое значение `k` равно 3.
Похожесть определяется по расстоянию между векторами признаков. Если значения соответствующих пикселей у двух изображений близки, расстояние между такими объектами обычно меньше. Следовательно, соседями становятся не изображения, расположенные рядом в таблице, а объекты с близкими числовыми признаками.
Например, если среди трёх ближайших соседей два объекта относятся к классу 5, а один — к классу 3, модель выберет класс 5. Это решение основано на большинстве среди найденных соседей.

> **Аналогия.** Чтобы определить неизвестный музыкальный жанр, можно найти три наиболее похожие песни в своей коллекции и посмотреть, к какому жанру относится большинство из них.

Параметр `k` задаётся до обучения, поэтому его называют гиперпараметром. При слишком малом `k` отдельный необычный пример может сильно повлиять на ответ. При слишком большом `k` в голосовании могут участвовать менее похожие изображения. Подходящее значение проверяют экспериментально на одних и тех же данных и по одинаковым правилам оценки.

> **Важно.** В отличие от многих моделей, KNN в основном сохраняет обучающие примеры, а основная вычислительная работа выполняется при поиске соседей во время

прогнозирования.

7.4. Как оценивать качество

Одной метрики не всегда достаточно для содержательного вывода. Общая доля правильных ответов показывает масштаб качества, матрица ошибок раскрывает направления путаницы, а просмотр отдельных изображений помогает увидеть возможные причины ошибок.

Accuracy = количество правильных прогнозов / количество всех тестовых объектов

Например, если модель правильно классифицировала 90 объектов из 100, её accuracy равна 0,9, или 90 %. Оставшиеся 10 объектов являются ошибками. Значение accuracy всегда находится в диапазоне от 0 до 1.

Инструмент	Что показывает	Ограничение
Accuracy	Доля правильных прогнозов среди всех тестовых примеров.	Не показывает, какие именно классы модель путает.
Матрица ошибок	Сколько объектов каждого истинного класса отнесено к каждому предсказанному классу.	Нужно внимательно читать строки и столбцы.
Список ошибок	Конкретные изображения, на которых прогноз неверен.	Это качественный анализ; по нескольким примерам нельзя делать общий вывод без метрик.
Precision, recall, F1	Качество отдельно по каждому классу.	Для первого анализа достаточно понимать, что значения ближе к 1 лучше.

Правило чтения матрицы. Строка — истинный класс, столбец — прогноз модели. Главная диагональ содержит правильные ответы, остальные клетки — ошибки.

Например, значение 4 в строке класса 7 и столбце класса 1 означает, что четыре изображения настоящей цифры 7 модель ошибочно распознала как 1. Обратная ошибка — цифра 1 распознана как 7 — находилась бы в другой клетке.

Частая ошибка. Нельзя вычислять accuracy, сравнивая признаки `X_test` с прогнозами. Метрика сравнивает два массива классов одинаковой длины: правильные ответы

> `y_test` и прогнозы `y_pred`.

7.5. Обучающая и тестовая выборки

Обучающая выборка используется методом `fit`, а тестовая — только после обучения, когда модель уже настроена. Такое разделение имитирует работу с новыми изображениями, правильные ответы для которых модель заранее не видела.
Параметр `stratify=y` помогает сохранить в обеих частях примерно те же доли классов, что и в исходном наборе. Это особенно важно, когда необходимо сравнивать качество распознавания разных цифр.
`random_state=42` фиксирует случайное разделение. При повторном запуске с теми же данными и параметрами в обучающую и тестовую части попадут те же объекты, поэтому результаты можно сопоставлять.

> **Утечка данных.** Если тестовые объекты или сведения о них влияют на обучение, итоговая оценка может оказаться завышенной. Тестовую часть следует использовать для проверки, а не для подгонки модели.

8. Готовый шаблон

Создайте новый блокнот. Выполняйте ячейки по порядку. Не меняйте `random_state=42` и `test_size=0.25`: это позволит всем получить сопоставимые результаты.
После каждой ячейки проверяйте, появились ли ожидаемые переменные и нет ли сообщения об ошибке. Если изменить раннюю ячейку, следует повторно выполнить и все зависящие от неё ячейки ниже.

Ячейка 1. Импорт библиотек и загрузка данных

Первая ячейка подключает инструменты для вычислений, визуализации, разделения данных, обучения KNN и оценки качества. Команды `print` позволяют проверить формы массивов до начала обучения.

```
import numpy as np
import matplotlib.pyplot as plt

from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import (
accuracy_score,
confusion_matrix,
ConfusionMatrixDisplay,
classification_report,
)

digits = load_digits()
X = digits.data
y = digits.target

print('X:', X.shape)
print('y:', y.shape)
print('images:', digits.images.shape)
print('classes:', digits.target_names)
```

В выводе число объектов должно совпадать у `X`, `y` и `digits.images`. Различаться будут остальные измерения: у таблицы признаков 64 столбца, а изображения представлены двумя измерениями 8 × 8.

Ячейка 2. Просмотр изображений

Визуальная проверка помогает связать числовую метку с изображением и убедиться, что классы интерпретируются правильно. Для каждой цифры выбирается первый объект с соответствующей меткой.

```
fig, axes = plt.subplots(2, 5, figsize=(9, 4))
for digit, ax in enumerate(axes.ravel()):
index = np.where(y == digit)[0][0]
ax.imshow(digits.images[index], cmap='gray_r')
ax.set_title(f'Класс {digit}')
ax.axis('off')
plt.tight_layout()
plt.show()
```

Эта ячейка не обучает модель и не изменяет данные. Она только отображает по одному примеру каждого класса от 0 до 9.

Ячейка 3. Разделение данных

Здесь признаки и метки разделяются одновременно. Благодаря этому каждой строке `X_train` соответствует метка с тем же индексом в `y_train`, а каждой строке `X_test` — метка в `y_test`.

```
X_train, X_test, y_train, y_test = train_test_split(
X,
y,
test_size=0.25,
random_state=42,
stratify=y,
)

print(X_train.shape, X_test.shape)
print(y_train.shape, y_test.shape)
```

> **Проверка формы.** У обучающих признаков и обучающих меток должно совпадать количество объектов. То же правило действует для тестовых признаков и тестовых меток.

Ячейка 4. Обучение и прогноз

Метод `fit` получает обучающие признаки и известные классы. После этого `predict` определяет классы тестовых изображений, не получая правильных ответов `y_test`.

```
model = KNeighborsClassifier(n_neighbors=3)
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

accuracy = accuracy_score(y_test, y_pred)
print(f'Accuracy: {accuracy:.4f}')
print('Ошибок:', np.sum(y_pred != y_test))
```

Выражение `y_pred != y_test` создаёт массив логических значений: `True` отмечает ошибочный прогноз, а `False` — правильный. Сумма такого массива даёт количество ошибок.

Ячейка 5. Матрица ошибок и отчёт

Общая accuracy дополняется подробной информацией по классам. Сначала строится числовая матрица, затем печатается отчёт и создаётся её графическое представление.

```
cm = confusion_matrix(y_test, y_pred)
print(cm)
print(classification_report(y_test, y_pred, digits=3))

ConfusionMatrixDisplay(cm, display_labels=digits.target_names).plot(
cmap='Blues', values_format='d'
)
plt.title('Матрица ошибок KNN')
plt.show()
```

При анализе сначала рассмотрите главную диагональ, затем найдите наибольшие значения вне диагонали. Они укажут, какие пары истинных и предсказанных классов требуют внимания.

> **Важно.** Параметр `digits=3` в `classification_report` задаёт количество знаков после запятой в отчёте и не связан с набором digits или количеством соседей.

9. Практические задачи

> **Порядок сложности.** Задача 1 — самая простая. Выполняйте задачи последовательно: результат предыдущей используется в следующей.

В ответах отделяйте наблюдение от объяснения. Наблюдение содержит конкретное число, форму массива или клетку матрицы, а объяснение показывает, почему этот результат получен и что он означает.

10. Дополнительные задания

> **Статус.** Дополнительные задания выполняются после основных и не снижают оценку при невыполнении.

Дополнительные эксперименты следует проводить при неизменном разделении данных. Тогда различия в результате будут связаны с настройкой модели, а не с тем, что в тестовую выборку попали другие изображения.

- Сравните несколько значений `k`. Для каждого значения запишите accuracy и количество ошибок.
- Найдите значение `k` с наибольшей accuracy на используемой тестовой выборке. Если результаты равны, укажите все варианты с одинаковым качеством.
- Для двух вариантов модели сравните не только accuracy, но и матрицы ошибок. Определите, одинаковые ли классы вызывают затруднения.
- Выведите индексы тестовых объектов, для которых `y_pred` не совпадает с `y_test`, и просмотрите несколько соответствующих изображений.

> **Ограничение вывода.** Лучшее значение `k` в одном разделении данных нельзя автоматически объявлять лучшим для любых изображений. Корректная формулировка должна указывать, на каких данных и по какой метрике выполнено сравнение.

11. Итоговый контроль

В каждом вопросе выберите один вариант и кратко объясните выбор с помощью определения или правила из урока.

1. Что хранится в одной строке `digits.data`?

А) имя файла

Б) 64 значения яркости пикселей одного изображения

В) десять вероятностей классов

Г) матрица ошибок

2. Почему нельзя обучать модель на `X_test`?

А) тестовые данные нужны для независимой оценки

Б) `X_test` всегда содержит строки

В) KNN не принимает тестовые данные

Г) потому что тестовая выборка больше обучающей

3. В матрице ошибок значение `C[8, 1]` равно 3. Что это означает?

А) три изображения цифры 1 распознаны как 8

Б) три изображения цифры 8 распознаны как 1

В) модель три раза обучалась

Г) accuracy равна 0,3

4. Почему при одинаковой accuracy две модели могут вести себя по-разному?

А) они могут ошибаться на разных классах и разных объектах

Б) accuracy содержит номер модели

В) классы всегда меняются местами

Г) такого быть не может

5. Какой вывод является корректным?

А) `k=1` навсегда лучше всех моделей

Б) лучший `k` определяется результатом на конкретных данных и должен проверяться устойчиво

В) чем больше `k`, тем accuracy всегда выше

Г) матрица ошибок не нужна при высокой accuracy

> **Мини-проверка.** Перед завершением контроля убедитесь, что в вопросе о матрице ошибок вы сначала определили истинный класс по строке, а затем предсказанный класс по столбцу.

12. Критерии оценивания

Задача	Максимум	Что проверяется
Задача 1	2 балла	Корректный паспорт данных и объяснение строки `X`.
Задача 2	2 балла	Верный прогноз размеров и исправление логики кода.
Задача 3	2 балла	Рабочая модель, метрики и осмысленный комментарий.
Задача 4	2 балла	Корректное чтение матрицы и анализ ошибок.
Задача 5	2 балла	Эксперимент, сравнение и доказательный итоговый вывод.

Максимум — 10 баллов. Рекомендуемый проходной результат — 6 баллов при обязательном выполнении задач 1–3.
Полный балл за вывод предполагает не только правильное число, но и его интерпретацию. Например, запись значения accuracy без пояснения не показывает, понимается ли смысл метрики.

> **Доказательный вывод.** Укажите настройку модели, полученную метрику, количество ошибок и хотя бы одно наблюдение по матрице ошибок. Избегайте абсолютных формулировок «всегда» и «для любых данных», если эксперимент проводился только на одной выборке.

13. Чек-лист самопроверки

☐ Все ячейки выполняются сверху вниз без ошибок.
☐ Формы `X_train` и `X_test` соответствуют ожидаемым.
☐ Модель обучается только на `X_train` и `y_train`.
☐ Accuracy рассчитана на `y_test` и `y_pred`.
☐ В отчёте указано количество ошибок, а не только accuracy.
☐ Матрица ошибок прочитана по правилу «строка — истина, столбец — прогноз».
☐ Названы классы, на которых модель ошибается.
☐ Эксперимент с `k` выполнен для всех семи значений.
☐ Итоговый вывод содержит числа и ограничение применимости результата.

☐ Файл сохранён с понятным названием.
Если один из пунктов не выполнен, вернитесь к соответствующей ячейке или разделу анализа. После повторного запуска проверьте, что новые значения действительно используются в последующих вычислениях.

14. Итоги урока

> **Теперь вы умеете.** представлять изображение как вектор числовых признаков, запускать готовый классификатор, проверять его на тестовых данных, рассчитывать accuracy, читать матрицу ошибок, находить сложные классы и сравнивать настройки модели.

Классификация не завершается получением одного числа. Полный анализ связывает устройство данных, условия эксперимента и несколько способов оценки: общую accuracy, количество ошибок, распределение ошибок по классам и просмотр отдельных неверно распознанных объектов.
Запишите три коротких ответа:
1. Что было самым понятным?
2. Какой результат вас удивил?
3. Какой следующий эксперимент вы бы провели?

_____

_____

_____

_____

В третьем ответе желательно указать, какой параметр будет изменён, что останется неизменным и по какой метрике будут сравниваться результаты.

15. Мини-глоссарий

Термин	Простое объяснение
Изображение	Матрица чисел, каждое из которых описывает яркость пикселя.
Признак	Числовая характеристика объекта; здесь — значение яркости пикселя.

Термин	Простое объяснение
Класс	Категория, которую должна предсказать модель; здесь — цифра от 0 до 9.
Обучающая выборка	Данные, на которых модель находит закономерности.
Тестовая выборка	Отложенные данные для честной проверки качества.
KNN	Алгоритм, определяющий класс по ближайшим похожим примерам.
Accuracy	Доля правильных прогнозов.
Матрица ошибок	Таблица, показывающая правильные ответы и путаницу между классами.
Гиперпараметр `k`	Настройка KNN: сколько ближайших соседей учитывать.
Утечка данных	Ситуация, когда сведения из тестовой части влияют на обучение и оценка становится нечестной.

Связь терминов можно представить как последовательность: каждый объект описывается признаками и имеет класс; обучающая выборка используется для настройки KNN; тестовая выборка нужна для расчёта accuracy и построения матрицы ошибок; гиперпараметр `k` определяет правило голосования соседей.

16. Источники и справочные материалы

Справочные страницы полезны для уточнения параметров функций, форматов входных данных и возвращаемых значений. При обращении к документации сопоставляйте обозначения из примеров с переменными текущего блокнота.

scikit-learn: `load_digits`: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html — описание набора изображений цифр

scikit-learn: `accuracy_score`: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.accuracy_score.html — определение метрики accuracy

scikit-learn: `confusion_matrix`: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html — правило построения матрицы ошибок