МОДУЛЬ 3

Полный цикл ML-проекта на датасете

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Вступление

01 На прошлых занятиях вы уже знакомились с отдельными элементами машинного обучения: данными, признаками, моделями и метриками.

02 Главная трудность ML-проекта обычно заключается не в одном вызове метода обучения, а в правильной организации всех этапов.

03 Рабочая цепочка должна быть воспроизводимой: повторный запуск ноутбука сверху вниз приводит к тому же способу подготовки данных, тому же разбиению и сопоставимым результатам.

1. Чему вы научитесь

01 различать объект, признак и целевую переменную.

02 проверять размер, типы данных, пропуски, дубликаты и баланс классов.

03 разделять данные на обучающую и тестовую части без утечки информации.

04 объединять масштабирование и модель в Pipeline.

2. Среда выполнения и правила работы

```
python -m pip install pandas matplotlib scikit-learn
```

Команда устанавливает библиотеки в среду Python, из которой она была запущена.

Выполняйте ячейки сверху вниз. После изменения ранней ячейки повторно запустите зависимые ячейки.

3.1. Полный цикл ML-проекта

01 Модель — только один элемент проекта.

02 Сначала формулируют задачу: определяют, что является объектом, какие столбцы служат признаками и какую целевую переменную требуется предсказать.

03 Порядок этапов важен.

04 Воспроизводимость означает, что в ноутбуке зафиксированы не только алгоритм и его настройки, но и последовательность преобразований.

3.2. Термины занятия · таблица 1/4

Термин	Простое объяснение
Объект	Одна строка датасета — один пример, для которого известны признаки.
Признак X	Измеряемая характеристика объекта, используемая моделью для прогноза.

3.2. Термины занятия · таблица 2/4

Термин	Простое объяснение
Целевая переменная y	Правильная метка, которую модель должна научиться предсказывать.
Классификация	Задача выбора одного класса из конечного набора классов.

3.2. Термины занятия · таблица 3/4

Термин	Простое объяснение
Гиперпараметр	Настройка, задаваемая до обучения; в KNN это число соседей k.
Валидация	Оценивание нескольких вариантов модели внутри обучающей части.

3.2. Термины занятия · таблица 4/4

Термин	Простое объяснение
Тестовая выборка	Отложенные данные для финальной проверки выбранного решения.
Pipeline	Единая цепочка предобработки и модели, уменьшающая риск ошибок и утечки данных.

3.3. Почему нельзя выбирать модель по тесту

01 Тестовая выборка играет роль независимого экзамена.

02 При кросс-валидации обучающая часть несколько раз делится на внутренние обучающие и валидационные фрагменты.

03 Например, при 5-кратной кросс-валидации получают пять значений метрики.

04 После выбора гиперпараметра модель с выбранными настройками обучают на всей обучающей части.

3.4. Метрики (1/2) · таблица 1/3

Метрика	Что показывает	На что обратить внимание
Accuracy	Доля всех правильных прогнозов.	Удобна при примерно сопоставимых классах.
Precision	Какая доля объектов, названных моделью классом, действительно относится к нему.	Важна, когда ложное срабатывание дорого.

3.4. Метрики (1/2) · таблица 2/3

Метрика	Что показывает	На что обратить внимание
Recall	Какую долю реальных объектов класса модель нашла.	Важна, когда опасно пропустить объект.
F1	Гармоническое среднее precision и recall.	Полезна для компромисса между двумя типами ошибок.

3.4. Метрики (1/2) · таблица 3/3

Метрика	Что показывает	На что обратить внимание
Матрица ошибок	Сколько объектов каждого истинного класса попало в каждый предсказанный класс.	Показывает не только число, но и направление ошибок.

3.4. Метрики (2/2)

01 При чтении матрицы ошибок необходимо проверить порядок меток классов, использованный функцией.

02 Мини-проверка: если accuracy высока, но macro recall заметно ниже, следует проверить, не пропускает ли модель значительную часть объектов одного или нескольких классов.

4. Чек-лист перед сдачей

01 ☐ Я сформулировал тип задачи и целевую переменную.

02 ☐ Я проверил размер, пропуски, дубликаты и баланс классов.

03 ☐ Я разделил данные до масштабирования.

04 ☐ Я объединил StandardScaler и KNN в Pipeline.

1. Практическая часть

01 Работайте последовательно.

3. Дополнительные задания (1/2)

Модель	CV mean	CV std	Test accuracy
KNN (k=3)			
Decision Tree (max_depth=3)			

3. Дополнительные задания (2/2)

```
error_indices = np.where(y_pred != y_test)[0]
print("Индексы ошибок в X_test:", error_indices)
if len(error_indices) > 0:
    idx = error_indices[0]
    print(f"\nПример ошибки {idx}:")
    print(f"Истинный класс: {y_test.iloc[idx]}")
    print(f"Предсказанный класс: {y_pred[idx]}")
    print("Значения признаков ошибочного объекта:")
    print(X_test.iloc[idx].round(3))
    print("\nСредние значения для истинного класса:")
    print(X_train[y_train == y_test.iloc[idx]].mean().round(3))
```

Фрагмент примера. Полный код приведён в тексте лекции.

Практическая работа

01 Задание №1

02 Задание №2

03 Задание №3

04 Задание №4

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами