МОДУЛЬ 3

Улучшение модели - данные, признаки, проверка

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

Улучшение модели - данные, признаки, проверка

01 На прошлом занятии вы собрали полный мини-пайплайн машинного обучения.

02 Важно не пытаться исправить всё одновременно.

1. Чему вы научитесь

01 отличать проблему данных от проблемы алгоритма.

02 находить пропуски, дубликаты, невозможные значения и шумовые столбцы.

03 выбирать признаки, связанные с задачей.

04 сравнивать модели на одной и той же тестовой выборке.

2. Среда выполнения и правила честного сравнения

01 При работе в ноутбуке результат одной ячейки может зависеть от всех выполненных ранее ячеек.

02 Выполняйте ячейки сверху вниз и не удаляйте RANDOM_STATE = 42. Фиксированное значение помогает повторить случайное разбиение и получить сопоставимые результаты.

03 Не изменяйте тестовую выборку: исходная и улучшенная модели должны проходить один и тот же «экзамен».

04 Не считайте улучшением случайный рост одной метрики на одном запуске. Рост accuracy следует сопоставить с macro F1, матрицей ошибок и результатами повторной проверки.

3.1. Три способа улучшить результат · таблица 1/2

Направление	Что проверяем	Примеры действий
Данные	Можно ли доверять строкам и значениям?	Удалить полные дубликаты; обработать пропуски; найти невозможные значения
Признаки	Есть ли в таблице полезный сигнал?	Убрать ID и случайный шум; сравнить разные наборы признаков

3.1. Три способа улучшить результат · таблица 2/2

Направление	Что проверяем	Примеры действий
Проверка	Улучшение устойчиво или случайно?	Использовать тот же тест; выполнить кросс-валидацию; сравнить несколько метрик

3.2. Почему «добавим более сложную модель» — не первый шаг

01 Если в таблице есть пропуски, дубликаты, ошибочные значения и случайные столбцы, более сложный алгоритм может лишь точнее запомнить беспорядок.

02 Например, столбец sample_id обозначает номер объекта, а не его свойства.

03 Частая ошибка — считать, что большее количество столбцов автоматически даёт модели больше полезной информации.

3.3. Что значит честное сравнение

01 Исходная и улучшенная модели должны проверяться на одних и тех же тестовых объектах.

02 Одинаковым должен оставаться не только список тестовых объектов, но и правильные ответы y_test .

03 Тестовую выборку не используют для выбора признаков, заполнения пропусков или настройки шагов обработки.

3.4. Метрики занятия · таблица 1/2

Метрика	Простой смысл	На что обратить внимание
Accuracy	Доля правильных прогнозов	Удобна при примерно равных классах
Macro F1	Среднее качество по каждому классу	Не позволяет крупному классу «скрыть» слабый результат по другому классу

3.4. Метрики занятия · таблица 2/2

Метрика	Простой смысл	На что обратить внимание
Матрица ошибок	Таблица правильных и ошибочных прогнозов	Показывает, какие классы модель путает

Блок 1. Импорт библиотек

```
import numpy as np
import pandas as pd
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split, StratifiedKFold, cross_val_
    score
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, f1_score, confusion_matrix
RANDOM_STATE = 42
rng = np.random.RandomState(RANDOM_STATE)
```

После выполнения блока в памяти появляются названия библиотек, классов и функций, но модель ещё не обучается.

Блок 2. Подготовка независимого теста и «испорченной» обучающей таблицы

01 Разбиение выполняется до добавления учебных проблем.

02 Метод reset_index(drop=True) создаёт последовательные индексы строк и не добавляет старый индекс как новый столбец.

03 Затем в данные добавляются технический идентификатор и восемь шумовых столбцов.

04 Переменные X_train_clean и y_train_clean сохраняют исходную обучающую часть.

5. Чек-лист перед сдачей

01 Проверяйте работу после перезапуска ноутбука и последовательного выполнения всех ячеек.

02 Все ячейки выполняются сверху вниз без ошибок.

03 Исходная и улучшенная модели проверены на одном тесте.

04 Заполнена таблица проблем данных.

6. Итог урока

01 Сегодня вы улучшили модель не за счёт «магии» и не за счёт случайной замены алгоритма.

02 Корректный итог эксперимента отвечает на три вопроса: что было изменено, как изменились метрики и насколько устойчиво наблюдаемое различие.

Практическая работа

01 Задача 1. Зафиксируйте исходный результат

02 Задача 2. Проведите аудит данных

03 Задача 3. Исправьте данные и код подготовки признаков

04 Задача 4. Сравните наборы признаков

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами