PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Теоретическая часть

Самостоятельная работа: подготовка мини-пайплайна ML

Содержание

- Что Вы будете уметь после выполнения работы
- Краткая памятка
- Практический кейс «Умный полив»
- Формулы
- Формат сдачи
- Итог работы

Что Вы будете уметь после выполнения работы

- формулировать задачу машинного обучения через объект, вход и прогноз;
- отбирать признаки и исключать идентификаторы и поля с утечкой ответа;
- определять целевую переменную и источник разметки;
- описывать тип модели и последовательность мини-пайплайна;
- разделять данные на обучающую, проверочную и тестовую части;
- рассчитывать accuracy и recall по матрице ошибок;
- описывать последствия ошибок и меры безопасного применения модели.

Краткая памятка

Понятие	Простое объяснение
Объект	Одна строка таблицы, для которой модель делает прогноз.

Понятие	Простое объяснение
Признак X	Характеристика объекта, известная до момента прогноза.
Целевая переменная y	Правильный ответ, который модель учится предсказывать.
Классификация	Выбор одного класса из заданного набора.
Train	Данные, на которых модель обучается.
Validation	Данные для выбора настроек и варианта модели.
Test	Новые данные для однократной итоговой проверки.
Утечка данных	В признаки или подготовку попала информация, раскрывающая ответ заранее.
Accuracy	Доля всех правильных прогнозов.
Recall класса «Да»	Доля реально нуждающихся в поливе растений, которые модель нашла.

Практический кейс «Умный полив»

> Школьная лаборатория создаёт помощника для теплицы. По параметрам растения модель должна определить, нужно ли полить его сейчас. Каждая строка — одно наблюдение за растением.

Практический результат: модель возвращает один из двух классов: «Да» или «Нет». Особенно опасно пропустить растение, которому действительно нужен полив.
В полном наборе есть 80 размеченных наблюдений. Ниже показан фрагмент ранних данных, по которому нужно определить признаки и правила подготовки.

ID	Влажность почвы, %	Температура, °C	Свет, ч/день	Дней после полива	Состояние листьев	Полить сейчас?
P01	22	27	6	5	поникшие	Да
P02	58	23	4	2	норма	Нет
P03	31	29	7	4	поникшие	Да
P04	72	21	3	1	норма	Нет

ID	Влажность почвы, %	Температура, °C	Свет, ч/день	Дней после полива	Состояние листьев	Полить сейчас?
P05	40	25	5	3	норма	Нет
P06		26	6	4	поникшие	Да
P07	18	30	8	6	пожелтевшие	Да
P08	65	22	2	2	норма	Нет
P09	36	28	7	3	поникшие	Да
P10	135	24	4	2	норма	Нет
P11	28	27	6	5	пожелт.	Да
P12	58	23	4	2	норма	Нет

В таблице специально оставлены проблемы качества: пропуск, невозможное значение, неодинаковая запись категории и повторяющаяся строка.

Результаты модели на 20 новых наблюдениях

Строки — фактический ответ эксперта, столбцы — прогноз модели.

Фактический класс / прогноз	Да	Нет
Да	8	2
Нет	1	9

Формулы

Accuracy = число всех правильных прогнозов / общее число прогнозов.

Recall класса «Да» = верно найденные объекты класса «Да» / все реальные объекты класса «Да».

Формат сдачи

> Можно загрузить один файл, но внутри него должны быть явно выделены семь пронумерованных результатов. Пропуск раздела означает, что соответствующий элемент не выполнен.

Итог работы

> Вы подготовили семь отдельных частей мини-пайплайна ML: определили задачу, признаки и целевую переменную, описали модель, разделили данные, рассчитали метрики и оценили риски. Такой формат позволяет проверить каждый обязательный результат отдельно.