SMART

Модуль 4. Проектирование и защита учебного ИИ-проекта

Занятие 4.6. Подготовка датасета для прикладного кейса

Подготовка датасета для прикладного кейса



Модель не понимает таблицу так, как человек. Дубликаты, пропуски и данные «из будущего» дают высокий результат на проверке и провал в реальной работе.

Теория

SMART

Четыре роли столбцов

Прежде чем чистить данные, определите, что делает каждый столбец.

идентификатор

запись различает, но в модель не идёт (record_id)

признак

то, что известно в момент прогноза

целевая

что модель должна предсказать (needs_service_24h)

утечка

заполняется после события — исключить из признаков

Главное правило

В признаки берём только то, что реально известно в момент, когда модель делает прогноз.

SMART

Реестр ошибок датасета «ТехСервис-24»

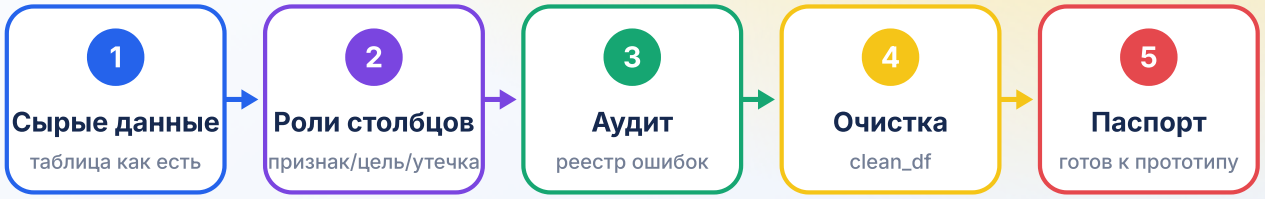
Ручной аудит таблицы: находим проблемы и формулируем обоснованные правила очистки.

Тип проблемы	Пример в данных	Правило очистки
Дубликат	record_id M07 повторяется	удалить повторяющуюся строку
Пропуск	M04 — вибрация, M09 — нагрузка	отметить, не выдумывать значение
Ошибка диапазона	нагрузка 140 %, температура −40	проверить и исключить невозможное
Несогласованные категории	Pump / pump, NIGHT / night	привести к единому виду
Утечка данных	**repair_result_after_shift**	**удалить — известно после смены**

SMART

Путь от сырых данных к датасету

Подготовка данных — отдельный этап проекта, а не техническая формальность.



Обоснованно

Правила очистки объясняем, а неизвестные значения не заменяем выдуманными.

Итог занятия

Очищенная таблица и паспорт датасета — то, что можно передать разработчику модели.

SMART

Нормализуем категории целевой переменной

В сырых данных цель записана по-разному: 1, 0, yes, Да, Нет. Приводим к единым 0 и 1.

```
raw = ["1", "0", "yes", "Да", "Нет", "1", "0"]
mapping = {"1": 1, "yes": 1, "да": 1, "0": 0, "нет": 0}
clean = [mapping[v.lower()] for v in raw]
print(clean)
print("высокий риск:", sum(clean))
```

ВЫВОД

```
[1, 0, 1, 1, 0, 1, 0]
высокий риск: 4
```

Единый формат

lower() убирает разницу регистра, словарь сводит все варианты к 0 или 1.

Зачем

Модель не поймёт «Да» и «1» как одно и то же — метки нужно согласовать.

SMART

Почему утечка данных опасна

На проверке — блеск

Столбец, заполненный после события (результат ремонта), сильно связан с целью — прототип показывает высокую точность.

!

В работе — провал

В реальном прогнозе этого столбца ещё нет: модель лишается «подсказки из будущего» и ошибается.

SMART

Памятка занятия

1. **Роли столбцов**
   идентификатор, признак, целевая и недопустимый (утечка)
2. **Аудит**
   дубликаты, пропуски, ошибки диапазонов, несогласованные категории
3. **Честная очистка**
   неизвестные значения не заменяем выдуманными
4. **Паспорт датасета**
   фиксирует признаки, цель, ограничения и риски модели

Главная мысль

Качество прототипа закладывается на этапе данных: чистый датасет без утечки важнее, чем сложная модель.

SMART

ИТОГ ЗАНЯТИЯ

Датасет готов к прототипированию

Мы определили роли столбцов, нашли ошибки, честно очистили данные и убрали утечку. Дальше выберем подход к решению — модель, алгоритм или ИИ-инструмент.

Следующее занятие

Занятие 4.7. Выбор подхода для профессионального решения

