МОДУЛЬ 4

Подготовка датасета для прикладного кейса

Разработчик интеллектуальных решений
Базовый уровень для студентов СПО

2. Вступление-обращение

01 Подготовка данных похожа на проверку измерительного прибора перед экспериментом: даже правильный алгоритм не компенсирует систематические ошибки во входной информации.

3. Что вы сможете после занятия

01 сформулировать объект прогнозирования и тип задачи машинного обучения.

02 разделить столбцы на идентификаторы, приизнаки, целевую переменную и недопустимые признаки.

03 обнаружить пропуски, дубликаты, ошибки диапазонов и несогласованные категории.

04 применить обоснованные правила очистки, не подменяя неизвестные значения выдуманными.

5. Краткий теоретический минимум (1/2)

01 Подготовка данных — отдельный этап проекта, а не техническая формальность.

02 До очистки необходимо зафиксировать постановку задачи.

03 Тип данных сам по себе не определяет роль столбца.

04 В качестве признаков используйте только то, что реально известно в момент, когда модель должна сделать прогноз.

5. Краткий теоретический минимум (2/2)

01 Заполнение пропуска медианой является оценкой, а не восстановлением истинного измерения.

02 Не следует исправлять подозрительное значение только потому, что оно выглядит необычно.

6. Прикладной кейс «ТехСервис-24»

01 Учебный сервисный центр обслуживает насосы, конвейеры и вентиляторы.

02 Можно ли по параметрам оборудования, доступным в конце смены, определить, требуется ли срочное обслуживание в течение следующих 24 часов?

03 Положительный класс соответствует случаю, когда срочное обслуживание потребуется, отрицательный — когда оно не потребуется.

04 Даже если учебный прототип покажет хороший результат, его нельзя автоматически переносить на реальный сервисный центр.

7. Исходный набор данных

01 Из-за ширины таблица разделена на две части.

02 При соединении частей необходимо контролировать ключ: повторяющийся record_id может размножить строки при merge.

03 Технические параметры.

04 Контекст, целевая переменная и результат после смены.

8. План работы на 90 минут · таблица 1/3

Этап	Время	Результат
Постановка задачи и роли столбцов	10 мин	Паспорт задачи
Ручной аудит таблицы	15 мин	Реестр ошибок

8. План работы на 90 минут · таблица 2/3

Этап	Время	Результат
Анализ и исправление кода	15 мин	Рабочие фрагменты pandas
Очистка и расчёт показателей	35 мин	clean_df и показатели

8. План работы на 90 минут · таблица 3/3

Этап	Время	Результат
Паспорт датасета и вывод	15 мин	Готовность к прототипированию

Задание 1. Постановка задачи и роли столбцов

01 Разделите столбцы на четыре группы: идентификатор, признаки, целевая переменная и недопустимые признаки.

Задание 2. Ручной аудит исходной таблицы

01 В наборе следует проверить повторяющийся record_id, регистр категорий, сокращение названия смены, разные обозначения классов, пропуски и физически или логически сомнительные значения.

02 Есть два способа считать дубликаты.

Задание 3. Анализ ошибочного кода

```
X = df.drop(columns=["needs_service_24h"])
y = df["needs_service_24h"].astype(int)
df.drop_duplicates(inplace=True)
X = X.fillna(X.mean(numeric_only=True))
print(X.shape, y.shape)
```

Рассмотрите фрагмент.

Задание 4. Нормализация категорий и целевой переменной

```
work_df = df.copy()
work_df["machine_type"] = (
    work_df["machine_type"]
    .str.strip()
    .str.lower()
)
work_df["shift"] = (
    work_df["shift"]
    .str.strip()
    .str.lower()
    .replace({"eve": "evening"})
```

Фрагмент примера. Полный код приведён в тексте лекции.

Задание 5. Очистка датасета и формирование clean_df

```
work_df = work_df.drop_duplicates(subset="record_id", keep="first").copy()
invalid_load = ~work_df["load_pct"].between(0, 100)
invalid_hours = work_df["hours_since_service"] < 0
work_df.loc[invalid_load, "load_pct"] = pd.NA
work_df.loc[invalid_hours, "hours_since_service"] = pd.NA
```

Это обязательное задание.

Задание 6. Автоматические проверки результата

```
assert clean_df["record_id"].is_unique
assert clean_df["needs_service_24h"].isin([0, 1]).all()
assert clean_df[feature_columns].isna().sum().sum() == 0
assert clean_df["load_pct"].between(0, 100).all()
assert (clean_df["hours_since_service"] >= 0).all()
assert "record_id" not in X.columns
assert "repair_result_after_shift" not in X.columns
assert len(X) == len(y)
assert X.index.equals(y.index)
```

Проверки должны завершаться без ошибок.

Задание 7. Базовые показатели качества данных

```
print("Размер исходного набора:", df.shape)
print("Размер очищенного набора:", clean_df.shape)
duplicate_count = df.duplicated(subset="record_id", keep="first").sum()
print("Лишних дубликатов:", duplicate_count)
missing_share = df.isna().mean().sort_values(ascending=False)
print("Доля пропусков:")
print(missing_share)
class_counts = clean_df["needs_service_24h"].value_counts().sort_index()
class_share = clean_df["needs_service_24h"].value_counts(normalize=True).sort_ind
    ex()
```

Фрагмент примера. Полный код приведён в тексте лекции.

10. Итоговый паспорт датасета

01 Он является итоговым продуктом занятия вместе с clean_df.

02 Формулировки должны быть проверяемыми.

03 В строке «Критерий готовности к прототипированию» укажите измеримые условия: уникальность ключа, допустимые значения цели, отсутствие пропусков в X, отсутствие утечки и успешное выполнение автоматических проверок.

12. Критерии оценивания · таблица 1/3

Компонент	Баллы	Условие полного балла
Постановка задачи и роли столбцов	3	Верно определены объект, тип задачи, цель, признаки и исключения.
Ручной аудит	4	Найдено не менее 8 проблем/рисков и предложены обоснованные правила.

12. Критерии оценивания · таблица 2/3

Компонент	Баллы	Условие полного балла
Анализ результата кода	3	Выбран правильный ответ и объяснена проблема несогласованных меток.
Исправление кода	4	Устранены все ключевые логические ошибки, X и y согласованы.

12. Критерии оценивания · таблица 3/3

Компонент	Баллы	Условие полного балла
Очистка и показатели	6	Датасет очищен, проверки пройдены, показатели рассчитаны.
Итого	20	Зачёт: 14 и более баллов при обязательном выполнении задачи 5.

13. Чек-лист сдачи

01 ☐ Я сформулировал(а) задачу и единицу наблюдения.

02 ☐ Я отделил(а) идентификатор, признаки, цель и столбец с утечкой.

03 ☐ В итоговой таблице нет повторяющихся record_id.

04 ☐ Категории записаны единообразно.

14. Самопроверка

01 Можно ли включать record_id в признаки только потому, что это число или код?

02 Почему repair_result_after_shift является утечкой?

03 Чем медиана полезна при заполнении пропусков?

04 Достаточно ли отсутствия пропусков, чтобы признать датасет качественным?

15. Глоссарий

01 Датасет. Набор связанных наблюдений, обычно представленный таблицей.

02 Признак. Характеристика объекта, используемая моделью для прогноза.

03 Целевая переменная. Ответ, который модель должна научиться предсказывать.

Приложение. Код для создания исходной таблицы

```
import pandas as pd
import numpy as np
rows = [
["M01", "pump", 72.4, 3.2, 78, 410, 1, "day", 0, "no_repair"],
["M02", "conveyor", 81.1, 6.8, 92, 780, 3, "night", 1, "bearing"],
["M03", "fan", 66.0, 2.1, 55, 250, 0, "evening", 0, "no_repair"],
["M04", "Pump", 79.5, np.nan, 88, 690, 2, "night", "yes", "inspection"],
["M05", "conveyor", 105.0, 9.2, 140, 1200, 5, "day", 1, "overheat"],
["M06", "fan", -40, 1.8, 45, 180, 0, "day", 0, "sensor_error"],
["M07", "pump", 75.2, 4.0, 80, -30, 1, "evening", 0, "no_repair"],
["M08", "conveyor", 83.0, 7.1, 95, 820, 4, "NIGHT", "Да", "belt"],
["M09", "fan", 68.3, 2.4, np.nan, 300, 0, "day", "Нет", "no_repair"],
```

Фрагмент примера. Полный код приведён в тексте лекции.

Практическая работа

01 Задание №1

02 Задание №2

03 Задание №3

04 Задание №4

Проверка результата

01 Сопоставление результата с условием

02 Проверка на исходных и изменённых данных

03 Объяснение решения своими словами