PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

Учебные данные синтетические. Не используйте реальные персональные или конфиденциальные сведения.

При дополнении наборов создавайте вымышленные идентификаторы, тексты обращений и числовые значения. Если для решения задачи требуется конкретизация, формулируйте безопасное допущение или отмечайте необходимость уточнения, но не добавляйте сведения о реальных людях, организациях и объектах.

1. Паспорт самостоятельной работы

Содержание

- 2. Семь проверяемых шагов
- 3. Рекомендуемое распределение времени
- 4. Основные правила
- 5. Краткий словарь
- 6. Кейс А. Классификатор заявок технической поддержки
- 7. Кейс Б. Помощник по срочному обслуживанию оборудования
- 8. Кейс В. Прогноз времени доставки
- 9. Рабочий лист: семь проверяемых шагов
- 10. Что нужно отправить преподавателю
- 11. Чек-лист перед сдачей
- 12. Итог работы

Параметр	Описание
Тема	4.9. Данные и требования проекта
Вид деятельности	Самостоятельная работа без непосредственного участия преподавателя
Продолжительность	45 минут

Параметр	Описание
Цель	Связать пользовательскую задачу, архитектуру данных, требования и критерии приемки будущего прототипа.
Итоговый результат	Семь отдельных проектных результатов по одному выбранному кейсу.
Необходимые средства	Документ, электронная таблица или знакомая среда Python; установка программ не требуется.

Работа посвящена предпроектному этапу: до создания прототипа необходимо определить, какую задачу он решает, какие данные доступны в момент применения и как будет проверяться результат. Это помогает заранее обнаружить противоречия, которые нельзя устранить одним только выбором модели.

Важно для сдачи
Кейс является единым профессиональным контекстом, но работа состоит из семи самостоятельных шагов. Каждый шаг должен быть выделен, иметь отдельный результат и проверяться независимо. При этом результаты должны быть согласованы между собой: вход и выход из шага 1 должны соответствовать полям шага 2, найденные в шаге 3 проблемы — действиям шага 4, а требования шага 5 — критериям приемки шага 6.

2. Семь проверяемых шагов

№	Проверяемый шаг	Что нужно сдать
1	Пользовательская задача	Пользователь, рабочая ситуация, решение и границы проекта.
2	Архитектура данных	Вход, выход, единица наблюдения, типы, диапазоны, доступность полей и утечка.
3	Аудит качества данных	Проблемные строки и столбцы с обоснованием влияния на проект.
4	Подготовка и дополнение	Решения по проблемам и минимум три новых примера разных ролей.
5	Требования и автоматизация	Не менее трёх требований, включая обработку неполного и неоднозначного ввода.

№	Проверяемый шаг	Что нужно сдать
6	Критерии приемки	Не менее трёх измеримых критериев: показатель, порог и процедура проверки.
7	Риски и готовность	Ограничения, ручная проверка и решение о готовности к прототипированию.

Шаги образуют последовательность решений. Например, обнаруженный пропуск нельзя просто указать в аудите: далее необходимо определить безопасное действие, закрепить реакцию системы в требованиях и предусмотреть проверку этой реакции при приемке.

3. Рекомендуемое распределение времени

Этап	Время
Выбор кейса и фиксация цифрового следа	3 минуты
Шаг 1	4 минуты
Шаг 2	6 минут
Шаг 3	8 минут
Шаг 4	6 минут
Шаг 5	6 минут
Шаг 6	6 минут
Шаг 7	3 минуты
Самопроверка и сдача	3 минуты

Если один из этапов занимает больше запланированного времени, сначала зафиксируйте краткое обоснованное решение, а затем переходите дальше. Не следует тратить всё время на очистку таблицы и оставлять без ответа требования, приемку или риски.

4. Основные правила

- Выберите один кейс: А, Б или В.

- Не исправляйте неизвестное значение догадкой: запросите уточнение, исключите строку или передайте её на ручную проверку.
- Не используйте поля, которые появляются после решения, ремонта, маршрутизации или доставки.
- Критерий приемки должен содержать показатель, числовой порог и процедуру проверки.
- В новых примерах не используйте реальные персональные или конфиденциальные данные.
- Зафиксируйте время начала, окончания, инструмент и количество существенных исправлений.
- Различайте исправление формата и изменение смысла. Например, приведение «Да» к «да» сохраняет значение, а замена неизвестной категории предполагаемой категорией создаёт новое, не подтверждённое данными значение.
- Не удаляйте проблемную строку без объяснения. Для каждого исключения укажите причину и возможное влияние на объём или представительность набора.
- Полные дубли и похожие реальные случаи — не одно и то же. Дублем считается повтор одной и той же записи, а одинаковые признаки у разных наблюдений могут быть допустимы.

5. Краткий словарь

Понятие	Объяснение
Функциональное требование	Что система должна принять, обработать, рассчитать, классифицировать или передать специалисту.
Архитектура данных	Описание единицы наблюдения, входных полей, результата, форматов, диапазонов и доступности данных.
Целевая переменная	Правильный исторический результат, который система должна предсказывать.
Утечка данных	Использование поля, недоступного в момент прогноза или почти раскрывающего правильный ответ.
Критерий приемки	Измеримое условие с показателем, порогом и способом проверки.
Ручная проверка	Передача неполного, неоднозначного или рискованного случая специалисту.

Понятие	Объяснение
Единица наблюдения	Один объект или случай, которому соответствует одна строка набора: например, одна заявка, одно состояние оборудования или одна доставка.
Полнота данных	Доля заполненных обязательных значений среди всех обязательных значений набора.
Accuracy	Доля правильно обработанных примеров среди всех проверенных примеров задачи классификации.
MAE	Среднее абсолютных ошибок прогноза. В задаче доставки показывает, на сколько минут в среднем прогноз отличается от фактического времени без учёта знака ошибки.

Целевая переменная используется при обучении и проверке, но не является обычным входным признаком в момент получения прогноза. Поле-утечка отличается от цели тем, что оно не нужно как правильный ответ и должно быть исключено из признаков из-за времени появления или прямой связи с уже произошедшим результатом.

6. Кейс A. Классификатор заявок технической поддержки

Диспетчер сервисной службы хочет автоматически направлять обращения в категории «доступ», «оборудование», «сеть», «программное обеспечение». Если заявка относится к нескольким категориям или недостаточно информативна, она передаётся специалисту. Поле assigned_team заполняется после маршрутизации и не является входным признаком. Единицей наблюдения в этом кейсе является одна заявка. Основной смысловой признак — текст обращения, а категория представляет правильный исторический результат классификации. Канал и срочность доступны до маршрутизации, однако их полезность и допустимость как признаков необходимо обосновать отдельно.

ID	Текст заявки	Канал	Срочность	Категория	assigned_team
A01	Не могу войти в учебную систему, пароль не подходит	email	высокая	доступ	team_access

ID	Текст заявки	Канал	Срочность	Категория	assigned_team
A02	Принтер захватывает бумагу и не печатает	portal	средняя	оборудование	team_hardware
A03	В аудитории постоянно пропадает Wi-Fi	chat	высокая	сеть	team_network
A04	Принтер захватывает бумагу и не печатает	portal	средняя	оборудование	team_hardware
A05	—	email	средняя	программное обеспечение	team_software
A06	Нужно срочно сбросить пароль преподавателя	portal	высокая	Доступ	team_access
A07	После обновления программа закрывается при запуске	email	средняя	программное обеспечение	team_software
A08	Не работает мышь на рабочем месте	telegram	низкая	оборудование	team_hardware
A09	Сломан монитор, изображения нет	portal	средняя	сеть	team_hardware
A10	Сайт колледжа не открывается из внутренней сети	chat	высокая	сеть	team_network
A11	Не открывается файл DOCX в офисной программе	email	низкая	программное обеспечение	team_software

ID	Текст заявки	Канал	Срочность	Категория	assigned_team
A12	VPN не подключается, а пароль учётной записи заблокирован	portal	высокая	сеть	team_network

Минимальные ограничения
Допустимые каналы: email, portal, chat. Категории записываются в едином регистре. Пустой текст недопустим. Неоднозначные заявки направляются на ручную проверку.
При аудите проверяйте не только формат, но и согласованность смысла: категория должна соответствовать тексту обращения, а неоднозначный текст не следует принудительно относить к одному классу без установленного правила.

Обратите внимание: совпадение assigned_team с категорией не доказывает качество исходной разметки, поскольку команда назначена после маршрутизации. Использование этого поля при обучении создало бы нереалистично простую задачу, но такой признак отсутствовал бы в момент обработки новой заявки.

7. Кейс Б. Помощник по срочному обслуживанию оборудования

Система должна по показаниям оборудования определить, требуется ли срочное обслуживание. Целевая переменная urgent_service принимает значения «да» и «нет». Поле repair_cost_after появляется после ремонта и создаёт утечку данных.
Единицей наблюдения является одно зафиксированное состояние оборудования. До принятия решения доступны показания температуры, вибрации, наработки в часах и количества кодов ошибок. Значение urgent_service должно проверяться не по стоимости последующего ремонта, а по заданному правилу эксперта.

ID	Темп., °C	Вибрация	Часы	Коды	urgent_service	repair_cost_after
B01	65	2,1	120	0	нет	0
B02	88	5,8	480	3	да	45000
B03	72	3,0	260	1	нет	0
B04	72	3,0	260	1	нет	0

ID	Темп., °C	Вибрация	Часы	Коды	urgent_service	repair_cost_after
B05	86	—	510	2	да	30000
B06	-15	2,4	150	0	нет	0
B07	95	6,2	600	4	Да	52000
B08	84	5,0	450	2	нет	35000
B09	90	4,4	300	1	да	12000
B10	70	2,2	200	0	нет	0
B11	110	7,0	720	5	да	80000
B12	78	2,8	260	1	да	0

Диапазоны и правило эксперта

Температура 0–120 °C, вибрация 0–10 мм/с, часы 0–1000, коды ошибок 0–10. Класс «да», если температура ≥ 90 °C, или вибрация ≥ 5,5 мм/с, или часы ≥ 500, или коды ошибок ≥ 3; иначе «нет». При пропуске ключевого датчика — ручная проверка.

Союз «или» означает, что для класса «да» достаточно выполнения хотя бы одного условия. Значения, точно равные порогам, также относятся к классу «да», поскольку в правиле используются знаки ≥.

При проверке строк последовательно отделяйте разные типы проблем: выход за допустимый диапазон, пропуск показания, несогласованный регистр целевой переменной, дубль и противоречие экспертному правилу. Одна строка может содержать несколько независимых проблем, и каждую из них следует зафиксировать.

8. Кейс B. Прогноз времени доставки

Логисту требуется оценка времени доставки в минутах в момент передачи заказа курьеру. Это задача регрессии. Целевая переменная — delivery_time_min. Поле rating_after заполняется после доставки и не может использоваться как признак.

В отличие от классификации, результатом здесь является числовая оценка, а не название класса. Единица наблюдения — одна завершённая доставка, для которой известны входные условия на момент передачи заказа и фактическое время, используемое как целевое значение.

ID	Км	Масса	Нагрузка	Погода	Задержка	Время	rating_after
C01	3,2	1,5	2	ясно	5	28	5
C02	8,0	4,0	5	дождь	12	65	4
C03	0	2,0	1	ясно	0	15	5
C04	8,0	4,0	5	дождь	12	65	4
C05	12,5	—	6	снег	20	95	3
C06	-4,0	1,0	2	ясно	5	20	5
C07	6,0	25,0	4	дождь	10	70	4
C08	5,5	2,0	3	Sunny	7	42	5
C09	15,0	8,0	7	снег	25	130	2
C10	2,5	1,0	2	ясно	3	22	5
C11	9,0	3,5	5	дождь	15	68	4
C12	4,0	2,0	3	ясно	8	180	1

Рабочие ограничения

Расстояние > 0 и ≤ 30 км; масса > 0 и ≤ 20 кг; нагрузка — целое число 0–10; погода: «ясно», «дождь», «снег»; задержка 0–60 минут; целевое время положительно.

Граничные значения следует читать буквально: расстояние 0 км недопустимо, а 30 км допустимо; масса 20 кг допустима, а значение выше 20 кг выходит за рабочий диапазон.

Необычно большое положительное время не обязательно является технически неверным: оно соответствует формальному ограничению «целевое время положительно». Однако такое значение может быть смысловой аномалией и требовать проверки по первичному источнику. Это пример различия между формальной валидацией и содержательным аудитом.

Паспорт выполнения

Выбранный кейс: _____ Инструмент: _____ Время начала: _____ Время окончания: _____ Количество существенных исправлений: _____

Существенным исправлением считается изменение, влияющее на выводы работы: например, пересмотр роли поля, исправление неверно определённой проблемы или изменение критерия приемки. Исправление опечатки без изменения смысла можно не учитывать.

9. Рабочий лист: семь проверяемых шагов

Заполняйте рабочий лист только по одному выбранному кейсу. Формулировки должны быть конкретными: вместо «система работает с данными» укажите, какие поля она получает, в какой момент и какое решение возвращает.

10. Что нужно отправить преподавателю

- шаг 1 — описание пользовательской задачи;
- шаг 2 — архитектуру данных;
- шаг 3 — журнал аудита;
- шаг 4 — план подготовки и три новых примера;
- шаг 5 — три проверяемых требования;
- шаг 6 — три измеримых критерия приемки;
- шаг 7 — риски и вывод о готовности;
- ответы на самопроверку или отметку о сверке с ключом.

Перед отправкой проверьте, что названия полей и ограничения во всех семи шагах относятся к одному выбранному кейсу. Если исправленная таблица прикладывается отдельно, сохраните исходные ID или явно укажите соответствие между исходными и подготовленными строками.

11. Чек-лист перед сдачей

☐ Я выбрал один кейс и зафиксировал цифровой след.
☐ Я оформил семь отдельных пронумерованных шагов.
☐ Я описал архитектуру данных и доступность каждого поля.
☐ Я исключил признаки, появляющиеся после результата.
☐ Я не заменял неизвестные значения догадками.
☐ Я добавил три примера разных ролей.
☐ Я сформулировал три требования и три критерия приемки.
☐ Я указал границы автоматизации и ручную проверку.
☐ Я описал ограничения и риски.
☐ В файле нет персональных и конфиденциальных данных.
☐ Мои действия по подготовке соответствуют проблемам, найденным в аудите.
☐ Для каждого критерия приемки указаны показатель, числовой порог и процедура проверки.

☐ Итоговый вывод согласован с перечисленными рисками и не обещает автоматизацию случаев, переданных специалисту.

12. Итог работы

Вы подготовили семь самостоятельных результатов предпроектного этапа: описали пользовательскую задачу, архитектуру данных, качество и подготовку набора, требования, критерии приемки и риски. Такой формат позволяет отдельно проверить каждый обязательный элемент и принять обоснованное решение о готовности кейса к прототипированию.
Главный результат работы — не просто очищенная таблица, а согласованная схема будущего решения. В ней понятно, какие данные доступны системе, какие значения считаются допустимыми, как обрабатываются исключения и по каким измеримым условиям прототип может быть принят. Если данных недостаточно или риск нельзя контролировать автоматически, корректным проектным решением остаётся ограничение автоматизации и участие специалиста.