PDF-версия исходной лекции iSMART из сохранённого HTML. Содержание не заменено пересказом. Служебные элементы интерфейса исключены.

1. Зачем тестировать прикладное решение

Содержание

- 2. Планируемые результаты
- 3. Краткий теоретический минимум
- 4. Кейс и критерии приемки
- 5. Материалы и программная среда
- 6. Тестовый набор
- 9. Итоговая таблица проверки качества
- 10. Журнал ошибок и ограничений
- 11. Итоговый вывод
- 12. Чек-лист самопроверки
- 13. Данные для копирования в Python

Рабочий прототип — это еще не готовое решение. Он может правильно обрабатывать знакомые примеры и одновременно ошибаться на редких формулировках, пограничных значениях или некорректных входных данных. Поэтому перед использованием прототипа необходимо провести независимую проверку: заранее определить ожидаемый результат, запустить решение на тестовом наборе, сравнить ответы и оценить последствия ошибок.
Такой порядок нужен, чтобы вывод о качестве не зависел от нескольких специально подобранных удачных примеров. Если сначала посмотреть ответы модели, а затем изменить под них ожидаемые классы, проверка перестанет быть независимой и полученные метрики окажутся завышенными.
На занятии вы будете проверять прототип «ServiceDesk Assistant 2.0». Он классифицирует заявки технической поддержки по четырем категориям: «Доступ», «Оборудование», «Сеть» и «ПО». Для каждой заявки прототип возвращает категорию и уверенность — число от 0 до 1. Чем ближе уверенность к 1, тем надежнее модель считает свой ответ.
Уверенность показывает внутреннюю оценку прототипа, но сама по себе не доказывает правильность прогноза. Модель может дать ошибочный ответ с высокой увереннностью или правильный ответ с низкой. Поэтому уверенность нужно сопоставлять с фактическими результатами на тестовом наборе.

> **Главный принцип.** Качество проекта нельзя оценивать по одному удачному примеру. Нужны разные тесты, единые критерии и обоснованный вывод о допустимом режиме работы.

2. Планируемые результаты

В ходе проверки важно не только получить значения метрик, но и связать их с требованиями заказчика. Итогом работы должен стать аргументированный ответ на вопрос, в каком режиме прототип можно использовать и какие риски при этом сохраняются.

- составлять таблицу тестирования с ожидаемым и фактическим результатом;
- рассчитывать accuracy и интерпретировать его ограничения;
- строить и читать матрицу ошибок для многоклассовой классификации;
- рассчитывать precision, recall и F1 для отдельных классов;
- оценивать влияние порога уверенности на качество и долю автоматически обработанных заявок;
- различать техническую ошибку, ошибку данных, ошибку модели и ошибку требований;
- формулировать вывод о готовности решения к пилотному использованию.

После выполнения работы каждое решение о приемке должно опираться на конкретное значение метрики, наблюдаемую ошибку или явно сформулированное ограничение, а не только на общее впечатление от работы прототипа.

3. Краткий теоретический минимум

Разные метрики отвечают на разные вопросы. Accuracy оценивает общую долю верных ответов, recall показывает, насколько полно система находит объекты определенного класса, а precision — насколько можно доверять присвоению этого класса. Поэтому одна метрика не заменяет остальные.

Термин	Объяснение
Тестовый набор	примеры, которые не использовались для настройки прототипа и применяются только для независимой проверки.
Ожидаемый класс	ответ, заранее установленный экспертом или составителем задания.
Фактический класс	ответ, который вернул прототип.
Accuracy	доля всех правильных ответов: число верных прогнозов делится на число тестов.
Precision класса	какая доля объектов, отнесенных системой к классу, действительно относится к этому классу.
Recall класса	какую долю объектов нужного класса система смогла найти.
F1	сбалансированная оценка precision и recall. Она полезна, когда важно учитывать оба типа ошибок.
Матрица ошибок	таблица, где строки соответствуют ожидаемым классам, а столбцы — прогнозам прототипа.
Порог уверенности	минимальная уверенность, при которой ответ принимается автоматически. Ответы ниже порога передаются специалисту.
Coverage	доля примеров, обработанных автоматически, без передачи специалисту.
Критерий приемки	измеримое условие, по которому заказчик решает, можно ли использовать решение.

Для расчета метрик отдельный класс временно рассматривают как целевой, а все остальные классы объединяют в группу «не этот класс». Тогда используются следующие обозначения:

- TP (true positive) — система верно присвоила объекту рассматриваемый класс;
- FP (false positive) — система присвоила рассматриваемый класс объекту, который к нему не относится;

- FN (false negative) — объект относится к рассматриваемому классу, но система выбрала другой класс.

Например, при оценке класса «Сеть» заявка с ожидаемым классом «Сеть» и прогнозом «Сеть» увеличивает TP. Если система ошибочно назвала заявкой «Сеть» объект класса «Оборудование», увеличивается FP. Если реальную заявку класса «Сеть» система отнесла к «ПО», увеличивается FN.
Формулы, которые понадобятся в работе:

- accuracy = число правильных ответов / общее число тестов;
- precision = TP / (TP + FP);
- recall = TP / (TP + FN);
- F1 = 2 × precision × recall / (precision + recall);
- coverage = число автоматически принятых ответов / общее число тестов.

F1 рассчитывается отдельно для каждого класса. Macro F1 получают как среднее арифметическое значений F1 всех классов: каждый класс влияет на результат одинаково, независимо от числа примеров этого класса. Аналогично минимальный recall класса — это наименьшее из значений recall, рассчитанных для всех четырех категорий.
Матрицу ошибок читают по строкам: каждая строка показывает, как распределились прогнозы для объектов одного ожидаемого класса. Значения на главной диагонали соответствуют правильным ответам, а значения вне диагонали показывают, какие классы система путает между собой.
При использовании порога отдельно вычисляют качество только тех ответов, которые были приняты автоматически. В данном задании выражение «точность автоматически принятых ответов» означает долю правильных прогнозов среди ответов с уверенностью не ниже выбранного порога. Это не precision отдельного класса.

> **Важно.** Высокий accuracy не гарантирует, что решение одинаково хорошо работает по всем классам. Поэтому для прикладного проекта проверяют не одну, а несколько метрик, а также отдельно рассматривают критичные ошибки.

> **Обратите внимание.** Повышение порога обычно уменьшает число автоматически принятых заявок. Поэтому порог нельзя выбирать только по качеству оставшихся ответов: одновременно необходимо проверять coverage.

Мини-проверка: если из 20 заявок система автоматически приняла 16, то coverage равен 16 / 20 = 0,80. Если среди этих 16 прогнозов правильными оказались 14, точность автоматически принятых ответов равна 14 / 16 = 0,875.

4. Кейс и критерии приемки

Заказчик — служба технической поддержки колледжа. Прототип должен автоматически направлять типовые заявки в нужную группу. Заявки с низкой уверенностью разрешено передавать оператору. Тестовые данные заморожены: во время проверки нельзя изменять ожидаемые ответы под результат модели.
Критерии приемки задаются до анализа результатов. Это позволяет отделить измерение качества от решения о внедрении: сначала рассчитываются показатели, затем каждый из них сравнивается с заранее установленной границей.

Проверяемая часть	Критерий приемки
Автоматический классификатор без передачи оператору	accuracy не ниже 0,80; macro F1 не ниже 0,75; recall каждого класса не ниже 0,70.

Проверяемая часть	Критерий приемки
Полуавтоматический процесс	точность автоматически принятых ответов не ниже 0,85; coverage не ниже 0,80; все ответы ниже порога передаются оператору.
Обработка входа	пустая строка и текст короче 5 символов не должны классифицироваться автоматически.
Объяснимость	для каждой ошибки должна быть указана вероятная причина и предлагаемое действие.

Критерии для двух режимов проверяются отдельно. Если классификатор не проходит требования для полностью автоматической работы, это еще не означает, что прототип нельзя использовать в полуавтоматическом режиме. Однако такой режим допустим только при одновременном выполнении требований к точности автоматических ответов, coverage и передаче остальных заявок оператору.
Проверка некорректного входа относится не к качеству классификации, а к надежности обработки данных. Пустую или слишком короткую строку система должна отклонить до выбора класса, иначе случайный прогноз может попасть в рабочий процесс как обычная заявка.

5. Материалы и программная среда

- Python 3.10 или новее;
- Jupyter Notebook, Google Colab или IDE с запуском Python;
- библиотеки pandas и scikit-learn: при необходимости выполните команду `pip install pandas scikit-learn`;
- тестовый набор из 24 заявок, приведенный ниже.

Перед расчетами убедитесь, что все 24 записи загружены без пропусков, названия классов записаны одинаково, а уверенность представлена числом. Даже лишний пробел или различие в написании класса может привести к неверному сравнению ожидаемого и фактического результата.
Рекомендуемый порядок работы: сначала заполнить столбец «Верно?», затем вычислить общие метрики, построить матрицу ошибок, рассчитать метрики классов и только после этого исследовать пороги уверенности. Такой порядок помогает не смешивать качество исходных прогнозов с качеством полуавтоматического режима.

6. Тестовый набор

Набор содержит по шесть заявок каждого ожидаемого класса. Благодаря этому можно сравнивать recall категорий в одинаковых условиях. При проверке учитывается точное совпадение названий ожидаемого и фактического классов.

№	Текст заявки	Ожидаемый класс	Прогноз	Уверенность	Верно?
1	Не могу войти в личный кабинет после смены пароля	Доступ	Доступ	0.91	
2	Учетная запись заблокирована после нескольких попыток входа	Доступ	Доступ	0.84	

№	Текст заявки	Ожидаемый класс	Прогноз	Уверенность	Верно?
3	Программа просит войти снова после обновления	Доступ	ПО	0.48	
4	Нужен сброс пароля сотрудника	Доступ	Доступ	0.72	
5	Не приходит код подтверждения для входа	Доступ	Доступ	0.66	
6	Нет прав на общую папку отдела	Доступ	Доступ	0.58	
7	Ноутбук не включается	Оборудование	Оборудование	0.89	
8	Монитор мигает и гаснет	Оборудование	Оборудование	0.76	
9	Принтер виден, но печать не начинается	Оборудование	Сеть	0.44	
10	После замены клавиатуры часть клавиш не работает	Оборудование	ПО	0.51	
11	Сломан разъем питания ноутбука	Оборудование	Оборудование	0.64	
12	Сканер не реагирует на кнопку включения	Оборудование	Оборудование	0.57	
13	Нет доступа к интернету по кабелю	Сеть	Сеть	0.93	
14	Wi-Fi постоянно отключается	Сеть	Сеть	0.82	
15	Компьютер не получает IP-адрес	Сеть	Оборудование	0.49	
16	Не открывается внутренний сайт, остальные сайты работают	Сеть	ПО	0.53	
17	Очень медленно работает корпоративная сеть	Сеть	Сеть	0.68	
18	VPN подключается, но ресурсы недоступны	Сеть	Сеть	0.61	
19	Текстовый редактор закрывается при запуске	ПО	ПО	0.94	
20	После обновления приложение показывает ошибку	ПО	ПО	0.86	

№	Текст заявки	Ожидаемый класс	Прогноз	Уверенность	Верно?
21	Не удается активировать лицензию программы	ПО	Доступ	0.52	
22	В отчете неверно отображается дата	ПО	ПО	0.73	
23	Приложение зависает при сохранении файла	ПО	ПО	0.63	
24	Не устанавливается обновление программы	ПО	ПО	0.59	

> **Правило работы.** В столбце «Верно?» поставьте 1, если ожидаемый и фактический классы совпадают, и 0, если они различаются.

После заполнения проверьте, что сумма значений в столбце «Верно?» совпадает с числом элементов на главной диагонали матрицы ошибок. Это два способа подсчета одних и тех же правильных прогнозов, поэтому различие между ними указывает на ошибку в расчетах.
При анализе уверенности не меняйте исходный прогноз. Порог определяет только то, будет ли готовый ответ принят автоматически или передан оператору; он не исправляет выбранный моделью класс.

9. Итоговая таблица проверки качества

Заполняйте таблицу после завершения всех расчетов. Для каждого числового показателя используйте одинаковое правило округления, например до двух или трех знаков после запятой, чтобы сравнение с критерием было однозначным.

Показатель	Полученное значение	Критерий	Статус: пройден/не пройден
Accuracy		≥ 0,80	
Macro F1		≥ 0,75	
Минимальный recall класса		≥ 0,70	
Точность автоматических ответов при выбранном пороге		≥ 0,85	
Coverage при выбранном пороге		≥ 0,80	
Некорректные входы блокируются		Да	

Если значение точно равно границе, критерий считается выполненным, поскольку в требованиях используется условие «не ниже». Не объединяйте статусы разных показателей: прохождение accuracy не компенсирует невыполнение требования к recall отдельного класса.

> **Важно.** Общий статус режима может быть «пройден» только тогда, когда выполнены все относящиеся к нему критерии. Среднее значение показателей вместо такой проверки использовать нельзя.

10. Журнал ошибок и ограничений

Журнал ошибок превращает список неверных ответов в план улучшения. В графе «Наблюдаемая ошибка» укажите ожидаемый и фактический классы, а в графе «Вероятная причина» отделяйте подтвержденные данные от предположений.
Возможные типы причин:

- техническая ошибка — сбой запуска, чтения данных, интерфейса или передачи результата;
- ошибка данных — неверная разметка, пропуск, дубликат или недостаток нужных примеров;
- ошибка модели — прототип не различает формулировки или признаки близких классов;
- ошибка требований — правило отнесения заявки к классу сформулировано неоднозначно или допускает разные трактовки.

Критичность следует определять по последствиям неверной маршрутизации, а не только по уверенности модели. Ошибка с низкой уверенностью может быть безопаснее в полуавтоматическом режиме, если такая заявка будет передана оператору.

№ теста	Наблюдаемая ошибка	Вероятная причина	Критичность	Предлагаемое улучшение

Предлагаемое улучшение должно соответствовать вероятной причине. Например, неоднозначные правила требуют уточнения требований, а недостаток характерных примеров — проверки и дополнения датасета. Повторный запуск без изменения причины ошибки сам по себе не является улучшением.

11. Итоговый вывод

Сформулируйте вывод в 6–8 предложениях. Укажите: какой набор использован; какие метрики получены; какие ошибки обнаружены; выполнены ли критерии; какой режим работы выбран; какие ограничения сохраняются; что необходимо сделать перед внедрением.
Начните с описания объема и состава тестового набора, затем приведите значения основных метрик. После этого назовите классы и виды заявок, на которых обнаружены ошибки, и сопоставьте результаты с критериями приемки. Завершите вывод конкретной рекомендацией: полностью автоматический режим, полуавтоматический пилот или отказ от запуска до исправлений.
Избегайте формулировок «модель работает хорошо» без числового обоснования. Если выбран полуавтоматический режим, обязательно укажите порог, полученные при нем точность автоматических ответов и coverage, а также подтвердите передачу остальных заявок оператору.

_____

_____

_____

_____

_____

_____

_____

12. Чек-лист самопроверки

Используйте чек-лист после завершения расчетов. Если хотя бы один пункт не выполнен, соответствующую часть работы следует проверить до формулировки окончательного решения о приемке.

- Я не изменял ожидаемые ответы после запуска прототипа.
- Я проверил все 24 примера и отметил правильные и ошибочные ответы.
- Я рассчитал accuracy и проверил его по критерию приемки.
- Я заполнил матрицу ошибок и определил проблемные классы.
- Я исправил ошибку в расчете recall.
- Я сравнил не менее двух порогов уверенности.
- Я заполнил итоговую таблицу качества и журнал ошибок.
- Мой вывод основан на числах и содержит ограничения решения.

Дополнительно проверьте согласованность результатов: число правильных прогнозов должно совпадать в исходной таблице и матрице ошибок, coverage должно быть рассчитано относительно всех 24 заявок, а качество автоматических ответов — только относительно заявок, прошедших выбранный порог.

13. Данные для копирования в Python

Ниже приведены те же данные, что и в тестовой таблице. После загрузки проверьте число записей и порядок полей в каждом кортеже: номер, текст, ожидаемый класс, прогноз и уверенность.

```
test_data = [
(1, 'Не могу войти в личный кабинет после смены пароля', 'Доступ', 'Доступ', 0.91),
(2, 'Учетная запись заблокирована после нескольких попыток входа', 'Доступ', 'Доступ', 0.84),
(3, 'Программа просит войти снова после обновления', 'Доступ', 'ПО', 0.48),
(4, 'Нужен сброс пароля сотрудника', 'Доступ', 'Доступ', 0.72),
(5, 'Не приходит код подтверждения для входа', 'Доступ', 'Доступ', 0.66),
(6, 'Нет прав на общую папку отдела', 'Доступ', 'Доступ', 0.58),
(7, 'Ноутбук не включается', 'Оборудование', 'Оборудование', 0.89),
(8, 'Монитор мигает и гаснет', 'Оборудование', 'Оборудование', 0.76),
(9, 'Принтер виден, но печать не начинается', 'Оборудование', 'Сеть', 0.44),
(10, 'После замены клавиатуры часть клавиш не работает', 'Оборудование', 'ПО', 0.51),
(11, 'Сломан разъем питания ноутбука', 'Оборудование', 'Оборудование', 0.64),
(12, 'Сканер не реагирует на кнопку включения', 'Оборудование', 'Оборудование', 0.57),
(13, 'Нет доступа к интернету по кабелю', 'Сеть', 'Сеть', 0.93),
(14, 'Wi-Fi постоянно отключается', 'Сеть', 'Сеть', 0.82),
(15, 'Компьютер не получает IP-адрес', 'Сеть', 'Оборудование', 0.49),
(16, 'Не открывается внутренний сайт, остальные сайты работают', 'Сеть', 'ПО', 0.53),
(17, 'Очень медленно работает корпоративная сеть', 'Сеть', 'Сеть', 0.68),
(18, 'VPN подключается, но ресурсы недоступны', 'Сеть', 'Сеть', 0.61),
(19, 'Текстовый редактор закрывается при запуске', 'ПО', 'ПО', 0.94),
(20, 'После обновления приложение показывает ошибку', 'ПО', 'ПО', 0.86),
(21, 'Не удается активировать лицензию программы', 'ПО', 'Доступ', 0.52),
(22, 'В отчете неверно отображается дата', 'ПО', 'ПО', 0.73),
(23, 'Приложение зависает при сохранении файла', 'ПО', 'ПО', 0.63),
(24, 'Не устанавливается обновление программы', 'ПО', 'ПО', 0.59)
]
```

При создании DataFrame задайте названия столбцов в том же порядке. Не округляйте значения уверенности до проверки порогов: преждевременное округление может изменить решение для заявки, расположенной рядом с границей.