SMART

Модуль 2. Математические основы искусственного интеллекта

Занятие 2.14. Корреляция - связаны ли два признака

Корреляция: связаны ли два признака



Корреляция — это число от −1 до +1, которое показывает, меняются ли два признака вместе. Так модель отделяет полезные признаки от случайного шума.

Теория

SMART

Что показывает коэффициент r

Знак говорит о направлении связи, модуль — о её силе.

r → +1

положительная: X растёт — Y растёт вместе с ним

r → −1

отрицательная: X растёт — Y убывает

r ≈ 0

нет линейной связи — облако точек без направления

Главная идея

Корреляция помогает понять, какие из десятков признаков реально связаны с целью, а какие — шум.

SMART

Шкала интерпретации r

По модулю коэффициента оценивают силу связи между признаками.

Значение r	Сила связи	Пример
±0,9 … ±1,0	Очень сильная	Площадь квартиры и цена
±0,7 … ±0,9	Сильная	Часы учёбы и балл на экзамене
±0,4 … ±0,7	Умеренная	Рост и вес человека
±0,1 … ±0,4	Слабая	Этаж и цена квартиры
−0,1 … +0,1	**Нет связи**	**Размер обуви и IQ**

Направление

Знак «+» — признаки растут вместе, «−» — один растёт, другой падает.

Отбор признаков

Признаки со связью около нуля можно исключить из модели.

SMART

Считаем корреляцию в Python

Вручную по формуле Пирсона считать не нужно — модуль statistics делает это одной строкой.

```
import statistics as st
temp = [15, 20, 25, 28, 30, 35]
sales = [40, 65, 90, 110, 130, 160]
r = st.correlation(temp, sales)
print(round(r, 3))
```

ВЫВОД

```
0.995
```

Температура и мороженое

r ≈ 0,995 — очень сильная положительная связь: жарче → больше продаж.

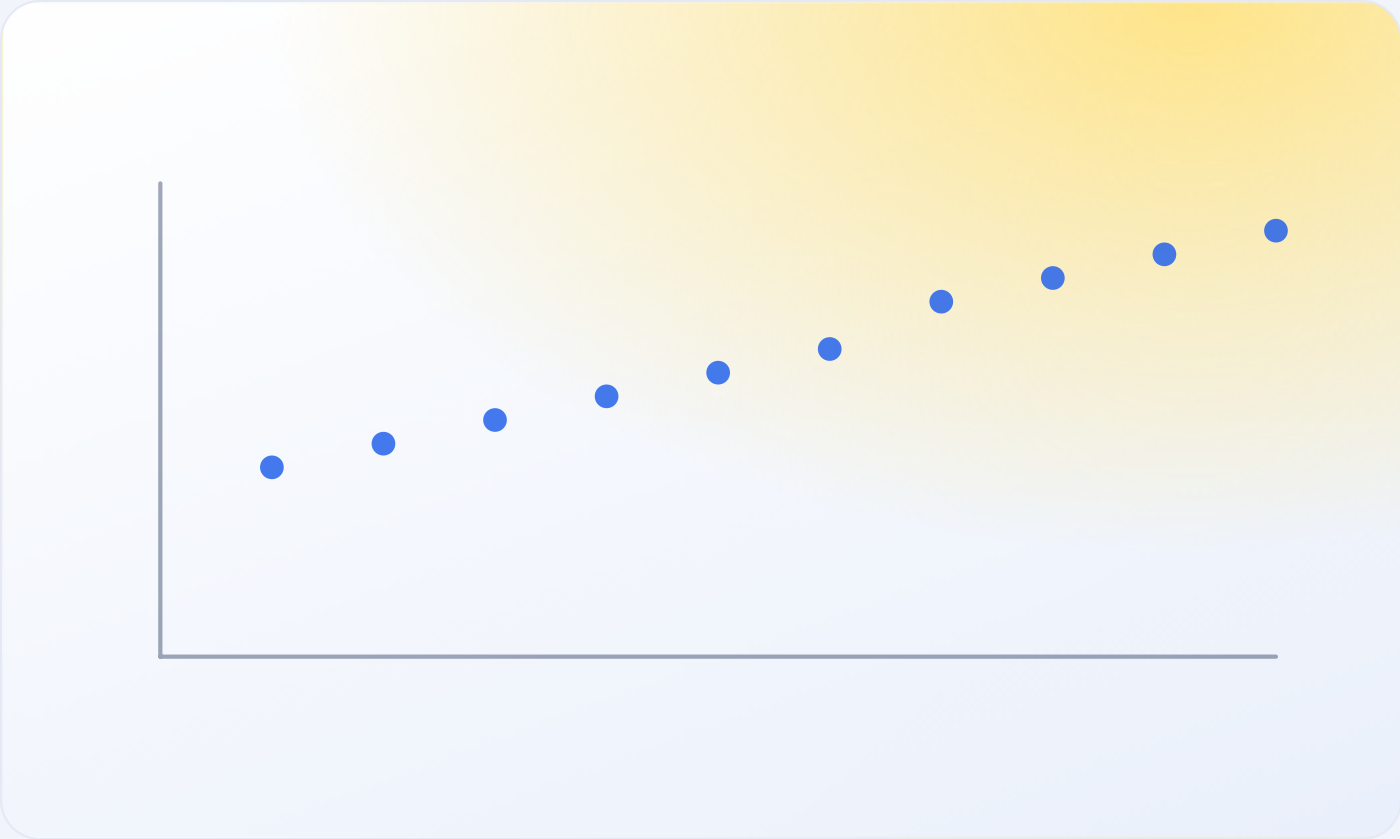
Готовые инструменты

Похожий результат дают numpy (corrcoef) и pandas (.corr).

SMART

Связь видно на точечной диаграмме

10 студентов: часы подготовки (X) и балл на экзамене (Y). Точки вытянуты по диагонали ↗.



Форма облака

Чем больше часов — тем выше балл: облако тянется снизу-слева вверх-вправо.

Сильная связь

Для этих данных r ≈ 1,0 — почти идеальная положительная корреляция.

SMART

Две ловушки корреляции

Корреляция ≠ причина

Связь двух признаков не значит, что один вызывает другой. Оба могут зависеть от третьего, скрытого фактора.

!

Только линейная связь

Пирсон измеряет линейную связь. У кривой (U-образной) зависимости r может быть ≈ 0, хотя связь есть.

SMART

Памятка занятия

1. **Диапазон**
   r лежит от −1 до +1: знак — направление, модуль — сила
2. **Ноль**
   r ≈ 0 — линейной связи нет, признак похож на шум
3. **Python**
   st.correlation, numpy.corrcoef или pandas .corr
4. **Осторожно**
   корреляция не доказывает причину и видит только линию

Главная мысль

Корреляция показывает, связаны ли два признака линейно, и помогает отобрать признаки для модели — но не путайте связь с причиной.

SMART

ИТОГ ЗАНЯТИЯ

Связь признаков измерима

Мы научились видеть и считать корреляцию и отличать связь от шума. Дальше соберём все инструменты вместе, чтобы принимать решения на основе данных.

Следующее занятие

Занятие 2.15. Принятие решений на основе данных

