SMART

Модуль 2. Математические основы искусственного интеллекта

Занятие 2.13. Распределение данных - как увидеть закономерность

Распределение данных: как увидеть закономерность



Среднее показывает центр, но не форму. Одинаковое среднее может скрывать совсем разные данные — форму раскрывает распределение.

Теория

SMART

Как описать форму данных

Частота показывает, как часто встречается значение; гистограмма делает форму видимой.

распределение

где значений много, а где мало по всему диапазону

частота

сколько раз значение или группа встретились в данных

гистограмма

столбцы: X — группы значений, высота — частота

Мода

Значение или группа, которая встречается чаще всего — самый высокий столбец гистограммы.

SMART

Строим таблицу частот

Словарь считает, сколько раз встретилось значение; sorted() выводит ключи по возрастанию.

```
scores = [4, 7, 7, 8, 4, 9, 7, 4, 8, 7]
freq = {}
for s in scores:
    freq[s] = freq.get(s, 0) + 1
for value, count in sorted(freq.items()):
    print(value, '-', count)
```

ВЫВОД

```
4 - 3
7 - 4
8 - 2
9 - 1
```

get(x, 0)

Возвращает текущую частоту или 0 для нового значения — без ошибки KeyError.

Мода здесь

Значение 7 встречается 4 раза — это мода набора.

SMART

Гистограмма уверенности спам-фильтра

30 сообщений получили оценку от 1 до 5, где 5 — «точно спам». Один символ ▇ = 1 сообщение.

Оценка	Частота	Отн. частота	Гистограмма
1	4	13,3%	▇▇▇▇
2	5	16,7%	▇▇▇▇▇
3	**10**	**33,3%**	▇▇▇▇▇▇▇▇▇▇
4	6	20,0%	▇▇▇▇▇▇
5	5	16,7%	▇▇▇▇▇

Мода = 3

Фильтр чаще всего «сомневается» — ставит среднюю оценку 3.

Форма

Пик в центре, края ниже — распределение почти симметрично.

SMART

Симметричное и скошенное распределение

Одно среднее — разные формы. Форма подсказывает, среднее или медиана честнее.

Симметричное

- стороны похожи
- пик в центре
- рост, ошибки приборов
- среднее ≈ медиана

Скошенное

- один хвост длиннее
- пик смещён
- зарплаты, время загрузки
- среднее ≠ медиана

Хвост

Длинный хвост тянет среднее в свою сторону — тогда медиана надёжнее.

Читаем график

Смотрим, где пик, есть ли хвосты и насколько ровно распределены значения.

SMART

Зачем ИИ форма данных

Форма распределения напрямую влияет на то, как обучается и ведёт себя модель.

пик

показывает самые частые значения — типичные примеры

хвосты

редкие значения и выбросы, где модель чаще ошибается

баланс

перекос классов делает модель предвзятой к частому

Практика

Прежде чем обучать модель, смотрят на распределение — оно предсказывает проблемы с данными.

SMART

Памятка занятия

1. **Частоты**
   таблица частот — первый шаг к пониманию данных
2. **Гистограмма**
   делает форму распределения видимой
3. **Форма**
   симметрия или скос подсказывают: среднее или медиана
4. **Выбросы**
   хвосты и редкие значения — зона риска для модели

Главная мысль

Распределение показывает не центр, а форму данных целиком — где пик, где хвосты и чего ждать от модели.

SMART

ИТОГ ЗАНЯТИЯ

Форму данных видно

Мы научились строить частоты и гистограмму и читать форму распределения. Дальше посмотрим, как связаны между собой два признака — корреляция.

Следующее занятие

Занятие 2.14. Корреляция - связаны ли два признака

